

Notas de Aula de Álgebra Linear

Elían Miguel Ferreira Custódio

20 de agosto de 2026

Sumário

1	Introdução à Álgebra Linear	1
1.1	Representação Geométrica de Sistemas Lineares	1
1.2	Representação Matricial de Sistemas Lineares	4
1.3	Classificação de Sistemas Lineares	5
1.4	Produto Interno Euclidiano	6
1.5	Desigualdades envolvendo o Produto Interno Euclidiano	8
1.6	Exercícios	9
2	Eliminação Gaussiana	11
2.1	Ideia da Eliminação	11
2.2	Eliminação	14
2.3	Multiplicação de Matrizes	16
2.4	Propriedades da Multiplicação de Matrizes	17
2.5	Eliminação com Matrizes	19
2.6	Matrizes de Permutação	22
2.7	Inversa de uma Matriz	22
2.8	Matrizes em Blocos	26
2.9	Exercícios	27
3	Fatoração LU	31
3.1	Fatoração LU	31
3.2	Fatoração LDU	33
3.3	Existência e Unicidade da Fatoração LU	33
3.4	Transposta de uma Matriz	35
3.5	Fatoração LDL^T	37
3.6	Fatoração PLU	37
3.7	Exercícios	37
4	Espaços Vetoriais	41
4.1	Espaços Vetoriais	41
4.2	Subespaços Vetoriais	43
4.3	Transformações Lineares	44
4.4	Propriedades dos Subespaços Vetoriais	45
4.5	Núcleo e Imagem de uma Matriz	47
4.6	Forma Escalonada de uma Matriz	49
4.7	Soluções de Sistemas Lineares	53
4.8	Exercícios	54

5	Os Quatro Subespaços Fundamentais	57
5.1	Posto de uma Matriz	57
5.2	Os Quatro Subespaços Fundamentais	58
5.3	Base de um Espaço Vetorial	59
5.4	Dimensão de um Espaço Vetorial	61
5.5	Base e Dimensão de $C(A)$ e $C(A^T)$	63
5.6	Base e Dimensão de $N(A)$	64
5.7	Base e Dimensão de $N(A^T)$	67
5.8	Resumo sobre os Quatro Subespaços Fundamentais	70
5.9	Exercícios	70
6	Transformações Lineares	73
6.1	Transformações Lineares	73
6.2	Núcleo e Imagem de uma Transformação Linear	75
6.3	Matriz de uma Transformação Linear	76
6.4	Composição de Transformações Lineares	78
6.5	Bijeções e Isomorfismos	80
6.6	Coordenadas e Mudança de Bases	82
6.7	Exercícios	85
7	Ortogonalidade	87
7.1	Norma e Produto Interno	87
7.2	Ortogonalidade	88
7.3	Complemento Ortogonal	91
7.4	Matrizes de Projeção	97
7.5	Mínimos Quadrados	102
7.6	Exercícios	105
8	Fatoração QR	109
8.1	Vetores Ortonormais	109
8.2	Matrizes Ortogonais	111
8.3	Processo de Gram-Schmidt	113
8.4	Fatoração QR	115
	Referências	119

Lista de Figuras

1.1	Exemplo de sistema linear	2
1.2	Operações entre vetores	3
1.3	Visualização do produto interno	7
2.1	Sistema linear antes da eliminação	11
2.2	Sistema linear depois da eliminação	12
7.1	Teorema de Pitágoras	89
7.2	Ortogonalidade em $\mathbb{R}^2$	90
7.3	Ortogonalidade em $\mathbb{R}^3$	91
7.4	Vetores LI em $\mathbb{R}^2$	97
7.5	Projeção ortogonal em $\mathbb{R}^2$	98
7.6	Regressão linear	104

Capítulo 1

Introdução à Álgebra Linear

Estas notas de aula destinam-se aos estudantes da FGV-EMAp que estão cursando a disciplina “Álgebra Linear”, com o Prof. Guilherme Tegoni Goedert. Álgebra Linear é uma disciplina considerada difícil pela maioria dos estudantes. É a primeira vez em que as ideias atingem um nível muito alto de abstração. Ao mesmo tempo, porém, e justamente por isso, é uma das áreas mais fascinantes e importantes da Matemática.

De fato, algumas das suas aplicações são:

- Resolução de sistemas de equações diferenciais ordinárias;
- Modelagem de circuitos elétricos;
- Modelos epidemiológicos;
- Manipulação de imagens e de vídeos;
- Aprendizado de máquinas.

Através destas notas de aula, eu pretendo ajudar os estudantes a entenderem todas as ferramentas que a Álgebra Linear desenvolve e utiliza, fornecendo uma sólida base teórica, e, de igual modo, ilustrando com algumas de suas aplicações.

1.1 Representação Geométrica de Sistemas Lineares

Importante: este capítulo é baseado em (1).

Em Álgebra Linear, nós estamos interessados em um problema principal, que é a base de todo o ferramental teórico que será desenvolvido: “Como podemos resolver um sistema linear de m equações e n variáveis? Quando é possível fazer isto?”.

Para responder a esta pergunta, é necessário primeiramente definir o que é um sistema linear:

Definição 1.1.1 (Sistema linear). *Um **sistema linear de m equações e n variáveis** é definido como um conjunto finito de equações envolvendo um mesmo conjunto de variáveis que devem ser satisfeitas simultaneamente, e que possui a seguinte forma:*

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \end{cases}$$

Um exemplo simples é o caso 2×2 , como no exemplo a seguir:

$$\begin{cases} x + 2y = 0 \\ 2x - y = 5 \end{cases}.$$




Figura 1.1: exemplo de sistema linear (arquivo pessoal)

Resolver este sistema não é uma tarefa difícil: da primeira equação, sabemos que $y = -\frac{x}{2}$. Da segunda equação, sabemos que $y = 2x - 5$. A solução procurada é exatamente o ponto P em que as duas retas se intersectam (neste caso, $P = (2, -1)$). No entanto, esta abordagem nos revela um modo de pensar, ao qual chamaremos de “**row picture**”: estamos olhando para as linhas do sistema linear. Em uma representação geométrica, esta abordagem se preocupa com o que as equações representam geometricamente (neste caso, duas retas em $\mathbb{R}^2$ que se interceptam em um único ponto).

Por outro lado, existem uma abordagem mais interessante à qual chamaremos de “**column picture**”, na qual olharemos para o sistema linear como uma combinação linear de vetores-coluna. No entanto, nós ainda não introduzimos os conceitos de “vetor” e de “combinação linear”. Nós o faremos agora de uma maneira provisória (pois, de fato, uma definição formal de vetor só poderá ser dada quando introduzirmos o conceito de espaço vetorial).

Definição 1.1.2 (Definição provisória de vetor). *Um **vetor** pode ser visto como uma lista de números sobre os quais podemos fazer duas operações: soma e multiplicação por escalar.*

Alguns exemplos de vetores são:

$$\begin{bmatrix} 3 \\ 2 \\ 4 \end{bmatrix}, \begin{bmatrix} 0 \\ -1 \end{bmatrix}, \begin{bmatrix} 10 \\ 5 \\ -6 \\ 7 \end{bmatrix}.$$

Quando nós representamos os vetores como acima, tais vetores são chamados de **vetores-coluna**. De igual modo, se representarmos um vetor em uma linha (por exemplo, $[2 \ 10 \ -5 \ 11 \ 3]$), nós o chamaremos de **vetor-linha**. Na maior parte do tempo, nós

consideraremos que um vetor v é um vetor-coluna (e que v^T é um vetor-linha, mas não se preocupem com esta notação agora, no momento certo nós a introduziremos).

Pensemos em dois vetores x e y em $\mathbb{R}^3$, definidos por $x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$ e $y = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$. Seja ainda $\alpha \in \mathbb{R}$ um escalar. Então, nós definimos a soma $x + y$ por:

$$x + y = \begin{bmatrix} x_1 + y_1 \\ x_2 + y_2 \\ x_3 + y_3 \end{bmatrix}$$

e a multiplicação por escalar por:

$$\alpha x = \begin{bmatrix} \alpha x_1 \\ \alpha x_2 \\ \alpha x_3 \end{bmatrix}.$$

Exemplo 1.1.3. Sejam $u = \begin{bmatrix} 3 \\ 1 \end{bmatrix}$ e $v = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$. Então, $u, v, u + v, u - v, -u, -v, 2u$ são conforme indicado na figura a seguir:




Figura 1.2: Operações entre vetores (arquivo pessoal)

Por sua vez, tendo definido provisoriamente o conceito de vetor, vamos fazer uma definição para o conceito de combinação linear:

Definição 1.1.4 (Combinação linear). Sejam $v_1, v_2, \dots, v_n$ vetores em um mesmo espaço, e $\alpha_1, \alpha_2, \dots, \alpha_n$ escalares em $\mathbb{R}$. Uma **combinação linear** destes vetores é definida como qualquer vetor v tal que

$$v = \alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n.$$

Para ilustrar este conceito como um exemplo, nós podemos voltar ao sistema linear que nós vimos no começo do capítulo. Recordando, nós estamos trabalhando com o sistema

$$\begin{cases} x + 2y = 0 \\ 2x - y = 5 \end{cases}.$$

Ao invés de olhar para o sistema por uma abordagem em linha, nós podemos analisar este sistema como uma combinação linear dos vetores-coluna de coeficientes, que produz um novo vetor-coluna. Isto deve ter parecido confuso em palavras, então vamos ilustrar:

Sabemos que x e y são escalares, que ainda não sabemos quem são. Por outro lado, na primeira equação, x é multiplicado por 1, e na segunda equação, x é multiplicado por 2. Como vimos acima, isso pode ser representado por multiplicação do escalar x pelo vetor $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$. Usando um raciocínio semelhante para y , nós obtemos a multiplicação do escalar y

pelo vetor $\begin{bmatrix} 2 \\ -1 \end{bmatrix}$. Olhando para o lado direito da equação, o vetor $\begin{bmatrix} 0 \\ 5 \end{bmatrix}$ pode ser escrito

como uma combinação linear dos vetores $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e $\begin{bmatrix} 2 \\ -1 \end{bmatrix}$.

Em termos matemáticos, isso é representado pela seguinte equação:

$$x \begin{bmatrix} 1 \\ 2 \end{bmatrix} + y \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 5 \end{bmatrix}.$$

Esta é exatamente a abordagem “column picture” do sistema linear: ele pode ser visto como uma combinação linear de vetores-coluna. E, de fato, esta abordagem é mais fácil de enxergar do que a abordagem “row picture”, pois não é geometricamente fácil olhar para um plano em $\mathbb{R}^6$, ou para uma reta em $\mathbb{R}^{729}$.

1.2 Representação Matricial de Sistemas Lineares

Por sua vez, há uma outra forma ainda (e a mais importante) de se representar um sistema linear qualquer. Para fazer isso, nós introduziremos o conceito de matriz:

Definição 1.2.1 (Matriz). Uma **matriz** é um conjunto de números organizado de forma retangular, ou seja, uma matriz A é tal que:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

Nós chamamos de a_{ij} ao elemento que está na linha i e na coluna j da matriz. Se $m = n$, a matriz A é dita **quadrada**.

Voltemos para o sistema linear com o qual estávamos trabalhando. Primeiramente, nós tínhamos entendido o sistema como elementos geométricos em $\mathbb{R}^2$ (row picture). Em seguida, nós entendemos o sistema como uma combinação linear de vetores-coluna (column picture). Agora, nós queremos dar um passo além e entender o sistema como a multiplicação de uma matriz por um vetor. Ou seja, queremos poder dizer que:

$$\begin{bmatrix} 1 & 2 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 5 \end{bmatrix}.$$

Não só isto é perfeitamente possível, como também esta é a forma como trabalharemos em muitos casos ao longo do curso (mas, de igual modo, o conceito de combinação linear será muito importante, como ainda veremos). Para realizar esta multiplicação, nós podemos pensar de duas formas: pelas linhas ou pelas colunas da matriz.

Se nós temos uma matriz $A = \begin{bmatrix} \text{linha } 1 \\ \text{linha } 2 \\ \vdots \\ \text{linha } m \end{bmatrix}$ e um vetor x , podemos pensar que $Ax = \begin{bmatrix} \text{linha } 1 \cdot x \\ \text{linha } 2 \cdot x \\ \vdots \\ \text{linha } m \cdot x \end{bmatrix}$, onde $\cdot$ indica uma operação entre vetores que definiremos em breve: o produto interno euclidiano.

Por outro lado, se ao invés de olharmos para as linhas de A , nós olharmos para as suas colunas, se nós definimos $A = [\text{coluna } 1 \quad \text{coluna } 2 \quad \cdots \quad \text{coluna } n]$, e $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$, nós

temos que $Ax = x_1[\text{coluna } 1] + x_2[\text{coluna } 2] + \dots + x_n[\text{coluna } n]$. Ou seja, nós temos duas informações: Ax é um vetor, e Ax pode ser escrito como a combinação linear das colunas de A .

Olhemos novamente para o sistema linear que estávamos estudando: vamos fazer a operação que desejávamos obter para concluir que esta representação equivale ao sistema linear que nós tínhamos antes:

$$\begin{bmatrix} 1 & 2 \\ 2 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = x \begin{bmatrix} 1 \\ 2 \end{bmatrix} + y \begin{bmatrix} 2 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 5 \end{bmatrix}.$$

Nós podemos estender o mesmo raciocínio para qualquer sistema linear de m equações e n incógnitas e concluir que, se A é a matriz dos coeficientes do sistema, x é o vetor das incógnitas e b é o vetor dos termos independentes, todo sistema linear pode ser escrito como

$$\boxed{Ax = b}$$

Algo importante a se notar é que, para todas as operações que nós vamos desenvolver, as dimensões das matrizes e dos vetores devem estar corretas. No caso da multiplicação de uma matriz por um vetor, por exemplo, se A é uma matriz com m linhas e n colunas (denotamos por $m \times n$), x deve ser um vetor $n \times 1$, e a saída b será um vetor $m \times 1$. Igualmente, somas de vetores só fazem sentido se as dimensões dos vetores somados forem iguais.

1.3 Classificação de Sistemas Lineares

Como é possível imaginar, nem sempre um sistema linear possuirá uma única solução. É possível que o sistema não possua nenhuma solução, e também é possível que o sistema possua infinitas soluções. Assim sendo, nós podemos classificar um sistema linear quanto à quantidade de soluções que ele possui:

- **Sistema Possível e Determinado (SPD):** possui uma única solução;
- **Sistema Possível e Indeterminado (SPI):** possui infinitas soluções;

- **Sistema Impossível (SI):** não possui nenhuma solução.

Vejamos alguns exemplos:

Exemplo 1.3.1 (SPD).

$$\begin{cases} x + 2y = 0 \\ 2x - y = 5 \end{cases}$$

Exemplo 1.3.2 (SPI).

$$\begin{cases} x + 2y = 4 \\ 2x + 4y = 8 \end{cases}$$

Exemplo 1.3.3 (SI).

$$\begin{cases} x + 2y = 4 \\ 2x + 4y = 7 \end{cases}$$

Como sugestão pessoal, pensem no significado geométrico destes três casos quando estamos lidando com sistemas lineares 2×2 .

1.4 Produto Interno Euclidiano

Nós vamos agora definir uma importante operação entre vetores: o produto interno euclidiano. É importante saber que o produto interno euclidiano é apenas **um** produto interno. No entanto, nós não definiremos formalmente o conceito de produto interno agora porque tal definição dependerá do conceito de espaço vetorial. Dito isso, vamos à definição:

Definição 1.4.1 (Produto Interno Euclidiano). *Sejam x e y dois vetores em $\mathbb{R}^n$. O **produto interno euclidiano** é definido como:*

$$x \cdot y = \sum_{i=1}^n x_i y_i = x_1 y_1 + x_2 y_2 + \cdots + x_n y_n.$$

Duas propriedades importantes do produto interno euclidiano são a simetria ($x \cdot y = y \cdot x$) e a linearidade no primeiro argumento ($(\alpha x + \beta z) \cdot y = \alpha(x \cdot y) + \beta(z \cdot y)$, para escalares α, β).

Assim, como nós definimos o produto interno euclidiano, nós podemos definir a norma euclidiana. De maneira equivalente, a norma euclidiana é apenas **uma** norma. Porém, é a que nós utilizaremos neste curso. No momento oportuno, nós faremos a definição geral de produto interno e de norma.

Definição 1.4.2 (Norma Euclidiana). *Seja x um vetor em $\mathbb{R}^n$. A **norma euclidiana** de x é definida como*

$$\|x\| = \sqrt{x \cdot x} = \sqrt{\sum_{i=1}^n x_i^2}.$$

A partir do conceito de norma euclidiana, definiremos o conceito de vetor unitário:

Definição 1.4.3 (Vetor Unitário). *Seja $x \in \mathbb{R}^n$. Dizemos que x é um **vetor unitário** se $\|x\| = 1$.*

Uma propriedade interessante é o fato de que, se um vetor qualquer é diferente de zero, ele pode ser transformado em unitário.

Proposição 1.4.4. *Seja x um vetor em $\mathbb{R}^n$ tal que $x \neq 0$. Então, $\frac{x}{\|x\|}$ é um vetor unitário.*

Demonstração. *Seja αx um vetor qualquer. Note que $\|\alpha x\| = |\alpha|\|x\|$. Assim sendo, tome $\alpha = \frac{1}{\|x\|}$. Nós temos que $\left\|\frac{x}{\|x\|}\right\| = \left|\frac{1}{\|x\|}\right|\|x\| = \frac{1}{\|x\|}\|x\| = 1$.*

□

Vamos agora desenvolver uma ideia que nós levará a uma propriedade interessante: suponha que nós temos dois vetores x e y unitários tais que o ângulo de cada um com relação a um certo eixo é α e β , respectivamente. Especificamente, definimos x e y como $x = \begin{bmatrix} \cos(\alpha) \\ \sin(\alpha) \end{bmatrix}$ e $y = \begin{bmatrix} \cos(\beta) \\ \sin(\beta) \end{bmatrix}$.

Seja θ o ângulo entre x e y . Pela forma como foram definidos α e β , nós temos que $\theta = \beta - \alpha$. Então, calculando $x \cdot y$, nós temos que:

$$x \cdot y = \cos(\alpha) \cos(\beta) + \sin(\alpha) \sin(\beta) = \cos(\beta - \alpha) = \cos(\theta).$$




Figura 1.3: visualização do produto interno dos vetores acima (arquivo pessoal)

Como todo vetor diferente do vetor zero pode ser transformado em um vetor unitário, nós obtemos a seguinte conclusão:

Proposição 1.4.5. *Sejam x e y dois vetores quaisquer diferentes de zero. Então,*

$$x \cdot y = \|x\| \|y\| \cos(\theta),$$

onde θ é o ângulo entre x e y .

Demonstração. *Sabemos, do desenvolvimento anterior, que $\frac{x}{\|x\|} \cdot \frac{y}{\|y\|} = \cos(\theta)$. Então, segue naturalmente que $x \cdot y = \|x\| \|y\| \cos(\theta)$.*

□

1.5 Desigualdades envolvendo o Produto Interno Euclidiano

Nesta seção, nós enunciaremos e demonstraremos duas importantes desigualdades que envolvem o produto interno euclidiano. A primeira delas é a Desigualdade de Cauchy-Schwarz, e a segunda é a Desigualdade Triangular.

Proposição 1.5.1 (Desigualdade de Cauchy-Schwarz). *Sejam x e y dois vetores em $\mathbb{R}^n$. Então,*

$$|x \cdot y| \leq \|x\| \|y\|.$$

Demonstração. *Se $y = 0$, a igualdade $|x \cdot y| = 0 = \|x\| \|y\|$ vale trivialmente. Suponha $y \neq 0$.*

(Note que, embora a proposição anterior forneça uma interpretação geométrica via ângulo, a demonstração a seguir é puramente algébrica para evitar circularidade na definição de ângulo em $\mathbb{R}^n$).

Seja $\lambda \in \mathbb{R}$ um escalar qualquer. Então, sabemos que $0 \leq \|x - \lambda y\|^2$ (pela definição de norma euclidiana). Por sua vez, nós temos que:

$$\|x - \lambda y\|^2 = (x - \lambda y) \cdot (x - \lambda y) = \|x\|^2 - 2\lambda(x \cdot y) + \lambda^2 \|y\|^2.$$

Como esta fórmula vale para qualquer λ , vamos escolher um λ apropriado. Defina $\lambda = \frac{x \cdot y}{\|y\|^2}$ (com $y \neq 0$). Então, segue que:

$$0 \leq \|x - \lambda y\|^2 = \|x\|^2 - 2 \frac{x \cdot y}{\|y\|^2} (x \cdot y) + \frac{(x \cdot y)^2}{\|y\|^4} \|y\|^2 = \|x\|^2 - \frac{(x \cdot y)^2}{\|y\|^2}.$$

Multiplicando os dois lados da equação por $\|y\|^2$, nós obtemos:

$$0 \leq \|x\|^2 \|y\|^2 - (x \cdot y)^2 \implies (x \cdot y)^2 \leq \|x\|^2 \|y\|^2 \implies |x \cdot y| \leq \|x\| \|y\|.$$

□

Proposição 1.5.2. *Sejam x e y dois vetores em $\mathbb{R}^n$. Então:*

$$\|x + y\| \leq \|x\| + \|y\|.$$

Demonstração. *Considere $\|x + y\|^2$. Nós temos que:*

$$\|x + y\|^2 = (x + y) \cdot (x + y) = \|x\|^2 + 2(x \cdot y) + \|y\|^2.$$

Pela Desigualdade de Cauchy-Schwarz, nós temos que esta expressão é menor ou igual a $\|x\|^2 + 2\|x\| \|y\| + \|y\|^2 = (\|x\| + \|y\|)^2$. Assim sendo, nós temos que:

$$\|x + y\|^2 \leq (\|x\| + \|y\|)^2 \implies \|x + y\| \leq \|x\| + \|y\|.$$

□

1.6 Exercícios

Importante: a maioria dos exercícios são baseados em (2).

1.1) Resolva (se possível) o seguinte sistema linear:

$$\begin{cases} 5x + 7y = 10 \\ 3x - 4y = 5 \end{cases}$$

e determine a sua classificação. Esboce as duas retas para concluir geometricamente que a sua resposta está de fato correta.

1.2) Descreva a representação do sistema a seguir de três formas: row picture, column picture e multiplicação de uma matriz por um vetor:

$$\begin{cases} 3x + 2y = 3 \\ 4x - 5y = 6 \end{cases}$$

1.3) Considere o sistema linear

$$\begin{cases} x + 2y = 7 \\ -2x - 4y = -14 \end{cases}$$

Este sistema é possível? Se sim, quantas soluções ele possui? E se substituirmos os dois elementos do lado direito por 1? E por 0?

1.4) Considere $x = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ e $y = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$. Ache uma combinação linear destes vetores que resulte em $\begin{bmatrix} 3 \\ 6 \end{bmatrix}$.

1.5) Determine a reta de interseção dos três planos $t = x + y$, $z = 1 - x$ e $x + y + z + 2t = 0$ em um espaço quadridimensional. Determine ainda três pontos que estão sobre esta reta.

1.6) Multiplique $\begin{bmatrix} 2 & 1 & -3 \\ 0 & 1 & 2 \\ 4 & 0 & 12 \end{bmatrix} \begin{bmatrix} 4 \\ -5 \\ 0 \end{bmatrix}$. Em seguida, multiplique a mesma matriz pelo vetor resultante se for possível.

1.7) Sejam $x = \begin{bmatrix} 3 \\ -1 \\ 4 \\ 5 \end{bmatrix}$ e $y = \begin{bmatrix} 2 \\ 3 \\ -1 \\ 0 \end{bmatrix}$. Calcule $x \cdot y$, $\|x\|$ e $\|y\|$.

1.8) Sejam v e w vetores tais que $\|v\| = 8$ e $\|w\| = 2$. Determine o menor e o maior valores possíveis para $\|v - w\|$ e $v \cdot w$.

1.9) (Desafio!) Mostre que um sistema linear qualquer possui, necessariamente, nenhuma solução, uma solução ou infinitas soluções.

Capítulo 2

Eliminação Gaussiana

Importante: este capítulo é baseado em (3).

No capítulo anterior, nós entendemos a interpretação geométrica de um sistema linear, e vimos que todo sistema linear pode ser escrito como uma equação matricial $Ax = b$. Agora, nós estamos interessados em encontrar um algoritmo que seja capaz de resolver qualquer sistema linear PD, independentemente do seu tamanho.

2.1 Ideia da Eliminação

Para descrevermos o processo de eliminação, primeiramente nós vamos definir o que é um pivô. Para motivar este conceito, vamos introduzir qual é a ideia da eliminação. Suponha que nós temos um sistema linear

$$\begin{cases} 2x + y = 8 \\ 6x - y = 16 \end{cases}$$

Olhando geometricamente para este sistema, nós temos a seguinte situação:




Figura 2.1: sistema linear antes da eliminação (arquivo pessoal)

Suponha agora que nós fazemos uma operação nas linhas do sistema: subtraímos 3 vezes a linha 1 da linha 2. Ou seja:

$$\begin{cases} 2x + y = 8 \\ 6x - y = 16 \end{cases} \xrightarrow{L_2 - 3L_1} \begin{cases} 2x + y = 8 \\ -4y = -8 \end{cases}$$

Segue que $y = 2$ e $x = 3$ no segundo sistema. Porém, veja o que acontece geometricamente quando fazemos esta operação:




Figura 2.2: sistema linear depois da eliminação (arquivo pessoal)

Como podemos perceber, a solução do segundo sistema linear é também a solução do primeiro sistema. Então, se nós tivermos um sistema linear PD mais complexo, a ideia é que nós podemos resolvê-lo facilmente apenas utilizando subtrações, multiplicações e (como nós veremos) trocas de linha.

No entanto, como nós vimos no primeiro capítulo, nem todo sistema linear é possível e determinado. Alguns sistemas não possuem nenhuma solução, e outros sistemas possuem infinitas soluções. Vamos ver o que acontece no caso 2×2 quando aplicamos a eliminação nesses tipos de sistemas.

Exemplo 2.1.1. *Considere o sistema linear*

$$\begin{cases} 2x + y = 3 \\ 4x + 2y = 7 \end{cases}$$

Este sistema, como se pode perceber facilmente, não possui nenhuma solução. Se fizermos $L_2 - 2L_1$, nós obtemos:

$$\begin{cases} 2x + y = 3 \\ 0x + 0y = 1 \end{cases}$$

Ou seja, nós zeramos o lado esquerdo da segunda equação, mas obtivemos $0 = 1$, o que é um absurdo. Isso justifica o fato de o sistema não possuir nenhuma solução.

Exemplo 2.1.2. *Considere o sistema linear*

$$\begin{cases} 2x + y = 3 \\ 4x + 2y = 6 \end{cases}$$

Também é fácil observar o que acontece com este sistema: como a segunda linha é múltipla da primeira, qualquer ponto que satisfaça à primeira equação satisfará também a segunda, logo, este sistema possui infinitas soluções. Se fizermos $L_2 - 2L_1$, nós obteremos:

$$\begin{cases} 2x + y = 3 \\ 0x + 0y = 0 \end{cases}$$

Ou seja, nós zeramos a linha 2 inteira, obtendo $0 = 0$. Isso justifica o fato de o sistema possuir infinitas soluções.

Em ambos os casos, quando o sistema é impossível, e quando o sistema é possível e indeterminado, a eliminação produz uma linha inteira de zeros no lado esquerdo da equação. Por outro lado, quando o sistema é possível e determinado, isso não acontece. Então, a partir deste fato, nós podemos definir o conceito de pivô:

Definição 2.1.3 (Pivô). Nós chamamos de **pivô** ao primeiro elemento não-nulo de uma linha usado para eliminação.

É importante notar que os pivôs não são considerados em relação ao estado inicial do sistema, mas em relação ao seu estado final. Isso quer dizer que, a cada passo da eliminação, nós obtemos um novo pivô (se o sistema for possível e determinado).

Por exemplo, no primeiro sistema de equações deste capítulo ($2x + y = 8, 6x - y = 16$), os pivôs são 2 e -4 . Já nos dois sistemas seguintes (o sistema sem solução e o sistema com infinitas soluções acima), o único pivô é 2. Isso nos leva a uma consequência importante: se um sistema de n equações e n variáveis possui menos de n pivôs, ou ele não possui solução, ou ele possui infinitas soluções. Por outro lado, se ele possui n pivôs, ele possui exatamente uma solução, mas pode ser necessário trocar linhas durante o processo de eliminação.

Uma pergunta importante é: “como nós definimos o fator de multiplicação durante o processo de eliminação?”. Como, por exemplo, eu pude falar no primeiro sistema do capítulo que faríamos “ $L_2 - 3L_1$ ”? De fato, a cada passo da eliminação, o que nós queremos produzir zeros imediatamente abaixo do pivô, de modo que, ao final, a última linha fique com apenas 1 termo diferente de zero, a penúltima fique com 2 termos diferentes de zero, e assim sucessivamente até a primeira linha, que permanece inalterada.

Para fazer isso, nós podemos definir o multiplicador como abaixo:

Definição 2.1.4 (Multiplicador). Nós definimos o **multiplicador** como:

$$\text{multiplicador} = \frac{\text{elemento a ser eliminado}}{\text{pivô}}.$$

Antes de fazermos uma descrição mais detalhada do processo de eliminação, vamos definir dois conceitos que serão importantes em breve: os conceitos de matriz triangular superior e matriz triangular inferior.

Definição 2.1.5 (Matriz triangular superior). Seja U uma matriz quadrada $n \times n$ tal que $u_{ij} = 0$ quando $i > j$ (ou seja, todas as entradas abaixo da diagonal principal são iguais a zero). Então, U é dita uma matriz **triangular superior**.

Definição 2.1.6 (Matriz triangular inferior). Seja L uma matriz quadrada $n \times n$ tal que $l_{ij} = 0$ quando $i < j$ (ou seja, todas as entradas acima da diagonal principal são iguais a zero). Então, L é dita uma matriz **triangular inferior**.

2.2 Eliminação

Agora, estamos prontos para descrever mais detalhadamente o processo de eliminação. A ideia central é simples: a partir de um sistema $Ax = b$, nós queremos aplicar operações elementares nas linhas de modo a obter um sistema triangular $Ux = c$, onde U é uma matriz triangular superior. Em seguida, nós usamos o novo sistema para encontrar as coordenadas de x , por meio do processo de substituição.

Para cada parte do processo de eliminação nós damos um nome: transformar $Ax = b$ em $Ux = c$ é um processo chamado de **escalonamento**, e encontrar a solução do sistema original a partir do sistema triangular superior é um processo chamado de **retrossubstituição**.

- **Escalonamento:** Nós partimos de um sistema $Ax = b$. Aplicamos subtrações, multiplicações e trocas de linha à matriz A e ao vetor b . Ao final do processo, obtemos uma matriz U triangular superior e um novo vetor c , ficando com o sistema $Ux = c$.
- **Retrossubstituição:** A partir do sistema $Ux = c$, nós encontramos os valores das coordenadas de x , começando da última linha até chegar à primeira.

Exemplo 2.2.1. Resolva o sistema linear $Ax = b$, onde $A = \begin{bmatrix} 2 & 4 & -1 \\ 4 & 5 & 7 \\ 8 & -2 & 6 \end{bmatrix}$, $x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$ e $b = \begin{bmatrix} 3 \\ 1 \\ 2 \end{bmatrix}$.

Resolução: Em primeiro lugar, vamos escalonar a matriz A , aplicando as mesmas operações ao vetor b . Nós temos que 2 é o primeiro pivô do sistema, e queremos eliminar o elemento a_{21} , que é 4. Então, o nosso primeiro multiplicador é dado por $\frac{4}{2} = 2$. Faremos, então, $L_2 - 2L_1$ em A e em b . Nós obtemos:

$$\begin{bmatrix} 2 & 4 & -1 \\ 4 & 5 & 7 \\ 8 & -2 & 6 \end{bmatrix} \xrightarrow{L_2 - 2L_1} \begin{bmatrix} 2 & 4 & -1 \\ 0 & -3 & 9 \\ 8 & -2 & 6 \end{bmatrix}$$

$$\begin{bmatrix} 3 \\ 1 \\ 2 \end{bmatrix} \xrightarrow{L_2 - 2L_1} \begin{bmatrix} 3 \\ -5 \\ 2 \end{bmatrix}$$

Agora, nós queremos eliminar o elemento a_{31} , que é 8 (lembre-se que, dado um pivô, nós queremos zerar todos os elementos que estão abaixo dele). Como o pivô atual continua sendo 2, nós temos que o segundo multiplicador é dado por $\frac{8}{2} = 4$. Assim sendo, nós faremos $L_3 - 4L_1$:

$$\begin{bmatrix} 2 & 4 & -1 \\ 0 & -3 & 9 \\ 8 & -2 & 6 \end{bmatrix} \xrightarrow{L_3 - 4L_1} \begin{bmatrix} 2 & 4 & -1 \\ 0 & -3 & 9 \\ 0 & -18 & 10 \end{bmatrix}$$

$$\begin{bmatrix} 3 \\ -5 \\ 2 \end{bmatrix} \xrightarrow{L_3 - 4L_1} \begin{bmatrix} 3 \\ -5 \\ -10 \end{bmatrix}$$

Já eliminamos todos os elementos abaixo do primeiro pivô, então vamos procurar um pivô na segunda linha. O primeiro elemento diferente de zero é -3 , logo ele será o nosso pivô atual. Queremos, neste passo, eliminar todos os elementos abaixo do pivô. No caso, só há um elemento a ser eliminado, que é o elemento na posição a_{32} , correspondente ao -18 . Assim sendo, o nosso multiplicador será $\frac{-18}{-3} = 6$, e, deste modo, faremos $L_3 - 6L_2$:

$$\begin{bmatrix} 2 & 4 & -1 \\ 0 & -3 & 9 \\ 0 & -18 & 10 \end{bmatrix} \xrightarrow{L_3 - 6L_2} \begin{bmatrix} 2 & 4 & -1 \\ 0 & -3 & 9 \\ 0 & 0 & -35 \end{bmatrix}$$

$$\begin{bmatrix} 3 \\ -5 \\ -10 \end{bmatrix} \xrightarrow{L_3 - 6L_2} \begin{bmatrix} 3 \\ -5 \\ 20 \end{bmatrix}$$

Nós ficamos agora com um sistema triangular superior $Ux = c$, que é explicitamente:

$$\begin{bmatrix} 2 & 4 & -1 \\ 0 & -3 & 9 \\ 0 & 0 & -35 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 3 \\ -5 \\ 20 \end{bmatrix}$$

Estamos prontos para fazer a retrossubstituição, que é feita da última linha para a primeira:

$$-35x_3 = 20 \implies x_3 = -\frac{20}{35} \implies x_3 = -\frac{4}{7}.$$

$$-3x_2 + 9x_3 = -3x_2 - 9 \cdot \frac{4}{7} = -5 \implies -3x_2 = \frac{1}{7} \implies x_2 = -\frac{1}{21}.$$

$$\begin{aligned} 2x_1 + 4x_2 - x_3 &= 2x_1 - 4 \cdot \frac{1}{21} + \frac{4}{7} = 3 \implies 2x_1 - \frac{4}{21} + \frac{12}{21} = 3 \implies 2x_1 + \frac{8}{21} = \frac{63}{21} \\ &\implies 2x_1 = \frac{55}{21} \implies x_1 = \frac{55}{42}. \end{aligned}$$

$$\text{Deste modo, a solução do sistema } Ax = b \text{ é } x = \begin{bmatrix} \frac{55}{42} \\ -\frac{1}{21} \\ -\frac{4}{7} \end{bmatrix} = \frac{1}{42} \begin{bmatrix} 55 \\ -2 \\ -24 \end{bmatrix}.$$

□

Por sua vez, nós não precisamos, a cada passo do escalonamento, aplicar as operações separadamente em A e em b : podemos considerar a matriz aumentada

$$[A \quad b] = \left[\begin{array}{ccc|c|c} | & | & & | & | \\ a_1 & a_2 & \cdots & a_n & b \\ | & | & & | & | \end{array} \right]$$

e, desta forma, aplicar todas as operações simultaneamente em A e em b .

Um fato interessante que nós não demonstraremos aqui, e que não será muito importante por agora, mas que no futuro o será, tem a ver com o número de operações que o processo de eliminação faz.

Teorema 2.2.2. *Seja $Ax = b$ um sistema linear sendo A uma matriz quadrada $n \times n$. Então, o processo de escalonamento possui complexidade temporal $O(n^3)$ e o processo de retrossubstituição possui complexidade temporal $O(n^2)$.*

Este resultado é melhor explicado em (4).

2.3 Multiplicação de Matrizes

No capítulo anterior, nós aprendemos a multiplicar uma matriz por um vetor. Agora, nós estamos interessados em estender aquele conceito de modo a conseguirmos multiplicar uma matriz por outra matriz.

Recordando o que nós fizemos anteriormente, sejam A uma matriz $m \times n$ e x um vetor $n \times 1$. Há duas formas de realizar esta multiplicação: a primeira consiste em multiplicar cada linha de A por x . A segunda consiste em enxergar Ax como uma combinação linear das colunas de A , multiplicando cada coordenada de x pela respectiva coluna de A , e somando os vetores resultantes das multiplicações.

Olhando para esta segunda forma, se $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$ e $A = \begin{bmatrix} | & | & \cdots & | \\ a_1 & a_2 & \cdots & a_n \\ | & | & \cdots & | \end{bmatrix}$, onde cada a_i

representa o i -ésimo vetor-coluna de A , então podemos escrever matematicamente

$$Ax = x_1 a_1 + x_2 a_2 + \cdots + x_n a_n,$$

onde Ax é um vetor $m \times 1$.

Suponha então que nós temos uma matriz $A_{m \times n}$ e uma matriz $B_{n \times p}$. Nós podemos enxergar a multiplicação AB como a multiplicação de A por cada coluna de B . E isso nós já sabemos fazer. Considere b_j como a j -ésima coluna da matriz B . Definamos b_j como

$$b_j = \begin{bmatrix} b_{1j} \\ b_{2j} \\ \vdots \\ b_{nj} \end{bmatrix}$$

Então,

$$Ab_j = b_{1j} a_1 + b_{2j} a_2 + \cdots + b_{nj} a_n,$$

e podemos definir a multiplicação AB como uma nova matriz $C_{m \times p}$ tal que:

$$C = AB = A \begin{bmatrix} | & | & \cdots & | \\ b_1 & b_2 & \cdots & b_p \\ | & | & \cdots & | \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ Ab_1 & Ab_2 & \cdots & Ab_p \\ | & | & \cdots & | \end{bmatrix}.$$

Algo importantíssimo deve ser dito neste momento: para que a multiplicação AB faça sentido, o número de colunas de A necessariamente precisa ser igual ao número de linhas de B . Como nós veremos futuramente, uma matriz é uma forma de representar uma transformação linear, ou seja, uma matriz é uma função. Se A é uma matriz $m \times n$, então a sua representação como uma função é $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$, e se B é uma matriz $n \times p$, então a sua representação como uma função é $B : \mathbb{R}^p \rightarrow \mathbb{R}^n$. Na prática, multiplicar duas matrizes é realizar uma composição de funções e, por isso, as dimensões devem estar corretas.

Com a definição que nós demos para a multiplicação AB , nós chegamos à fórmula que sempre usaremos quando fizermos multiplicação matricial.

Teorema 2.3.1. *Sejam A uma matriz $m \times n$ e B uma matriz $n \times p$. Então, o elemento c_{ij} da matriz $C = AB$ pode ser calculado como*

$$c_{ij} = \sum_{k=1}^n a_{ik}b_{kj} = (\text{linha } i \text{ de } A) \cdot (\text{coluna } j \text{ de } B).$$

Demonstração. *Por definição,*

$$\begin{aligned} c_{ij} &= (Ab_j)_i = (b_{1j}a_1 + b_{2j}a_2 + \cdots + b_{nj}a_n)_i \\ &= \begin{bmatrix} (\text{linha } 1 \text{ de } A) \cdot b_j \\ (\text{linha } 2 \text{ de } A) \cdot b_j \\ \vdots \\ (\text{linha } m \text{ de } A) \cdot b_j \end{bmatrix}_i = (\text{linha } i \text{ de } A) \cdot b_j = \sum_{k=1}^n a_{ik}b_{kj}. \end{aligned}$$

□

Um ponto importante na interpretação da multiplicação de matrizes é o fato de que, dadas duas matrizes $A_{m \times n}$ e $B_{n \times p}$, assim como nós podemos ver a coluna j de AB como $A(\text{coluna } j \text{ de } B)$, nós podemos enxergar a linha i de AB como $(\text{linha } i \text{ de } A)B$ (esta operação faz sentido porque as linhas de A são vetores $1 \times n$). Ou seja, enquanto as colunas de AB são combinações lineares das colunas de A , as linhas de AB são combinações lineares das linhas de B .

Nós temos alguns casos específicos e mais importantes da multiplicação de matrizes:

- Se A é uma matriz $1 \times n$ e B é uma matriz $n \times 1$, então AB é o produto interno euclidiano, que definimos anteriormente.
- Se A é uma matriz $m \times 1$ e B é uma matriz $1 \times p$, então todas as colunas de AB são múltiplas das colunas de A , e todas as linhas de AB são múltiplas das linhas de B . Nós chamamos esta operação de **produto externo**, e a matriz AB é dita uma **matriz de posto 1**.

2.4 Propriedades da Multiplicação de Matrizes

Vamos agora enunciar e demonstrar algumas propriedades da multiplicação de matrizes.

Proposição 2.4.1 (Não-comutatividade). *Sejam A e B duas matrizes $n \times n$. Então, em geral, $AB \neq BA$.*

Demonstração. *Existem inúmeros exemplos deste fato. Para mostrar um, suponha*

$$A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \text{ e } B = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}.$$

Então:

$$AB = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix}$$

$$BA = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix}.$$

Assim, $AB \neq BA$.

□

Proposição 2.4.2 (Distributividade à Esquerda). *Sejam A e B duas matrizes $m \times n$ e C uma matriz $p \times m$. Então, $C(A+B) = CA + CB$.*

Demonstração. *Vamos calcular $C(A+B)$. Por definição, $(A+B)_{ij} = a_{ij} + b_{ij}$. Assim sendo, nós temos que:*

$$[C(A+B)]_{ij} = \sum_{k=1}^m c_{ik}(a_{kj} + b_{kj}) = \sum_{k=1}^m (c_{ik}a_{kj} + c_{ik}b_{kj}) = \sum_{k=1}^m c_{ik}a_{kj} + \sum_{k=1}^m c_{ik}b_{kj} = (CA + CB)_{ij}.$$

Logo, $C(A+B) = CA + CB$, como queríamos provar.

□

Proposição 2.4.3. (Distributividade à Direita) *Sejam A e B duas matrizes $m \times n$, e C uma matriz $n \times p$. Então, $(A+B)C = AC + BC$.*

Demonstração. *Vamos calcular $(A+B)C$. Por definição, $(A+B)_{ij} = a_{ij} + b_{ij}$. Assim sendo, nós temos que:*

$$[(A+B)C]_{ij} = \sum_{k=1}^n (a_{ik} + b_{ik})c_{kj} = \sum_{k=1}^n (a_{ik}c_{kj} + b_{ik}c_{kj}) = \sum_{k=1}^n a_{ik}c_{kj} + \sum_{k=1}^n b_{ik}c_{kj} = (AC + BC)_{ij}.$$

Logo, $(A+B)C = AC + BC$, como queríamos provar.

□

Proposição 2.4.4 (Associatividade da Adição). *Sejam A , B e C três matrizes $n \times n$. Então, $(A+B) + C = A + (B+C)$.*

Demonstração. *Nós temos que:*

$$[(A+B) + C]_{ij} = (a_{ij} + b_{ij}) + c_{ij} = a_{ij} + (b_{ij} + c_{ij}) = [A + (B+C)]_{ij}.$$

Logo, $(A+B) + C = A + (B+C)$.

□

Proposição 2.4.5 (Associatividade da Multiplicação). *Sejam $A_{l \times m}$, $B_{m \times n}$ e $C_{n \times p}$ três matrizes. Então, $A(BC) = (AB)C$.*

Demonstração. *Primeiramente, vamos calcular $[A(BC)]_{ij}$. Por definição, nós temos:*

$$[A(BC)]_{ij} = \sum_{k=1}^m a_{ik}(BC)_{kj} = \sum_{k=1}^m a_{ik} \sum_{l=1}^n b_{kl}c_{lj} = \sum_{k=1}^m \sum_{l=1}^n a_{ik}b_{kl}c_{lj}.$$

Agora, nós vamos calcular $[(AB)C]_{ij}$. Por definição, nós temos:

$$[(AB)C]_{ij} = \sum_{k=1}^n (AB)_{ik}c_{kj} = \sum_{k=1}^n \sum_{l=1}^m a_{il}b_{lk}c_{kj}.$$

Perceba que, trocando a ordem dos somatórios nesta expressão (o que é permitido, pois as somas são finitas), nós obtemos:

$$[(AB)C]_{ij} = \sum_{l=1}^m \sum_{k=1}^n a_{il} b_{lk} c_{kj} = \sum_{l=1}^m a_{il} (BC)_{lj},$$

que é exatamente a expressão correspondente a $[A(BC)]_{ij}$.

Logo, $A(BC) = (AB)C$, como queríamos demonstrar. □

Proposição 2.4.6 (Multiplicação de Matrizes Triangulares). *Sejam L_1 e L_2 duas matrizes $n \times n$ triangulares inferior. Então, $L_1 L_2$ também é uma matriz triangular inferior (o mesmo vale para matrizes triangulares superior).*

Demonstração. *Sejam L_1 e L_2 duas matrizes triangulares inferior. Vejamos o que acontece com o elemento ij da matriz $L_1 L_2$, quando $i < j$:*

$$(L_1 L_2)_{ij} = \sum_{k=1}^n (L_1)_{ik} (L_2)_{kj}.$$

Quando $k > i$, $(L_1)_{ik} = 0$. Quando $k \leq i$, como $i < j$, temos $k < j$ e portanto $(L_2)_{kj} = 0$. Logo, $(L_1 L_2)_{ij} = 0$ quando $i < j$. Assim sendo, segue que $L_1 L_2$ é uma matriz triangular inferior. Para demonstrar a propriedade das matrizes triangulares superior, basta usar o mesmo argumento com $i > j$. □

Por fim, vamos definir o conceito de potência de matrizes:

Definição 2.4.7 (Potências). *Seja A uma matriz $n \times n$. Então, definimos A^p como:*

$$A^p = \underbrace{AAA \cdots A}_{p \text{ vezes}}.$$

2.5 Eliminação com Matrizes

Como nós já sabemos multiplicar matrizes, a nossa intenção agora é descrever o processo de eliminação unicamente utilizando matrizes. De fato, nós já sabemos fazer eliminação em uma matriz: basta fazer subtrações de linhas, utilizando o multiplicador correto e, se necessário, fazer permutações (nós ainda não fizemos nenhum exemplo, mas o faremos em breve). No entanto, é mais interessante descrever todo este processo utilizando matrizes.

Primeiramente, vamos definir o conceito de matriz identidade:

Definição 2.5.1 (Matriz Identidade). *Seja I uma matriz quadrada $n \times n$ tal que:*

$$I_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}.$$

Então, I é denominada **matriz identidade**.

Esta matriz recebe este nome porque é o elemento neutro da multiplicação matricial. Uma propriedade interessante sobre a comutatividade da multiplicação matricial é a seguinte:

Teorema 2.5.2. *Sejam I a matriz identidade $n \times n$ e $c \in \mathbb{R}$ um escalar qualquer. Então, as matrizes da forma cI (incluindo a matriz I) são as únicas matrizes que comutam com todas as matrizes $n \times n$.*

Demonstração. *Seja A uma matriz $n \times n$ que comuta com todas as matrizes $n \times n$. Então, particularmente, A comuta com a matriz F_{ij} , definida como tendo entrada 1 na posição ij , e 0 em todas as outras posições. Ou seja, $AF_{ij} = F_{ij}A$.*

Vamos primeiro analisar o que acontece quando calculamos a posição ij das duas multiplicações:

$$(AF_{ij})_{ij} = \sum_{k=1}^n a_{ik}(F_{ij})_{kj} = a_{ii}(F_{ij})_{ij} = a_{ii} \cdot 1 = a_{ii}.$$

$$(F_{ij}A)_{ij} = \sum_{k=1}^n (F_{ij})_{ik}a_{kj} = (F_{ij})_{ij}a_{jj} = 1 \cdot a_{jj} = a_{jj}.$$

Pela comutatividade, $a_{ii} = a_{jj}$. Logo, todos os elementos da diagonal de A correspondem a uma constante.

Agora, vamos analisar o que acontece quando calculamos a posição il das duas multiplicações, onde $l \neq j$:

$$(AF_{ij})_{il} = \sum_{k=1}^n a_{ik}(F_{ij})_{kl}.$$

Como $l \neq j$ sempre, segue que todos os valores de $(F_{ij})_{kl}$ considerados no somatório acima serão iguais a zero, logo, $(AF_{ij})_{il} = 0$.

Por outro lado:

$$(F_{ij}A)_{il} = \sum_{k=1}^n (F_{ij})_{ik}a_{kl} = (F_{ij})_{ij}a_{jl} = 1 \cdot a_{jl} = a_{jl}.$$

Logo, $a_{jl} = 0$. Ou seja, todos os elementos fora da diagonal principal de A são iguais a 0.

Assim sendo, $A = cI$, como queríamos provar.

□

Vamos agora definir as matrizes elementares, que nós usaremos para descrever o processo de eliminação:

Definição 2.5.3 (Matriz Elementar). *Seja $E_{ij}(l)$ uma matriz $n \times n$ que subtrai l vezes a linha j da linha i . Chamamos esta matriz de **matriz elementar**, ou **matriz de eliminação**.*

A matriz elementar é basicamente a matriz identidade, porém com a entrada $-l$ na posição ij .

Exemplo 2.5.4. *Considere a matriz $E_{21}(l)$ de um sistema linear 3×3 . Então, nós temos que:*

$$E_{21}(l) = \begin{bmatrix} 1 & 0 & 0 \\ -l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Vamos ver um exemplo de como as matrizes elementares atuam na prática:

Exemplo 2.5.5. Considere a matriz $A = \begin{bmatrix} 1 & 0 & 2 \\ 3 & 4 & -5 \\ 4 & 4 & 7 \end{bmatrix}$. Queremos encontrar a matriz triangular superior U resultante do processo de escalonamento.

Em primeiro lugar, o nosso primeiro pivô é 1, e o multiplicador é 3. Assim sendo, faremos $L_2 - 3L_1$. Assim sendo, a nossa primeira matriz elementar é a matriz:

$$E_{21}(3) = \begin{bmatrix} 1 & 0 & 0 \\ -3 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Multiplicando $E_{21}(3)$ à esquerda por A , nós obtemos:

$$E_{21}(3)A = \begin{bmatrix} 1 & 0 & 0 \\ -3 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 \\ 3 & 4 & -5 \\ 4 & 4 & 7 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 4 & -11 \\ 4 & 4 & 7 \end{bmatrix}.$$

Agora, o nosso pivô continua sendo 1, mas o multiplicador é 4. Então, nós faremos $L_3 - 4L_1$. A nossa segunda matriz elementar é a matriz:

$$E_{31}(4) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix}$$

Multiplicando $E_{31}(4)$ à esquerda por $E_{21}(3)A$, nós obtemos:

$$E_{31}(4)E_{21}(3)A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -4 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 \\ 0 & 4 & -11 \\ 4 & 4 & 7 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 4 & -11 \\ 0 & 4 & -1 \end{bmatrix}$$

Agora, o nosso pivô é 4, e o nosso multiplicador é 4. Assim sendo, nós faremos $L_3 - L_2$. A nossa terceira matriz elementar é a matriz:

$$E_{32}(1) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix}$$

Multiplicando $E_{32}(1)$ à esquerda por $E_{31}(4)E_{21}(3)A$, nós obtemos:

$$E_{32}(1)E_{31}(4)E_{21}(3)A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 2 \\ 0 & 4 & -11 \\ 0 & 4 & -1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 4 & -11 \\ 0 & 0 & 10 \end{bmatrix}.$$

No final, nós obtivemos $E_{32}(1)E_{31}(4)E_{21}(3)A = U$.

Perceba que, ao multiplicar as matrizes elementares pela matriz A na ordem correta (ou seja, cada nova matriz elementar é multiplicada à esquerda), nós conseguimos descrever o processo de eliminação apenas utilizando matrizes.

Mais do que isso: como na seção anterior nós provamos que a multiplicação de matrizes triangulares superior (inferior) é uma matriz triangular superior (inferior), nós podemos escrever $E_{32}(1)E_{31}(4)E_{21}(3) = E$, onde E é uma matriz triangular superior.

Fazendo isso, nós obtemos uma equação matricial $EA = U$, de onde surgirá a nossa primeira fatoração de matrizes, $A = LU$, onde L é a matriz inversa de E (que nós definiremos em breve).

2.6 Matrizes de Permutação

Até agora, nós focamos apenas nos sistemas lineares que podem ser resolvidos sem troca de linhas ou de colunas. No entanto, nem sempre isto é possível. Um exemplo disso é o seguinte sistema:

$$\begin{cases} 3y = 9 \\ x + 2y = 6 \end{cases}$$

Neste caso, para observarmos o procedimento padrão da Eliminação Gaussiana, nós trocamos a linha 1 com a linha 2 (indicamos esta operação por $L_1 \leftrightarrow L_2$). Utilizando a notação matricial, nós fazemos:

$$\begin{bmatrix} 0 & 3 \\ 1 & 2 \end{bmatrix} \xrightarrow{L_1 \leftrightarrow L_2} \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}$$

Assim como na seção anterior, nós estamos interessados em descrever este processo usando matrizes. Então, nós podemos um tipo especial de matriz que realiza esta operação: as matrizes de permutação.

Definição 2.6.1 (Matriz de Permutação). *Uma **matriz de permutação** P é definida como a matriz identidade com as linhas (ou colunas) que serão trocadas permutadas.*

Exemplo 2.6.2. *Suponha que nós temos um sistema linear 3×3 , no qual nós precisamos trocar a linha 1 com a linha 2. Então, a matriz de permutação P que realiza esta troca é:*

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Exemplo 2.6.3. *Suponha que nós temos um sistema linear 4×4 , no qual precisamos trocar a linha 2 com a linha 4. Então, a matriz de permutação P que realiza esta troca é:*

$$P = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}$$

Aqui é necessário um certo cuidado: se nós queremos trocar linhas, nós multiplicamos P à esquerda de A (PA). Se nós queremos trocar colunas, nós multiplicamos P à direita de A (AP).

2.7 Inversa de uma Matriz

O próximo conceito importante que definiremos é o de inversa de uma matriz. De fato, se nós temos um sistema linear $Ax = b$ com uma única solução, nós queremos ser capazes de escrever x em termos de uma multiplicação matricial. A matriz inversa faz exatamente este papel.

Definição 2.7.1 (Matriz Inversa). *Seja A uma matriz quadrada $n \times n$. Dizemos que C é uma **inversa** de A se $AC = CA = I$.*

Para matrizes retangulares, é possível ter uma inversa à esquerda e outra inversa à direita em alguns casos. A notação que nós usaremos para denotar a inversa de uma matriz A é A^{-1} . A rigor, ainda não deveríamos usar esta notação, porque não demonstramos ainda a unicidade da matriz inversa. Porém, até que o façamos, nós usaremos esta notação mesmo assim, supondo que a inversa é única (e ela é, como demonstraremos em breve).

Uma inversa muito fácil é a inversa de uma matriz elementar: $E_{ij}(l)^{-1} = E_{ij}(-l)$.

Exemplo 2.7.2. Considere a matriz $E_{21}(l)$ de um sistema linear 3×3 . Então:

$$E_{21}(l) = \begin{bmatrix} 1 & 0 & 0 \\ -l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$E_{21}(-l) = \begin{bmatrix} 1 & 0 & 0 \\ l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$E_{21}(l)E_{21}(-l) = \begin{bmatrix} 1 & 0 & 0 \\ -l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = I$$

$$E_{21}(-l)E_{21}(l) = \begin{bmatrix} 1 & 0 & 0 \\ l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ -l & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = I$$

Logo, $E_{21}(l)^{-1} = E_{21}(-l)$.

Apesar deste exemplo, nem sempre é uma tarefa fácil encontrar a inversa de uma matriz quando ela existe. Assim sendo, nós queremos encontrar um método que nos dê a capacidade de fazer isto para qualquer matriz invertível.

E a ideia é usar a definição: dado que A^{-1} é a matriz inversa de A quando $AA^{-1} = A^{-1}A = I$, e que toda matriz pode ser vista como uma lista de vetores-coluna, encontrar a matriz inversa equivale a resolver vários sistemas lineares.

Se denotarmos as colunas de A^{-1} por $x_1, \dots, x_n$, e as colunas de I por $e_1, \dots, e_n$, nós queremos resolver:

$$A \begin{bmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_n \\ | & | & \cdots & | \end{bmatrix} = \begin{bmatrix} | & | & \cdots & | \\ e_1 & e_2 & \cdots & e_n \\ | & | & \cdots & | \end{bmatrix}$$

Isto equivale a resolver n sistemas lineares da forma $Ax_i = e_i$, para $i \in \{1, \dots, n\}$.

Esta ideia nos leva ao processo de Eliminação de Gauss-Jordan:

$$[A \mid I] \implies [I \mid A^{-1}]$$

De um modo mais detalhado, nós iniciamos o processo construindo uma matriz aumentada $[A \mid I]$, onde I é a matriz identidade $n \times n$. Em seguida, nós aplicamos os passos da eliminação de modo a obter, no bloco esquerdo, uma matriz triangular superior U . Ficamos, assim, com a matriz aumentada $[U \mid C]$, onde C é uma matriz $n \times n$ intermediária. Por fim, nós aplicamos um processo de eliminação acima da diagonal de U , e fazemos divisões nas linhas se for necessário, de modo a obter a matriz identidade I no bloco esquerdo da matriz aumentada, e a matriz que fica no bloco direito é a inversa de A . Ou seja, ao final, nós obtemos $[I \mid A^{-1}]$.

Exemplo 2.7.3. Seja $A = \begin{bmatrix} 2 & 8 \\ 4 & 3 \end{bmatrix}$. Para achar a matriz inversa A^{-1} , nós fazemos o seguinte processo:

$$\begin{aligned} \left[\begin{array}{cc|cc} 2 & 8 & 1 & 0 \\ 4 & 3 & 0 & 1 \end{array} \right] &\xrightarrow{L_2 - 2L_1} \left[\begin{array}{cc|cc} 2 & 8 & 1 & 0 \\ 0 & -13 & -2 & 1 \end{array} \right] \xrightarrow{L_1/2} \left[\begin{array}{cc|cc} 1 & 4 & 1/2 & 0 \\ 0 & -13 & -2 & 1 \end{array} \right] \\ &\xrightarrow{L_2/-13} \left[\begin{array}{cc|cc} 1 & 4 & 1/2 & 0 \\ 0 & 1 & 2/13 & -1/13 \end{array} \right] \xrightarrow{L_1 - 4L_2} \left[\begin{array}{cc|cc} 1 & 0 & -3/26 & 8/26 \\ 0 & 1 & 4/26 & -2/26 \end{array} \right] \end{aligned}$$

$$\text{Assim sendo, } A^{-1} = -\frac{1}{26} \begin{bmatrix} 3 & -8 \\ -4 & 2 \end{bmatrix}.$$

Agora que nós já sabemos encontrar a inversa de uma matriz, vamos enunciar e demonstrar algumas de suas propriedades:

Proposição 2.7.4 (Unicidade da Inversa). *Seja A uma matriz $n \times n$ invertível. Então, a sua inversa é única.*

Demonstração. *Sejam B e C inversas de A . Então, $BA = AB = I$ e $CA = AC = I$. Assim sendo, $BA = AC = I$. Ao multiplicar C à direita de A , nós obtemos $BAC = B(AC) = BI = B$. Ao mesmo tempo, porém, $BAC = (BA)C = IC = C$. Logo, $B = C$.* $\square$

Proposição 2.7.5. *Se existe $x \neq 0$ tal que $Ax = 0$, então A não possui inversa.*

Demonstração. *Suponha, por absurdo, que A possui inversa, dada por A^{-1} . Então:*

$$Ax = 0 \implies A^{-1}Ax = A^{-1}0 \implies Ix = 0 \implies x = 0.$$

Isto é um absurdo, dado que $x \neq 0$ por hipótese. Logo, A não possui inversa. $\square$

Proposição 2.7.6 (Inversa de uma matriz 2×2). *Seja $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ uma matriz invertível.*

$$\text{Então, } A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

Demonstração. *Vamos calcular AA^{-1} , e mostrar que o resultado é igual a I :*

$$AA^{-1} = \frac{1}{ad - bc} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \frac{1}{ad - bc} \begin{bmatrix} ad - bc & 0 \\ 0 & ad - bc \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = I.$$

$\square$

Proposição 2.7.7 (Inversa da Multiplicação). *Sejam A e B duas matrizes $n \times n$ invertíveis. Então, $(AB)^{-1} = B^{-1}A^{-1}$.*

Demonstração. *Vamos calcular o produto matricial $AB(B^{-1}A^{-1})$. Nós temos que:*

$$AB(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AIA^{-1} = AA^{-1} = I$$

Agora, nós vamos calcular o produto matricial $(B^{-1}A^{-1})AB$. Nós temos que:

$$(B^{-1}A^{-1})AB = B^{-1}(A^{-1}A)B = B^{-1}IB = B^{-1}B = I$$

Logo, $(AB)^{-1} = B^{-1}A^{-1}$.

□

Para a próxima propriedade, nós vamos definir o conceito de matriz diagonal:

Definição 2.7.8 (Matriz Diagonal). *Seja D uma matriz tal que $D_{ij} = 0$ se $i \neq j$. Então, D é chamada uma **matriz diagonal**.*

Proposição 2.7.9 (Inversa de uma Matriz Diagonal). *Seja $D = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix}$, com $d_i \neq 0$ para todo $i \in \{1, \dots, n\}$. Então, $D^{-1} = \begin{bmatrix} 1/d_1 & 0 & \cdots & 0 \\ 0 & 1/d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1/d_n \end{bmatrix}$.*

Demonstração. *Vamos calcular DD^{-1} :*

$$\begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & d_n \end{bmatrix} \begin{bmatrix} 1/d_1 & 0 & \cdots & 0 \\ 0 & 1/d_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1/d_n \end{bmatrix} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix} = I$$

□

Proposição 2.7.10 (Solução do Sistema Linear $Ax = b$). *Seja A uma matriz $n \times n$ invertível. Então, a solução do sistema linear $Ax = b$ é dada por $x = A^{-1}b$.*

Demonstração. *Seja A uma matriz $n \times n$ tal que $Ax = b$, cuja inversa existe e é dada por A^{-1} . Então, podemos multiplicar os dois lados da equação à esquerda por A^{-1} . Nós obtemos:*

$$Ax = b \implies A^{-1}Ax = A^{-1}b \implies Ix = A^{-1}b \implies x = A^{-1}b.$$

□

Proposição 2.7.11 (Inversa de uma Matriz Triangular). *Seja L uma matriz triangular inferior com diagonal não-zero. Então, L^{-1} é uma matriz triangular inferior com diagonal não-zero (o mesmo vale para matriz triangular superior).*

Demonstração. *Seja L uma matriz triangular inferior $n \times n$ com todos os elementos da diagonal principal diferentes de zero. Então, queremos encontrar a matriz inversa $X = L^{-1}$ tal que $LX = I$. Ou seja, nós podemos resolver n sistemas lineares da forma $Lx_j = e_j$.*

Vamos analisar os elementos x_{ij} da coluna x_j da matriz X . Quando $i < j$, nós temos:

$$l_{11}x_{1j} = 0 \implies x_{1j} = 0$$

$$l_{21}x_{1j} + l_{22}x_{2j} = 0 \implies x_{2j} = 0$$

$$\vdots$$

$$l_{n1}x_{1j} + l_{n2}x_{2j} + \cdots + l_{nn}x_{nj} = 0 \implies x_{nj} = 0$$

Logo, $x_{ij} = 0$ quando $i < j$.

Quando $i = j$, a equação correspondente à linha j é:

$$\sum_{k=1}^{j-1} l_{jk}x_{kj} + l_{jj}x_{jj} = e_{jj}$$

Como $x_{ij} = 0$ quando $i < j$, resta apenas o termo $l_{jj}x_{jj} = 1 \implies x_{jj} = \frac{1}{l_{jj}}$. Ou seja, os elementos da diagonal de L^{-1} são diferentes de zero.

Para provar a mesma propriedade para matrizes triangulares superior, basta usar o mesmo raciocínio. □

Proposição 2.7.12 (Existência da Inversa). *Seja A uma matriz $n \times n$ qualquer. Então, A^{-1} existe exatamente quando A tem n pivôs.*

Demonstração. $\Leftarrow$ *Suponha que A possui n pivôs. Então, existe uma matriz de eliminação E tal que $EA = U$ com diagonal não-zero. Sabemos que a matriz E é triangular inferior com 1's na diagonal. Do teorema anterior, nós sabemos que U possui inversa. Assim sendo, multiplicando U^{-1} a ambos os lados da equação, nós obtemos:*

$$U^{-1}EA = U^{-1}U \implies (U^{-1}E)A = I \implies A^{-1} = U^{-1}E$$

. Logo, A^{-1} existe.

$\implies$ *Se A possui inversa, então $AA^{-1} = I \implies (EA)A^{-1} = E$. Assim sendo, linha i de $(EAA^{-1}) = (\text{linha } i \text{ de } EA)A^{-1} = \text{linha } i \text{ de } E$. Se a linha i de EA for nula, nós teremos um absurdo (pois a linha i de E não é nula, por hipótese). Por sua vez, se A não tem n pivôs, então pelo menos uma linha de EA é zero, logo, A possui exatamente n pivôs. □*

2.8 Matrizes em Blocos

A última ideia que nós vamos apresentar neste capítulo, mas que já apareceu anteriormente, é a de dividir uma matriz em blocos. De fato, por vezes a estrutura de uma matriz permite que ela seja dividida em submatrizes menores que possuem, sozinhas, características que podem ser interessantes na hora de fazer cálculos. Um exemplo é o seguinte:

Exemplo 2.8.1. *Considere a matriz $A = \begin{bmatrix} 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix}$. Nós podemos dividir esta matriz A em blocos de matrizes identidade 2×2 , como a seguir:*

$$A = \begin{bmatrix} I_2 & I_2 & I_2 \\ I_2 & I_2 & I_2 \end{bmatrix}$$

Assim como nós já sabemos multiplicar matrizes, nós podemos utilizar o mesmo raciocínio para multiplicar matrizes em blocos (nós não iremos demonstrar este fato, mas pense intuitivamente que todo número pode ser visto como uma matriz 1×1 , e esta é apenas uma extensão para blocos de matrizes que possuam as dimensões corretas entre si).

A multiplicação em blocos é feita da mesma forma que a multiplicação normal de matrizes. Considere, por exemplo, $A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix}$ e $\begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$. Considere ainda que as submatrizes possuem as dimensões compatíveis com a operação de multiplicação matricial. Então:

$$(AB)_{11} = A_{11}B_{11} + A_{21}B_{21},$$

e assim por diante.

Assim como nós fazíamos eliminação olhando para cada elemento de uma matriz, nós podemos fazer eliminação por blocos também. Considere $M = \begin{bmatrix} A & B \\ C & D \end{bmatrix}$, em que A^{-1} existe.

Se tomarmos $E = \begin{bmatrix} I & 0 \\ -CA^{-1} & I \end{bmatrix}$, com as dimensões corretas, nós podemos fazer:

$$EM = \begin{bmatrix} A & B \\ 0 & -CA^{-1}B + D \end{bmatrix},$$

obtendo uma espécie de matriz triangular superior por blocos.

2.9 Exercícios

Importante: a maioria dos exercícios são baseados em (2).

2.1) Sejam $A = \begin{bmatrix} 1 & 0 & 4 \\ 3 & -1 & 2 \\ 2 & 5 & -13 \end{bmatrix}$ e $b = \begin{bmatrix} 2 \\ 4 \\ -8 \end{bmatrix}$. Ache o vetor x tal que $Ax = b$.

2.2) Considere o seguinte sistema linear:

$$\begin{cases} ax + by = e \\ cx + dy = f \end{cases}$$

Suponha que o primeiro pivô é a . A eliminação produz que fórmula para o segundo pivô? Verifique que o segundo pivô não existe se $ad = bc$. Supondo que os dois pivôs existam, resolva o sistema linear.

2.3) Considere as duas matrizes $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ e $B = \begin{bmatrix} x & y \\ w & z \end{bmatrix}$. Calcule AB e BA . É verdade que $AB = BA$ neste caso? Calcule também A^2 e B^2 .

2.4) Sejam $x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$ e $y = \begin{bmatrix} y_1 & y_2 & y_3 \end{bmatrix}$. Calcule xy e yx . Em seguida, calcule $(yx)xy$.

Por que não podemos dizer que $(yx)xy = y(xx)y$?

2.5) Ache a matriz de eliminação E que reduz a matriz de Pascal em uma menor:

$$E \begin{bmatrix} 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 2 & 1 & 0 \\ 1 & 3 & 3 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 1 & 2 & 1 \end{bmatrix}.$$

Qual matriz M reduz a matriz de Pascal à matriz identidade?

2.6) Para quais valores de a o método de eliminação não dará 3 pivôs?

$$\begin{bmatrix} a & 2 & 3 \\ a & a & 4 \\ a & a & a \end{bmatrix}.$$

2.7) Suponha que D é uma matriz diagonal $n \times n$ com n pivôs. Quantas operações são necessárias para resolver o sistema linear $Dx = b$? E se nós tivermos uma matriz triangular superior U com n pivôs, quantas operações são necessárias para resolver o sistema $Ux = b$? (Para este exercício, suponha que não há troca de linhas ou de colunas).

2.8) Considere a seguinte matriz:

$$T = \begin{bmatrix} 1 & 2 & 0 & 0 & 0 \\ 3 & 4 & 3 & 0 & 0 \\ 0 & 8 & -2 & 4 & 0 \\ 0 & 0 & 3 & 1 & 1 \\ 0 & 0 & 0 & 2 & 3 \end{bmatrix}.$$

Ache a matriz triangular superior U resultante do processo de escalonamento de T .

2.9) Resolva o seguinte sistema linear:

$$\begin{bmatrix} 1 & 4 & 8 \\ 2 & 8 & 12 \\ 3 & 16 & -9 \end{bmatrix} x = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}.$$

Qual foi a matriz de permutação P utilizada?

2.10) Considere o vetor $x = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}$. Qual é a matriz de permutação P tal que $Px = \begin{bmatrix} 4 \\ 3 \\ 2 \\ 1 \end{bmatrix}$?

2.11) Considere as matrizes $A = \begin{bmatrix} 2 & 3 & 4 \\ 1 & 2 & 3 \\ 5 & 6 & 7 \end{bmatrix}$ e $P = \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}$. Calcule AP e PA . Qual é a diferença entre as duas multiplicações?

2.12) Mostre que $(A + B)^2 \neq A^2 + 2AB + B^2$. Qual é a fórmula correta?

2.13) Usando o processo de Eliminação de Gauss-Jordan, encontre a inversa de

$$A = \begin{bmatrix} 2 & 3 & 0 \\ 4 & -1 & 5 \\ 3 & 2 & 7 \end{bmatrix}.$$

2.14) Use o método de Gauss-Jordan para encontrar a inversa da matriz triangular inferior:

$$U = \begin{bmatrix} 1 & a & b \\ 0 & 1 & c \\ 0 & 0 & 1 \end{bmatrix}$$

2.15) Sejam A e B duas matrizes $n \times n$ tais que $A + B$ é invertível. Pode-se dizer que $(A + B)^{-1} = A^{-1} + B^{-1}$? Se sim, demonstre. Se não, mostre um contra-exemplo.

2.16) Considere as matrizes em blocos $E = \begin{bmatrix} I_2 & I_2 \\ I_2 & I_2 \end{bmatrix}$ e $M = \begin{bmatrix} A_{2 \times 2} & B_{2 \times 2} \\ C_{2 \times 2} & D_{2 \times 2} \end{bmatrix}$. Calcule EM e ME . É possível dizer que $EM = ME$?

2.17) Ache uma matriz não-zero A tal que $A^2 = 0$ e uma matriz B com $B^2 \neq 0$ e $B^3 = 0$.

2.18) Ache uma matriz $A_{3 \times 3}$ diferente da matriz identidade e da matriz nula tal que $A^2 = A$.

2.19) Verdadeiro ou falso (prove ou dê um contra-exemplo):

- a) Se A^2 está bem definida, então A é quadrada.
- b) Se AB e BA estão bem definidas, então A e B são quadradas.
- c) Se AB e BA estão bem definidas, então AB e BA são quadradas.
- d) Se $AB = B$, então $A = I$.

2.20) Seja A uma matriz quadrada $n \times n$ invertível. Demonstre que $(A^{-1})^{-1} = A$.

2.21) Prove que, se L é uma matriz triangular inferior com 1's na diagonal, então a sua inversa L^{-1} também é uma matriz triangular inferior com 1's na diagonal.

Capítulo 3

Fatoração LU

Importante: Este capítulo é baseado em (5).

No capítulo anterior, nós vimos que, dada uma matriz A invertível, nós podemos encontrar uma matriz de eliminação E tal que $EA = U$, onde U é uma matriz triangular superior e E é uma matriz triangular inferior. Isto nos sugere que, ao encontrar a matriz inversa de E , nós podemos escrever A como a multiplicação de duas matrizes, uma triangular inferior e uma triangular superior. Esta é a ideia da fatoração LU , que nós desenvolveremos neste capítulo.

3.1 Fatoração LU

Antes de nós desenvolvermos as ideias para construir a fatoração LU , é necessário nós entendermos o que é uma fatoração matricial:

Definição 3.1.1 (Fatoração). *Seja A uma matriz qualquer. Uma **fatoração** de A consiste em escrever A como o produto de matrizes mais simples.*

Ao longo destas notas de aula, nós veremos várias fatorações de matrizes. A primeira que nós veremos é a fatoração LU , e algumas de suas variantes. Mas antes, vamos falar um pouco sobre o porque fatorações são importantes. Muitas vezes, nós estamos interessados em descobrir quais são as propriedades de uma matriz, ou o que ela está fazendo quando é aplicada a um vetor. Assim sendo, nós podemos fatorar uma matriz em outras matrizes que possuam propriedades interessantes (como matrizes diagonais, triangulares, e outros tipos que ainda definiremos), de modo a compreender melhor a estrutura da matriz original.

Dito isto, vamos desenvolver a ideia da fatoração LU através de um exemplo e, em seguida, vamos generalizar este conceito.

Exemplo 3.1.2. *Considere a matriz $A = \begin{bmatrix} 3 & 1 & 0 \\ 6 & 4 & 1 \\ 0 & 4 & 3 \end{bmatrix}$. Vamos começar a aplicar os passos*

da eliminação gaussiana a esta matriz. O nosso primeiro pivô é 3, e o nosso primeiro multiplicador é 2. Assim sendo, nós faremos $L_2 - 2L_1$. A matriz de eliminação deste passo

é $E_{21}(2) = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$. Calculando $E_{21}(2)A$, nós obtemos:

$$E_{21}(2)A = \begin{bmatrix} 3 & 1 & 0 \\ 0 & 2 & 1 \\ 0 & 4 & 3 \end{bmatrix}.$$

Como o segundo multiplicador é 0, não fazemos nada, e avançamos para o próximo passo. Agora, o nosso pivô é 2 e o multiplicador é 2. Assim sendo, nós faremos $L_3 - 2L_2$,

obtendo $E_{32}(2) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -2 & 1 \end{bmatrix}$. Calculando $E_{32}(2)E_{21}(2)A$, nós obtemos:

$$E_{32}(2)E_{21}(2)A = \begin{bmatrix} 3 & 1 & 0 \\ 0 & 2 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

Neste passo, nós terminamos o processo de escalonamento. Vamos ver o que nós obtivemos: a partir da matriz A , nós construímos uma matriz $E = E_{32}(2)E_{21}(2)$ tal que $EA = U$, onde E é uma matriz triangular inferior e U é uma matriz triangular superior.

Podemos nos perguntar agora: o que acontece se multiplicarmos E^{-1} dos dois lados da equação final? Do lado esquerdo, nós obtemos a matriz A . Do lado direito, nós obtemos $(E_{32}(2)E_{21}(2))^{-1}U$. Sabemos que a inversa de AB , quando existe, é igual a $B^{-1}A^{-1}$. Assim sendo, vamos escrever a equação como um produto de inversas:

$$A = E_{21}(2)^{-1}E_{32}(2)^{-1}U.$$

No entanto, como nós vimos no capítulo anterior, a inversa de uma matriz de eliminação é muito fácil de se achar: nós obtemos a equação

$$A = E_{21}(-2)E_{32}(-2)U$$

Fazemos as contas, nós finalmente encontramos:

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 2 & 1 \end{bmatrix} \begin{bmatrix} 3 & 1 & 0 \\ 0 & 2 & 1 \\ 0 & 0 & 1 \end{bmatrix}.$$

Assim sendo, nós conseguimos escrever A como o produto de uma matriz triangular inferior e uma matriz triangular superior. Chamando E^{-1} de L , nós obtemos que $A = LU$. Esta é a fatoração LU de A , onde L é a inversa da matriz de eliminação, e U é a matriz obtida ao final do processo de escalonamento.

De uma maneira geral, suponha que nós temos uma matriz $A_{n \times n}$ invertível. Então, existe uma matriz E de eliminação tal que $EA = U$. A matriz E , por construção, é dada por:

$$E = E_{n,n-1} \dots E_{n,2} \dots E_{4,2} E_{3,2} E_{n,1} \dots E_{3,1} E_{2,1}.$$

Por sua vez, a matriz L é dada por:

$$L = E^{-1} = E_{2,1}^{-1} E_{3,1}^{-1} \dots E_{n,1}^{-1} E_{3,2}^{-1} E_{4,2}^{-1} \dots E_{n,2}^{-1} \dots E_{n,n-1}^{-1}.$$

Deste modo, a fatoração LU de A é dada por $A = LU$, onde L é a matriz descrita acima, e U é a matriz final resultante do processo de escalonamento.

Apesar de parecer ser muito complicado encontrar a matriz L , é algo incrivelmente simples: os seus elementos abaixo da diagonal principal são simplesmente os multiplicadores da eliminação.

3.2 Fatoração LDU

A primeira variante da fatoração LU que nós veremos é a fatoração LDU , em que D é a matriz diagonal com pivôs de A . Suponha que, após o processo de eliminação, nós

conseguimos encontrar a fatoração LU de A , na qual $U = \begin{bmatrix} d_1 & u_{12} & u_{13} & \cdots & u_{1n} \\ 0 & d_2 & u_{23} & \cdots & u_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & d_n \end{bmatrix}$.

Nós podemos escrever a matriz U como:

$$U = \begin{bmatrix} d_1 & 0 & 0 & \cdots & 0 \\ 0 & d_2 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & d_n \end{bmatrix} \begin{bmatrix} 1 & u_{12}/d_1 & u_{13}/d_1 & \cdots & u_{1n}/d_1 \\ 0 & 1 & u_{23}/d_2 & \cdots & u_{2n}/d_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix}$$

Ou seja, nós escrevemos U como o produto de uma matriz diagonal e uma matriz triangular superior. Dessa forma, chamando a nova matriz triangular superior de U , nós temos que A pode ser escrita como $A = LDU$.

Exemplo 3.2.1. No exemplo que nós usamos para apresentar a fatoração LU , nós conseguimos obter a seguinte fatoração LDU :

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ 0 & 2 & 1 \end{bmatrix} \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1/3 & 0 \\ 0 & 1 & 1/2 \\ 0 & 0 & 1 \end{bmatrix}.$$

3.3 Existência e Unicidade da Fatoração LU

Nas seções anteriores, nós aprendemos a calcular a fatoração LU de uma matriz, e uma de suas variantes. No entanto, nós ainda não demonstramos a existência da fatoração LU . Nós o faremos agora, e também demonstraremos a sua unicidade.

Teorema 3.3.1 (Existência e Unicidade da Fatoração LU). *Seja A uma matriz $n \times n$ invertível. Então, A pode ser escrita de forma única como o produto de uma matriz triangular inferior L com todos os elementos da diagonal iguais a 1, e uma matriz triangular superior U .*

Demonstração. Existência: Em primeiro lugar, demonstremos a existência da fatoração LU . Para fazer isto, considere uma matriz $A_{k \times k}$ invertível. Nós usaremos indução em k .

Para $k = 1$, seja $A_{1 \times 1} = a$. Tomando $L = 1$ e $U = a$, nós temos que $A = 1 \cdot a = LU$.

Suponha que a fatoração LU existe quando $k = n - 1$. Vamos provar que ela existe para $k = n$:

Defina $A = \begin{bmatrix} B_{(n-1) \times (n-1)} & \begin{bmatrix} a_{1n} \\ \vdots \\ a_{(n-1),n} \end{bmatrix} \\ \begin{bmatrix} a_{n1} & \cdots & a_{n,n-1} \end{bmatrix} & a_{nn} \end{bmatrix}$, onde B é uma matriz invertível. Por hipótese, sabemos que existem L_{n-1} e U_{n-1} tais que $B = L_{n-1}U_{n-1}$.

Vamos definir duas matrizes L e U tais que:

$$L = \begin{bmatrix} L_{n-1} & \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} \\ l_{n-1} & 1 \end{bmatrix} \quad e \quad U = \begin{bmatrix} U_{n-1} & u_{n-1} \\ 0 & \cdots & 0 & u_{nn} \end{bmatrix}$$

Note que l_{n-1} e u_{n-1} são vetores. Note também que L é uma matriz triangular inferior com 1's na diagonal, e que U é uma matriz triangular superior. Vamos determinar o que é a matriz LU :

$$LU = \begin{bmatrix} L_{n-1}U_{n-1} & L_{n-1}u_{n-1} \\ l_{n-1}U_{n-1} & l_{n-1}u_{n-1} + u_{nn} \end{bmatrix} = \begin{bmatrix} B & L_{n-1}u_{n-1} \\ l_{n-1}U_{n-1} & l_{n-1}u_{n-1} + u_{nn} \end{bmatrix}$$

Existem três elementos que nós precisamos encontrar: l_{n-1} , u_{n-1} e u_{nn} . Tomando $A = LU$, nós obtemos o seguinte sistema de equações:

$$\begin{cases} l_{n-1}U_{n-1} = \begin{bmatrix} a_{n1} & \cdots & a_{n,n-1} \end{bmatrix} \\ L_{n-1}u_{n-1} = \begin{bmatrix} a_{1n} \\ \vdots \\ a_{n-1,n} \end{bmatrix} \\ l_{n-1}u_{n-1} + u_{nn} = a_{nn} \end{cases}$$

Da primeira equação, nós temos que $l_{n-1} = \begin{bmatrix} a_{n1} & \cdots & a_{nn} \end{bmatrix} U_{n-1}^{-1}$. Como nós vimos no capítulo anterior, U_{n-1}^{-1} existe. Logo, l_{n-1} está bem definida.

Da segunda equação, nós temos que $u_{n-1} = L_{n-1}^{-1} \begin{bmatrix} a_{1n} \\ \vdots \\ a_{nn} \end{bmatrix}$. Nós também sabemos que

L_{n-1}^{-1} existe. Logo, u_{n-1} está bem definida.

Finalmente, da terceira equação, nós temos que $u_{nn} = a_{nn} - l_{n-1}u_{n-1}$. Nós temos que a_{nn} já é conhecido, e l_{n-1} e u_{n-1} nós encontramos. Portanto, u_{nn} também está bem definido. Logo, $A = LU$.

Unicidade: Agora, considerando as mesmas hipóteses para A , nós vamos demonstrar a unicidade da fatoração LU . Suponha que $A = LU = \hat{L}\hat{U}$. Então, $I = L^{-1}LU^{-1} = L^{-1}\hat{L}\hat{U}U^{-1}$. Segue então que $\hat{U}U^{-1} = (L^{-1}\hat{L})^{-1} = \hat{L}^{-1}L$.

Ou seja, dado que nós obtivemos uma igualdade entre uma matriz triangular superior e uma matriz triangular inferior, segue que $\hat{L}^{-1}L$ precisa ser diagonal, e, como por hipótese a diagonal de L é composta por 1's, $\hat{L}^{-1}L$ possui diagonal apenas com 1's. Logo, $\hat{L}^{-1}L = I \implies L = \hat{L}$.

Por sua vez, como agora sabemos que $LU = L\hat{U}$, podemos multiplicar L^{-1} à esquerda dos dois lados da equação, obtendo:

$$L^{-1}LU = L^{-1}L\hat{U} \implies U = \hat{U}.$$

Logo, a fatoração LU é única. □

Um resultado que vem do processo de eliminação: se uma matriz A é tal que $A = LU$, então o sistema $Ax = b$ vira $Ux = c = L^{-1}b$. No entanto, até agora, nós tratamos da fatoração LU unicamente no caso em que não há trocas de linhas ou de colunas. Se houver

trocas de linhas, não é verdade que $A = LU$, mas é verdade que $PA = LU$, onde P é a matriz de permutação que realiza as trocas.

3.4 Transposta de uma Matriz

Nesta seção, nós vamos definir o conceito de matriz transposta, e provar algumas das suas propriedades.

Definição 3.4.1 (Matriz Transposta). *Seja A uma matriz $m \times n$ qualquer. Nós dizemos que A^T é a **matriz transposta** de A se $(A^T)_{ij} = A_{ji}$.*

Vejamos um exemplo de matriz transposta:

Exemplo 3.4.2. *Seja $A = \begin{bmatrix} 2 & 1 \\ 3 & 5 \\ 4 & 8 \end{bmatrix}$. Então, a sua matriz transposta, A^T , é dada por*

$$A^T = \begin{bmatrix} 2 & 3 & 4 \\ 1 & 5 & 8 \end{bmatrix}.$$

Na prática, para encontrar a transposta de uma matriz, basta escrever cada coluna da matriz original como uma linha da matriz transposta.

Vejamos agora algumas de suas propriedades:

Proposição 3.4.3 (Transposta do Produto). *Sejam $A_{m \times n}$ e $B_{n \times p}$ duas matrizes quaisquer. Então, $(AB)^T = B^T A^T$.*

Demonstração. *Primeiramente, vamos calcular $(AB)_{ij}^T$:*

$$(AB)_{ij}^T = (AB)_{ji} = \sum_{k=1}^n a_{jk} b_{ki}.$$

Agora, vamos calcular $(B^T A^T)_{ij}$:

$$(B^T A^T)_{ij} = \sum_{k=1}^n (B^T)_{ik} (A^T)_{kj} = \sum_{k=1}^n b_{ki} a_{jk} = \sum_{k=1}^n a_{jk} b_{ki}.$$

Logo, $(AB)^T = B^T A^T$.

□

Proposição 3.4.4 (Inversa da Transposta). *Seja $A_{n \times n}$ uma matriz invertível. Então, $(A^T)^{-1} = (A^{-1})^T$.*

Demonstração. *Seja $C = (A^{-1})^T$. Nós queremos verificar que C é a inversa de A , ou seja, que $CA^T = I$. Para fazer isto, vamos calcular CA^T :*

$$CA^T = (A^{-1})^T A^T = (AA^{-1})^T = I^T = I.$$

Logo, $C = (A^T)^{-1}$, ou seja, $(A^T)^{-1} = (A^{-1})^T$.

□

Proposição 3.4.5 (Transposta de uma Matriz Triangular). *Seja $L_{n \times n}$ uma matriz triangular inferior. Então, L^T é uma matriz triangular superior.*

Demonstração. Se L é uma matriz triangular inferior, por definição, $L_{ij} = 0$ se $i < j$. Sabemos que $L_{ji}^T = L_{ij}$. Assim sendo, quando $i < j$, $L_{ji}^T = 0$, e como $j > i$, segue que L^T é uma matriz triangular superior. $\square$

Proposição 3.4.6 (Transposta da Transposta). *Seja $A_{m \times n}$ uma matriz qualquer. Então, $(A^T)^T = A$.*

Demonstração. Seja $C = A^T$. Então, $C_{ij}^T = C_{ji} = (A^T)_{ji} = A_{ij}$. Logo, $A = (A^T)^T$. $\square$

Proposição 3.4.7 (Produto Interno e Produto Externo). *Sejam x e y vetores-coluna $n \times 1$. Então, $x^T y$ é o produto interno euclidiano de x e y , e xy^T é uma matriz cujas colunas são múltiplas de x .*

Demonstração. Primeiramente, vamos calcular $x^T y$:

$$x^T y = \sum_{k=1}^n x_{1k}^T y_{k1} = \sum_{k=1}^n x_{k1} y_{k1} = \sum_{k=1}^n x_k y_k = x \cdot y.$$

Agora, vamos calcular xy^T :

$$(xy^T)_{ij} = \sum_{k=1}^n x_{ik} y_{kj}^T = \sum_{k=1}^n x_{ik} y^{jk} = x_i y_j.$$

$\square$

Para a próxima propriedade, nós vamos fazer uma convenção sobre a matriz de permutação: seja e_i o i -ésimo vetor-coluna da matriz identidade $n \times n$. Então, uma matriz de permutação é dada por:

$$P = \begin{bmatrix} - & e_{p_1}^T & - \\ - & e_{p_2}^T & - \\ \vdots & & \\ - & e_{p_n}^T & - \end{bmatrix},$$

onde $(p_1, p_2, \dots, p_n)$ é uma permutação qualquer de $\{1, 2, \dots, n\}$.

Proposição 3.4.8 (Inversa da Permutação). *Seja $P_{n \times n}$ uma matriz de permutação. Então, $P^{-1} = P^T$.*

Demonstração. Usando a definição que nós acabamos de dar, nós temos que:

$$P = \begin{bmatrix} - & e_{p_1}^T & - \\ - & e_{p_2}^T & - \\ \vdots & & \\ - & e_{p_n}^T & - \end{bmatrix} \quad e \quad P^T = \begin{bmatrix} | & | & \cdots & | \\ e_{p_1} & e_{p_2} & \cdots & e_{p_n} \\ | & | & & | \end{bmatrix}.$$

Assim sendo, nós temos que:

$$(PP^T)_{ij} = e_{p_i}^T e_{p_j} = \begin{cases} 0, & \text{se } i \neq j \\ 1, & \text{se } i = j \end{cases} = I_{ij}.$$

Logo, $PP^T = I$. $\square$

3.5 Fatoração LDL^T

Vamos agora ver mais uma variante da fatoração LU . Antes, porém, vamos dar duas definições, das quais nós utilizaremos a primeira.

Definição 3.5.1 (Matriz Simétrica). *Seja $A_{n \times n}$ uma matriz qualquer. Dizemos que A é uma **matriz simétrica** se $A = A^T$.*

Definição 3.5.2 (Matriz Anti-simétrica). *Seja $A_{n \times n}$ uma matriz qualquer. Dizemos que A é uma **matriz anti-simétrica** se $A = -A^T$.*

A variante que nós apresentaremos agora é para o caso em que A é uma matriz simétrica. Considere que $A = LDU$, e que $A = A^T$.

Então, nós temos que $A = LDU$ e $A^T = (LDU)^T = U^T D^T L^T$. Assim sendo, $LDU = U^T D^T L^T$. No entanto, $D^T = D$ (nós não provamos este fato, mas este será um dos exercícios, por agora, assumiremos que é verdade, o que, de fato, é bem intuitivo).

Logo, $LDU = U^T D L^T$, em que U^T é uma matriz triangular inferior, e L^T é uma matriz triangular superior. Assim sendo, $L = U^T$ e $U = L^T$, e nós obtemos a seguinte fatoração de A : $A = LDL^T$.

De fato, verificando o que acontece com A^T , nós temos que:

$$A^T = (LDL^T)^T = LD^T L^T = LDL^T = A.$$

3.6 Fatoração PLU

Para finalizar as principais variantes da fatoração LU , nós vamos falar muito brevemente do caso em que há trocas de linhas durante o processo de eliminação.

Suponha que, ao realizar a eliminação, nós precisamos fazer trocas de linhas descritas por uma matriz de permutação P' . Então, nós podemos escrever a fatoração LU como:

$$P'A = LU.$$

Aplicando P'^{-1} à esquerda de ambos os lados da equação, nós obtemos:

$$P'^{-1}P'A = LU \implies A = P'^{-1}LU.$$

Sabemos, porém, que $P'^{-1} = P'^T$, e que esta matriz é também uma matriz de permutação. Chamando P'^T de P , nós obtemos uma fatoração $A = PLU$.

É possível ainda encontrar outras variações da fatoração LU , mas todas seguem basicamente a mesma ideia das variações que nós apresentamos aqui.

3.7 Exercícios

Importante: vários dos exercícios são baseados em (2).

3.1) Calcule a fatoração LU da seguinte matriz:

$$A = \begin{bmatrix} 2 & 3 & 0 \\ 4 & 1 & 3 \\ 8 & 2 & 3 \end{bmatrix}.$$

Calcule também a sua fatoraçaõ LDU .

3.2) Calcule a decomposiçaõ LU da seguinte matriz simétrica:

$$A = \begin{bmatrix} a & a & a & a \\ a & b & b & b \\ a & b & c & c \\ a & b & c & d \end{bmatrix}$$

Qual é a condiçaõ para que A tenha quatro pivõs?

3.3) Prove que, se A e B sãõ duas matrizes $m \times n$, entãõ $(A + B)^T = A^T + B^T$.

3.4) Prove que, se D é uma matriz diagonal, entãõ $D^T = D$.

3.5) Sejam y um vetor-coluna $m \times 1$, e A uma matriz $m \times n$. Prove que $y^T A$ é uma combinaçaõ linear das linhas de A .

3.6) Ache uma matriz de permutaçaõ P tal que P é 3×3 , $P \neq I$ e $P^3 = I$.

3.7) Considere uma matriz $A_{4 \times 4}$. Suponha que, nesta ordem, foram feitas as seguintes operaçaõs (sempre em cima da matriz resultante da operaçaõ anterior): $L_3 \leftrightarrow L_4$; $C_1 \leftrightarrow C_2$; $L_1 \leftrightarrow L_2$; $C_3 \leftrightarrow C_4$; $L_2 \leftrightarrow L_3$, em que L_i indica a linha i , e C_j indica a coluna j . Escreva a matriz final como $P_1 A P_2$, onde P_1 e P_2 sãõ duas matrizes de permutaçaõ.

3.8) Seja A uma matriz 4×4 . Quantas entradas de A podem ser escolhidas de A podem ser escolhidas independentemente caso A seja

- a) simétrica ($A^T = A$)?
- b) anti-simétrica ($A^T = -A$)?

3.9) Seja

$$A = \begin{bmatrix} 1 & c & 0 \\ 2 & 4 & 1 \\ 3 & 5 & 1 \end{bmatrix}.$$

a) Qual é o número c que leva o segundo pivõ a ser 0? O que podemos fazer para resolver este problema? Ainda é válido $A = LU$?

b) Qual é o número c que leva o terceiro pivõ a ser 0? É possível resolver este problema?

3.10) Seja A uma matriz $n \times n$ qualquer. Prove que sempre é possível escrever $A = B + C$, onde B é uma matriz simétrica e C é uma matriz anti-simétrica.

3.11) (Desafio!) Uma matriz de Vandermonde de ordem $n \times n$ definida por n pontos distintos $x_1, \dots, x_n$ é definida como:

$$V = \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ x_1 & x_2 & x_3 & \cdots & x_n \\ x_1^2 & x_2^2 & x_3^2 & \cdots & x_n^2 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_1^{n-1} & x_2^{n-1} & x_3^{n-1} & \cdots & x_n^{n-1} \end{bmatrix}.$$

Encontre a decomposição LU da matriz V .

Capítulo 4

Espaços Vetoriais

Importante: este capítulo é baseado em (6) e em (7).

Neste capítulo, nós vamos introduzir o conceito mais importante da Álgebra Linear, que é o de espaço vetorial. De fato, todas as operações que nós estávamos fazendo com vetores e com matrizes só fazem sentido porque existe uma estrutura algébrica na qual estes elementos existem. Ao mesmo tempo, com a definição que vamos dar, nós finalmente seremos capazes de abordar a definição mais correta de vetor.

4.1 Espaços Vetoriais

Nos capítulos anteriores, nós estávamos trabalhando com vetores e matrizes sem pensar muito na estrutura à qual eles pertencem. No entanto, se nós queremos dar um embasamento teórico forte para o que estamos fazendo, nós precisamos dizer qual é a estrutura que faz as coisas funcionarem.

Para isso, vamos definir formalmente o que é um espaço vetorial:

Definição 4.1.1 (Espaço Vetorial). *Um conjunto V é dito um **espaço vetorial** sobre $\mathbb{R}$ munido de adição e de multiplicação por escalar se possui as seguintes propriedades:*

- 1) Comutatividade da Adição:** $u + v = v + u, \forall u, v \in V$.
- 2) Associatividade:** $(u + v) + w = u + (v + w)$ e $(ab)v = a(bv), \forall u, v, w \in V$ e $\forall a, b \in \mathbb{R}$.
- 3) Identidade Aditiva:** Existe um elemento $0 \in V$ tal que $v + 0 = v, \forall v \in V$.
- 4) Inverso Aditivo:** Para todo $v \in V$, existe $w \in V$ tal que $v + w = 0$.
- 5) Identidade Multiplicativa:** $1v = v, \forall v \in V$.
- 6) Distributividade:** $a(u + v) = au + av$ e $(a + b)v = av + bv, \forall u, v \in V$ e $\forall a, b \in \mathbb{R}$.

Exemplo 4.1.2. *Alguns exemplos de espaços vetoriais são:*

- 1) O conjunto $\mathbb{R}^n = \left\{ \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} ; x_i \in \mathbb{R} \right\}$.
- 2) O conjunto $\mathbb{C}^n = \left\{ \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{bmatrix} ; z_i \in \mathbb{C} \right\}$.

$$3) \text{ O conjunto } \mathbb{M}^{m \times n} = \left\{ \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}; a_{ij} \in \mathbb{R} \right\}.$$

$$4) \text{ O conjunto } \mathbb{R}^{\mathbb{R}} = \{f : \mathbb{R} \rightarrow \mathbb{R}; f(x) \in \mathbb{R}\}.$$

$$5) \text{ O conjunto } \mathcal{P}_n = \{p \in \mathbb{R}^{\mathbb{R}}; \exists a_0, a_1, \dots, a_n \in \mathbb{R} \text{ t.q. } p(x) = a_0 + a_1x + a_2x^2 + \cdots + a_nx^n\}.$$

Tendo definido o conceito de espaço vetorial, nós podemos dar uma definição melhor de vetor:

Definição 4.1.3 (Definição precisa de vetor). *Seja V um espaço vetorial. Todo elemento $v \in V$ é chamado de **vetor**.*

Com esta definição, nós não precisamos ficar restritos a pensar nos vetores como listas de números. Eles são os elementos de um espaço vetorial, qualquer que seja este espaço. Assim sendo, uma lista de números pode ser um vetor, uma matriz pode ser um vetor, uma função pode ser um vetor, e assim por diante. Tudo depende da forma como o espaço é definido, e se os seus elementos cumprem os axiomas de espaço vetorial.

Para dar um exemplo de como se demonstra que um conjunto fechado sob adição e multiplicação por escalar é um espaço vetorial, vamos demonstrar que $\mathbb{R}^n$ é um espaço vetorial:

Proposição 4.1.4. *Seja $\mathbb{R}^n$ o conjunto conforme definido acima. Então, sob as operações usuais de adição e de multiplicação por escalar, $\mathbb{R}^n$ é um espaço vetorial.*

Demonstração. *Vamos demonstrar que $\mathbb{R}^n$ satisfaz todos os axiomas de espaço vetorial:*

$$1) \text{ **Comutatividade da adição:** Sejam } u = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix} \text{ e } v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} \text{ dois elementos de } \mathbb{R}^n.$$

Então:

$$u + v = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix} + \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} u_1 + v_1 \\ \vdots \\ u_n + v_n \end{bmatrix} = \begin{bmatrix} v_1 + u_1 \\ \vdots \\ v_n + u_n \end{bmatrix} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} + \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix} = v + u.$$

$$2) \text{ **Associatividade:** Sejam } u = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix}, v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} \text{ e } w = \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix} \text{ três elementos de } \mathbb{R}^n.$$

Então:

$$(u + v) + w = \begin{bmatrix} u_1 + v_1 \\ \vdots \\ u_n + v_n \end{bmatrix} + \begin{bmatrix} w_1 \\ \vdots \\ w_n \end{bmatrix} = \begin{bmatrix} u_1 + v_1 + w_1 \\ \vdots \\ u_n + v_n + w_n \end{bmatrix} = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix} + \begin{bmatrix} v_1 + w_1 \\ \vdots \\ v_n + w_n \end{bmatrix} = u + (v + w).$$

Sejam $a, b \in \mathbb{R}$. Então:

$$(ab)v = ab \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} abv_1 \\ \vdots \\ abv_n \end{bmatrix} = a \begin{bmatrix} bv_1 \\ \vdots \\ bv_n \end{bmatrix} = a(bv).$$

3) Identidade Aditiva: Sejam $0 \in \mathbb{R}^n$ definido por $0 = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$ e $v \in \mathbb{R}^n$ definido por $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$. Então:

$$v + 0 = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} + \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} = \begin{bmatrix} v_1 + 0 \\ \vdots \\ v_n + 0 \end{bmatrix} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = v.$$

4) Inverso Aditivo: Sejam $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$ e $w = \begin{bmatrix} -v_1 \\ \vdots \\ -v_n \end{bmatrix}$ dois elementos de $\mathbb{R}^n$. Então:

$$v + w = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} + \begin{bmatrix} -v_1 \\ \vdots \\ -v_n \end{bmatrix} = \begin{bmatrix} v_1 - v_1 \\ \vdots \\ v_n - v_n \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix} = 0.$$

5) Identidade Multiplicativa: Seja $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$ um elemento de $\mathbb{R}^n$. Então:

$$1v = 1 \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} 1v_1 \\ \vdots \\ 1v_n \end{bmatrix} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = v.$$

6) Distributividade: Sejam $u = \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix}$ e $v = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$ dois elementos de $\mathbb{R}^n$, e $a, b \in \mathbb{R}$.

Então:

$$a(u + v) = a \begin{bmatrix} u_1 + v_1 \\ \vdots \\ u_n + v_n \end{bmatrix} = \begin{bmatrix} a(u_1 + v_1) \\ \vdots \\ a(u_n + v_n) \end{bmatrix} = \begin{bmatrix} au_1 + av_1 \\ \vdots \\ au_n + av_n \end{bmatrix} = \begin{bmatrix} au_1 \\ \vdots \\ au_n \end{bmatrix} + \begin{bmatrix} av_1 \\ \vdots \\ av_n \end{bmatrix} = au + av.$$

$$(a + b)v = (a + b) \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} (a + b)v_1 \\ \vdots \\ (a + b)v_n \end{bmatrix} = \begin{bmatrix} av_1 + bv_1 \\ \vdots \\ av_n + bv_n \end{bmatrix} = \begin{bmatrix} av_1 \\ \vdots \\ av_n \end{bmatrix} + \begin{bmatrix} bv_1 \\ \vdots \\ bv_n \end{bmatrix} = av + bv$$

Logo, o conjunto $\mathbb{R}^n$ é um espaço vetorial.

□

4.2 Subespaços Vetoriais

Muitas vezes, no estudo de Álgebra Linear, nós não estamos preocupados com a análise do espaço inteiro, mas sim de um (ou mais) pedaços dele que seguem as mesmas regras de um espaço vetorial. Para fazer isso, nós vamos agora definir o conceito de subespaço vetorial:

Definição 4.2.1 (Subespaço Vetorial). *Um conjunto $U \subset V$ é dito um **subespaço vetorial** se, dados $u, v \in U$ e $\alpha, \beta \in \mathbb{R}$, então*

$$\alpha u + \beta v \in U.$$

Em outras palavras, um conjunto U contido em um espaço vetorial V é dito um subespaço se for fechado para combinações lineares. Uma facilidade de subespaços vetoriais é o fato de que, para demonstrar que um conjunto é um subespaço, basta demonstrar a propriedade do fechamento. De fato, se nós temos um subconjunto de um espaço vetorial, nós já sabemos que os 6 (ou 8, dependendo da contagem) axiomas de um espaço vetorial são necessariamente satisfeitos. Não é preciso demonstrar todos eles novamente, basta se preocupar com o fechamento sob combinações lineares.

Para dar alguns exemplos de subespaços vetoriais, vamos considerar o espaço que nós mais trabalharemos neste curso: o $\mathbb{R}^n$.

Exemplo 4.2.2. *Considere o espaço $\mathbb{R}^n$. Então, alguns dos seus subespaços são os conjuntos:*

- 1) *O conjunto $U = \{0\}$ (ou seja, a origem).*
- 2) *O conjunto $U = \{\alpha u; \alpha \in \mathbb{R}\}$ (ou seja, uma reta).*
- 3) *O conjunto $U = \{\alpha u + \beta v; \alpha, \beta \in \mathbb{R}\}$ (ou seja, um plano).*
- 4) *O conjunto $U = \{\alpha u + \beta v + \gamma w; \alpha, \beta, \gamma \in \mathbb{R}\}$ (ou seja, um hiperplano).*
- 5) *O conjunto $U = \mathbb{R}^n$ (ou seja, todo o espaço).*

Para dar um exemplo de demonstração, vamos demonstrar que uma reta em $\mathbb{R}^n$ é um subespaço de $\mathbb{R}^n$.

Proposição 4.2.3. *Seja $U = \{\alpha u; \alpha \in \mathbb{R}\}$ um subconjunto de $\mathbb{R}^n$. Então, U é um subespaço vetorial de $\mathbb{R}^n$.*

Demonstração. *Sejam x e y elementos de U . Então, $x = \alpha u$ e $y = \beta u$. Tomemos α' e β' dois escalares em $\mathbb{R}$. Então:*

$$\alpha' x + \beta' y = \alpha' \alpha u + \beta' \beta u = (\alpha' \alpha + \beta' \beta) u \in U.$$

Logo, U é um subespaço vetorial de $\mathbb{R}^n$.

□

4.3 Transformações Lineares

Nesta seção, nós iremos apresentar brevemente o conceito de transformação linear. Este é um dos conceitos mais importantes da Álgebra Linear, porque de fato, nós não queremos passar o tempo todo tentando provar que um conjunto é um espaço vetorial: nós queremos poder relacionar um ou mais espaços através de funções, e transformar vetores entre os espaços.

Por ser um conceito tão importante, nós dedicaremos um capítulo inteiro às transformações lineares, onde nós revisitaremos a sua definição e falaremos melhor das suas propriedades. Por agora, no entanto, nós faremos apenas a definição de transformação linear e daremos alguns exemplos:

Definição 4.3.1 (Transformação Linear). *Sejam U e V dois espaços vetoriais. Então, a função $T : U \rightarrow V$ é dita uma **transformação linear** se:*

$$1) T(x + y) = T(x) + T(y);$$

$$2) T(\alpha x) = \alpha T(x),$$

onde $x, y \in U$ e $\alpha \in \mathbb{R}$.

Exemplo 4.3.2. *Alguns exemplos de transformações lineares são:*

1) *Considere a transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ definida como $T(x) = Ax$, onde A é uma matriz $m \times n$. Então, T é uma transformação linear.*

2) *Considere a transformação $D : \mathcal{P}_n \rightarrow \mathcal{P}_n$ definida como $D(p) = p'$. Então, D é uma transformação linear.*

3) *Considere a transformação $I : \mathbb{R}^n \rightarrow \mathbb{R}^n$ definida como $I(x) = x$. Então, I é uma transformação linear.*

No futuro, nós falaremos melhor sobre este conceito, e também trataremos da demonstração de que uma transformação é linear. Penso, no entanto, que já é interessante apresentar o conceito de transformação linear por um motivo simples: matrizes são uma forma de representar transformações lineares, como nós veremos em breve. Assim sendo, quando nós falarmos, por exemplo, do espaço coluna de uma matriz, nós poderemos já pensar neste espaço como sendo a imagem da matriz, e quando nós falarmos do espaço nulo de uma matriz, nós já poderemos pensar neste espaço como sendo o núcleo de uma transformação linear.

4.4 Propriedades dos Subespaços Vetoriais

Nós vamos iniciar esta seção com um fato cuja demonstração será um dos exercícios: todo subespaço vetorial é um espaço vetorial. Isto é, de fato, bastante intuitivo pois, se um certo conjunto S , fechado sob combinações lineares, é formado por elementos de um espaço vetorial, muito provavelmente ele deve ser, por si só, um espaço vetorial.

Assim sendo, as propriedades comuns a todos os subespaços vetoriais que enunciaremos a seguir são válidas para qualquer espaço vetorial.

Proposição 4.4.1 (Elemento neutro). *Todo subespaço vetorial contém o vetor 0.*

Demonstração. *Seja U um subespaço vetorial de V . Então, tomando $u \in U$ e $\alpha \in \mathbb{R}$, nós temos que $\alpha u \in U$. Assim sendo, tome $\alpha = 0$. Então, $0u = 0 \in U$. Logo, $0 \in U$.* □

Proposição 4.4.2 (Interseção e união de dois subespaços vetoriais). *Sejam V e W dois subespaços vetoriais de E . Então:*

a) *$V \cap W$ é um subespaço vetorial;*

b) *$V \cup W$ nem sempre é um subespaço vetorial.*

Demonstração. a) *Sejam v e w dois elementos de $V \cap W$. Então, nós temos que $v \in V$ e $v \in W$. Também temos que $w \in V$ e $w \in W$. Assim sendo, $\alpha v + \beta w \in V$ (pois V é um subespaço vetorial) e $\alpha v + \beta w \in W$ (pois W é um subespaço vetorial). Logo, $\alpha v + \beta w \in V \cap W$ (pela definição de interseção entre conjuntos). Logo, $V \cap W$ é um subespaço vetorial.*

b) Para demonstrar que há casos em que $V \cup W$ não é um subespaço vetorial, basta encontrar um contra-exemplo. Assim sendo, considere $u \in \mathbb{R}^n$, e tome $V = \{\alpha u; \alpha \in \mathbb{R}\}$ e $W = \{\beta u; \beta \in \mathbb{R} \text{ e } \beta \neq \alpha\}$. Ao tomarmos o vetor $v = (\alpha + \beta)u$, que é uma combinação linear de um vetor em V com um vetor em W , nós temos que v não pertence a V nem a W , a menos que $\alpha = 0$ ou $\beta = 0$. Logo, nem sempre $V \cup W$ é um subespaço vetorial. $\square$

Para as próximas duas propriedades, nós definiremos um conjunto especial de vetores que será muito importante ao longo do curso.

Definição 4.4.3 (*span*). Seja $S = \{v_1, v_2, \dots, v_k\}$ um conjunto de elementos de um subespaço vetorial V . Então, definimos o conjunto **span** como:

$$\text{span}(S) = \{\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_k v_k; \alpha_i \in \mathbb{R}\}.$$

De forma resumida, $\text{span}(S)$ é o conjunto de todas as combinações lineares dos elementos de S . Para dar um exemplo, considere que $S = \{e_1, e_2, e_3\}$, onde cada e_i é um dos vetores canônicos de $\mathbb{R}^3$. Então, $\text{span}(S) = \{\alpha_1 e_1 + \alpha_2 e_2 + \alpha_3 e_3; \alpha_i \in \mathbb{R}\}$. Ou seja, $\text{span}(S) = \mathbb{R}^3$.

Intuitivamente, parece-nos que este conjunto especial é um subespaço vetorial. De fato, ele é, e nós o provamos agora, e também demonstraremos uma propriedade especial do conjunto gerador (*span* significa gerador em inglês).

Proposição 4.4.4. Seja $S = \{v_1, v_2, \dots, v_k\}$ um conjunto de vetores de um subespaço vetorial V . Então, $\text{span}(S)$ é um subespaço vetorial de V .

Demonstração. Sejam u e v dois elementos de $\text{span}(S)$, e sejam $\alpha, \beta \in \mathbb{R}$. Nós queremos provar que $\alpha u + \beta v \in \text{span}(S)$. Para isto, nós sabemos que existem $a_1, a_2, \dots, a_k \in \mathbb{R}$ e $b_1, b_2, \dots, b_k \in \mathbb{R}$ tais que $u = \sum_{i=1}^k a_i v_i$ e $v = \sum_{i=1}^k b_i v_i$. Assim sendo:

$$\begin{aligned} \alpha u + \beta v &= \alpha \sum_{i=1}^k a_i v_i + \beta \sum_{i=1}^k b_i v_i = \sum_{i=1}^k \alpha a_i v_i + \sum_{i=1}^k \beta b_i v_i \\ &= \sum_{i=1}^k (\alpha a_i v_i + \beta b_i v_i) = \sum_{i=1}^k (\alpha a_i + \beta b_i) v_i \in \text{span}(S). \end{aligned}$$

Logo, $\text{span}(S)$ é um subespaço vetorial de V . $\square$

Proposição 4.4.5. Seja $S = \{v_1, v_2, \dots, v_k\}$ um conjunto de vetores de um subespaço vetorial V . Então, $\text{span}(S)$ é o menor subespaço vetorial que contém S .

Demonstração. Em primeiro lugar, vamos conferir o fato de que $S \subseteq \text{span}(S)$. De fato, se tomarmos $\alpha_i = 1$ e $\alpha_j = 0$ para todo $i \neq j$ na definição de $\text{span}(S)$, nós concluímos que $S \subseteq \text{span}(S)$.

Agora, precisamos provar que $\text{span}(S)$ é o menor subespaço vetorial que contém S . Ou seja, precisamos provar que, dado qualquer subespaço vetorial V tal que $S \subseteq V$, nós temos que $\text{span}(S) \subseteq V$.

Isto segue do fato que, se $S \subseteq V$, então $\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_k v_k \in V, \forall \alpha_i \in \mathbb{R}$. Porém, $\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_k v_k \in \text{span}(S)$, pela definição. Logo, $\text{span}(S) \subseteq V$. $\square$

4.5 Núcleo e Imagem de uma Matriz

Considere uma matriz $A_{m \times n}$ qualquer. Como nós vimos (mas ainda não demonstramos), nós podemos pensar em A como uma transformação linear definida por:

$$\begin{aligned} A : \mathbb{R}^n &\rightarrow \mathbb{R}^m \\ x &\mapsto Ax \end{aligned}$$

Isto quer dizer que uma matriz $m \times n$ é uma forma de representar uma função linear entre dois espaços vetoriais, em que $\mathbb{R}^n$ é o domínio e $\mathbb{R}^m$ é o contra-domínio da função. Por sua vez, quando nós estamos trabalhando com funções, muitas vezes nós estamos interessados em analisar subconjuntos específicos do domínio e do contradomínio.

O exemplo mais famoso e clássico deste fato é a imagem, que nada mais é do que um subconjunto do contradomínio cujos elementos são aqueles que foram associados a pelo menos um valor do domínio. Um outro conjunto que costuma ser muito importante, muito embora menos falado, é o conjunto dos zeros de uma função, que consiste em todos os valores do domínio para os quais a função, avaliada nestes valores, é igual a zero.

Em Álgebra Linear não é diferente: nós estamos interessados também em estudar subconjuntos específicos das transformações lineares que fazem exatamente este papel: a imagem (que chamaremos, no caso das matrizes, de espaço coluna) e o núcleo (que corresponde ao conjunto dos zeros da transformação linear/matriz).

Definição 4.5.1 (Núcleo de uma matriz). *Seja A uma matriz $m \times n$ qualquer. Então, chamamos de **núcleo** da matriz A ao conjunto:*

$$N(A) = \{x \in \mathbb{R}^n; Ax = 0\}.$$

Uma outra notação bastante comum para o núcleo de uma matriz A é $\ker(A)$ (que vem da palavra *kernel*).

Definição 4.5.2 (Imagem de uma matriz). *Seja A uma matriz $m \times n$ qualquer. Então, chamamos de **imagem**, ou **espaço coluna** da matriz A ao conjunto:*

$$C(A) = \{Ax \in \mathbb{R}^m; x \in \mathbb{R}^n\}.$$

Para o espaço coluna, uma outra notação pode ser $\text{Im}(A)$, em referência à sua visão enquanto imagem de uma transformação linear.

No capítulo sobre Transformações Lineares, nós iremos revisar estes conceitos, estendendo-os para transformações lineares em geral. Via de regra, nestas notas de aula, quando falarmos em espaço coluna, nós estaremos olhando para o aspecto matricial, enquanto quando falarmos em imagem, enfatizaremos o aspecto funcional.

A primeira coisa importante sobre estes dois conjuntos é o fato de que ambos são subespaços vetoriais.

Proposição 4.5.3. *Seja A uma matriz $m \times n$ qualquer. Então, $N(A)$ é um subespaço vetorial.*

Demonstração. Sejam x e y dois elementos pertencentes a $N(A)$. Então, sabemos que $Ax = 0$ e que $Ay = 0$. Sabemos também que, pela definição, $N(A) \subseteq \mathbb{R}^n$. Considere então $\alpha, \beta \in \mathbb{R}$. Sabendo que A é linear, vamos ver o que acontece com $\alpha x + \beta y$:

$$A(\alpha x + \beta y) = A(\alpha x) + A(\beta y) = \alpha(Ax) + \beta(Ay) = \alpha \cdot 0 + \beta \cdot 0 = 0 + 0 = 0.$$

Logo, $\alpha x + \beta y \in N(A)$, logo $N(A)$ é um subespaço vetorial de $\mathbb{R}^n$. □

Proposição 4.5.4. Seja A uma matriz $m \times n$ qualquer. Então, $C(A)$ é um subespaço vetorial.

Demonstração. Sejam u e v dois elementos de $C(A)$. Então, pela definição, existem $x, y \in \mathbb{R}^n$ tais que $u = Ax$ e $v = Ay$. Sabemos também, pela definição, que $C(A) \subseteq \mathbb{R}^m$. Assim sendo, considere $\alpha, \beta \in \mathbb{R}$ quaisquer. Calculemos $\alpha u + \beta v$:

$$\alpha u + \beta v = \alpha(Ax) + \beta(Ay) = A(\alpha x) + A(\beta y) = A(\alpha x + \beta y) \in C(A).$$

Logo, $C(A)$ é um subespaço vetorial de $\mathbb{R}^m$. □

O motivo pelo qual damos o nome de “espaço coluna” para a imagem de uma matriz A é o fato de que $C(A)$ é o espaço vetorial criado com todas as combinações lineares das colunas de A (ou, em linguagem matemática, $C(A) = \text{span}(\{a_1, \dots, a_n\})$).

Daí decorre uma propriedade que é extremamente óbvia, mas que nós demonstraremos aqui:

Proposição 4.5.5. Sejam A uma matriz $m \times n$ e b um vetor $m \times 1$. Então, o sistema $Ax = b$ possui solução se, e somente se, $b \in C(A)$.

Demonstração. $\implies$ Suponha que o sistema $Ax = b$ possui solução. Então, existe um vetor $x \in \mathbb{R}^n$ tal que $Ax = b$. No entanto, sabemos que $Ax = x_1 a_1 + x_2 a_2 + \dots + x_n a_n$. Ou seja, $Ax \in \text{span}(\{a_1, \dots, a_n\})$. Logo, $b \in \text{span}(\{a_1, \dots, a_n\})$. Porém, como nós vimos, $C(A) = \text{span}(\{a_1, \dots, a_n\})$. Logo, $b \in C(A)$.

$\impliedby$ Suponha que $b \in C(A)$. Então, b pode ser escrito como $b = x_1 a_1 + \dots + x_n a_n = Ax$. Logo, existe $x \in \mathbb{R}^n$ tal que $Ax = b$. Assim sendo, o sistema $Ax = b$ possui solução. □

Agora, vamos dar alguns exemplos simples do núcleo de uma matriz.

Exemplo 4.5.6. Considere a matriz $A = \begin{bmatrix} 2 & 1 \\ 4 & 2 \end{bmatrix}$. Queremos achar todos os vetores x tais que $Ax = 0$. Assim sendo, considere $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$. Nós obtemos o seguinte sistema linear:

$$\begin{bmatrix} 2 & 1 \\ 4 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \iff \begin{bmatrix} 2 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \iff 2x_1 + x_2 = 0.$$

Ou seja, $N(A) = \{(x_1, x_2)^T; 2x_1 + x_2 = 0\}$. Também podemos escrever x_2 em função de x_1 , obtendo $x_2 = -2x_1$. Fazendo isso, podemos considerar um vetor qualquer que satisfaça esta equação, como por exemplo $x = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$, e dizer que $N(A) = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ -2 \end{bmatrix} \right\} \right)$.

Exemplo 4.5.7. Considere a matriz $A = \begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix}$. Nós queremos achar todos os vetores x tais que $Ax = 0$. Nós temos que:

$$\begin{bmatrix} 3 & 1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \iff x_1 = x_2 = 0.$$

$$\text{Logo, } N(A) = \left\{ \begin{bmatrix} 0 \\ 0 \end{bmatrix} \right\}.$$

O primeiro exemplo nos motiva uma discussão interessante. Suponha que $A = LU$. Neste caso, nós estamos considerando uma espécie de “fatoração LU estendida”, em que a matriz U pode conter linhas inteiras de zeros. Neste caso:

$$Ax = 0 \iff LUX = 0 \iff UX = 0.$$

Ou seja, $N(A) = N(U)$.

Por outro lado, não é verdade que $C(A) = C(U)$. Suponha que $Ax = b$, com $b \neq 0$. Então, $LUX = b \iff UX = L^{-1}b = c$. Assim sendo, $C(A) \neq C(U)$.

Ainda nos referindo ao primeiro exemplo desta seção ($A = \begin{bmatrix} 2 & 1 \\ 4 & 2 \end{bmatrix}$ com $U = \begin{bmatrix} 2 & 1 \\ 0 & 0 \end{bmatrix}$), nós temos que:

$$C(A) = \text{span} \left(\left\{ \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \right) = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \right)$$

(lembre-se que $(2, 4)^T = 2(1, 2)^T$). Por outro lado,

$$C(U) = \text{span} \left(\left\{ \begin{bmatrix} 2 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\} \right) = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix} \right\} \right).$$

Logo, $C(A) \neq C(U)$.

4.6 Forma Escalonada de uma Matriz

Considere agora uma matriz $A_{m \times n}$ qualquer. Estamos ainda interessados no problema de encontrar o núcleo de A . Como nós vimos na seção anterior, dada uma qualquer $B_{n \times n}$, se U é a matriz triangular superior resultante do processo de eliminação de B , então $N(B) = N(U)$ (lembrando que, neste caso, nós estamos considerando que a fatoração LU pode ser estendida para o caso em que B não é invertível).

Por sua vez, suponha que nós aplicamos o processo de eliminação à matriz A . Como A não é uma matriz quadrada, nós não encontraremos uma matriz triangular superior no final. No entanto, nós poderemos encontrar uma certa matriz U que muito parecida com uma matriz triangular superior, embora seja retangular. Também neste caso, é verdade que $N(A) = N(U)$. Vamos fazer um exemplo para enxergar melhor esta situação:

Exemplo 4.6.1. Seja $A = \begin{bmatrix} 1 & 2 & 2 & 2 \\ 2 & 4 & 6 & 8 \\ 3 & 6 & 8 & 10 \end{bmatrix}$. Aplicando os passos da eliminação, nós obtemos:

$$A \xrightarrow[L_3-3L_1]{L_2-2L_1} \begin{bmatrix} 1 & 2 & 2 & 2 \\ 0 & 0 & 2 & 4 \\ 0 & 0 & 2 & 4 \end{bmatrix} \xrightarrow{L_3-L_2} \begin{bmatrix} 1 & 2 & 2 & 2 \\ 0 & 0 & 2 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix} = U.$$

Usando este exemplo, nós temos que a matriz A possui dois pivôs: 1 e 2. Na matriz U , eles estão, respectivamente, na primeira e na terceira colunas. Nós podemos continuar o processo de eliminação a partir de U de modo que todos os pivôs sejam iguais a 1 e que todos os elementos acima dos pivôs sejam iguais a 0. No nosso exemplo, nós podemos continuar este processo da seguinte forma:

$$U \xrightarrow{L_2/2} \begin{bmatrix} 1 & 2 & 2 & 2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix} \xrightarrow{L_1-2L_2} \begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix} = R$$

Esta matriz R recebe um nome especial, que definiremos a seguir:

Definição 4.6.2 (Forma escalonada reduzida). *Seja A uma matriz $m \times n$ qualquer. Suponha que, ao aplicar o processo de eliminação a A , nós obtemos uma certa matriz U com k pivôs e, em seguida, nós continuamos o processo de eliminação de modo a tornar cada um dos pivôs igual a 1 e a produzir zeros nos elementos acima dos pivôs, obtendo, ao final, uma matriz R . A esta matriz R nós damos o nome de **forma escalonada reduzida** de A .*

Nós ainda podemos fazer permutações de colunas, de modo a obter uma forma especial para R . No nosso exemplo, isto é feito da seguinte forma:

$$R \xrightarrow{C_2 \leftrightarrow C_3} \begin{bmatrix} 1 & 0 & 2 & -2 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} I & F \\ 0 & 0 \end{bmatrix} = R'.$$

O que torna R' especial é a sua estrutura: ela é uma matriz por blocos, cujas primeiras colunas contêm os pivôs, e cujas últimas colunas não possuem pivôs.

Nós damos nomes especiais a estes tipos de colunas: uma coluna com pivô é chamada de **coluna pivô** e uma coluna sem pivô é chamada de **coluna livre**.

A grande importância do que estamos fazendo se deve ao seguinte fato:

Proposição 4.6.3. *Seja A uma matriz $m \times n$ qualquer, e R a sua forma escalonada reduzida. Então, $N(A) = N(R)$.*

Demonstração. *Seja E a matriz $m \times m$ tal que $EA = R$. Então, nós temos que:*

$$Ax = 0 \iff EAx = E0 \iff (EA)x = 0 \iff Rx = 0.$$

Logo, $N(A) = N(R)$. □

Assim sendo, nós podemos encontrar o núcleo de A resolvendo o sistema linear $Rx = 0$. No nosso exemplo, isto equivale a:

$$\begin{bmatrix} 1 & 2 & 0 & -2 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Isto equivale ao seguinte sistema de equações:

$$\begin{cases} x_1 + 2x_2 + 0x_3 - 2x_4 = 0 \\ x_3 + 2x_4 = 0 \end{cases}.$$

Como se pode perceber facilmente, este sistema possui infinitas soluções. Assim sendo, se nós queremos achar vetores no núcleo, é conveniente utilizar uma escolha que facilite os cálculos. Uma boa escolha é colocar 1 em uma das variáveis livres e 0 nas outras variáveis livres, repetindo este processo até termos colocado 1 em todas as variáveis livres.

No nosso exemplo, isto equivale a:

1) Colocando 1 na primeira variável livre e 0 nas outras (ou seja, $x_2 = 1$ e $x_4 = 0$):

$$\begin{cases} x_1 + 2 = 0 \\ x_3 = 0 \end{cases} \implies \begin{cases} x_1 = -2 \\ x_3 = 0 \end{cases}$$

2) Colocando 1 na segunda variável livre e 0 nas outras (ou seja, $x_4 = 1$ e $x_2 = 0$):

$$\begin{cases} x_1 - 2 = 0 \\ x_3 + 2 = 0 \end{cases} \implies \begin{cases} x_1 = 2 \\ x_3 = -2 \end{cases}$$

Do primeiro caso, nós obtivemos o vetor $\begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}$. Do segundo caso, nós obtivemos o vetor $\begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix}$. Assim sendo, nós concluímos que:

$$N(A) = N(R) = \text{span} \left(\left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 2 \\ 0 \\ -2 \\ 1 \end{bmatrix} \right\} \right).$$

A partir deste exemplo, vamos construir uma matriz especial que facilitará profundamente os nossos cálculos. Considere $N = \begin{bmatrix} -2 & 2 \\ 1 & 0 \\ 0 & -2 \\ 0 & 1 \end{bmatrix}$. Fazendo a permutação das linhas 2 e 3, nós obtemos:

$$N' = \begin{bmatrix} -2 & 2 \\ 0 & -2 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Compare a matriz N' com a matriz R' . As duas primeiras linhas de N' formam exatamente a matriz $-F$. Assim sendo, nós podemos fazer a seguinte definição:

Definição 4.6.4 (Matriz núcleo). *Sejam $A_{m \times n}$ uma matriz qualquer, R a sua forma escalonada reduzida e R' a matriz em blocos formada após as permutações necessárias*

das colunas de R . Se nós definimos N' como $N' = \begin{bmatrix} -F \\ I \end{bmatrix}$, então a **matriz núcleo** N é definida como:

$$N = PN',$$

onde P é a matriz de permutação que troca as linhas de N correspondentes às colunas de R que foram permutadas.

A matriz núcleo recebe este nome por um motivo muito simples: os seus vetores-coluna geram o núcleo de A . Então, se nós queremos encontrar o núcleo de uma matriz A , nós podemos simplesmente encontrar a sua forma escalonada reduzida R , e montar a matriz núcleo N .

Vamos fazer mais um exemplo:

Exemplo 4.6.5. Seja $A = \begin{bmatrix} 1 & 2 & 3 \end{bmatrix}$. Então, nós temos que A já está na forma escalonada reduzida R e também que, neste caso, $R = R'$. Assim sendo, o único pivô de A está na primeira coluna, e as outras duas colunas são colunas livres. Nós temos, neste caso, que $F = \begin{bmatrix} 2 & 3 \end{bmatrix}$. Assim sendo, a matriz núcleo N , que neste caso é igual a N' , é dada por:

$$N = \begin{bmatrix} -F \\ I \end{bmatrix} = \begin{bmatrix} -2 & -3 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Assim sendo, nós temos que:

$$N(A) = \text{span} \left(\left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix} \right\} \right).$$

Algo importante que este exemplo nos mostra é o fato de que a matriz identidade da matriz N' não é a mesma matriz que aparece em R' . E de fato, para que todas as contas que nós fizemos até agora sejam válidas, é necessário que todas as matrizes que compõem R' e N' sejam dimensionalmente compatíveis.

Assim sendo, seja r o número de pivôs de A (que ganhará uma definição própria mais adiante). Nós temos que o número de colunas livres é dado por $n - r$. Desta forma, nós temos que:

$$R' = \begin{bmatrix} I_{r \times r} & F_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{bmatrix}$$

$$N' = \begin{bmatrix} -F_{r \times (n-r)} \\ I_{(n-r) \times (n-r)} \end{bmatrix}.$$

Para terminar esta seção, vamos falar sobre um tipo especial de matrizes. Suponha que A é uma matriz $m \times n$ tal que $r = 1$. Neste caso, nós temos que toda coluna é um múltiplo da coluna pivô, e que toda linha é um múltiplo da linha pivô. Assim sendo, nós podemos escrever $A = uv^T$, em que $u \in \mathbb{R}^m$ e $v \in \mathbb{R}^n$. Uma matriz deste tipo é chamada de **matriz de posto 1**.

Uma propriedade deste tipo de matrizes é a seguinte:

Proposição 4.6.6. Seja $A_{m \times n}$ uma matriz tal que $A = uv^T$, onde $u \in \mathbb{R}^m$ e $v \in \mathbb{R}^n$. Então, $N(A) = \{x \in \mathbb{R}^n; v^T x = 0\}$.

Demonstração. Queremos achar todos os vetores $x \in \mathbb{R}^n$ tais que $Ax = 0$. Nós temos que:

$$Ax = 0 \iff (uv^T)x = 0 \iff u(v^Tx) = 0 \iff v^Tx = 0.$$

Logo, $N(A) = \{x \in \mathbb{R}^n; v^Tx = 0\}$.

□

4.7 Soluções de Sistemas Lineares

Vamos voltar agora à discussão do problema fundamental. Dado um sistema linear $Ax = b$, onde A é uma matriz $m \times n$, nós queremos se existem e quais são as soluções do sistema. E, para a discussão das condições de existência, nós podemos montar um critério rápido baseado na forma escalonada reduzida de A .

Dado um sistema linear $Ax = b$, podemos seguir o seguinte passo a passo:

- 1) Montar a matriz aumentada $\begin{bmatrix} A & b \end{bmatrix}$;
- 2) Fazer as eliminações e as permutações, transformando-a em $\begin{bmatrix} R' & c \end{bmatrix}$
- 3) Zerar os elementos de c que correspondem às linhas de zeros de R' .

Ao executar este último passo, as condições para a existência de x tal que $Ax = b$ aparecem naturalmente. De uma maneira mais explícita, suponha que, após o passo 2, nós obtivemos o sistema $R'x = c$, descrito em blocos da seguinte forma:

$$\begin{bmatrix} I & F \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_r \\ x_{n-r} \end{bmatrix} = \begin{bmatrix} c_r \\ c_{m-r} \end{bmatrix}.$$

Realizando a multiplicação do lado esquerdo da equação, nós obtemos:

$$\begin{bmatrix} x_r + Fx_{n-r} \\ 0 \end{bmatrix} = \begin{bmatrix} c_r \\ c_{m-r} \end{bmatrix},$$

de modo que:

$$\begin{cases} x_r + Fx_{n-r} = c_r \\ c_{m-r} = 0 \end{cases}.$$

Isto nos dá um método para achar uma **solução particular** de $Ax = b$, caso a condição $c_{m-r} = 0$ seja satisfeita. Para acharmos tal solução particular, basta escolher $x_{n-r} = 0$, obtendo $x_r = c_r$. Assim sendo, podemos dizer que x_p é uma solução particular de $Ax = b$ definindo:

$$x_p = \begin{bmatrix} c_r \\ 0 \end{bmatrix}.$$

A partir desta ideia de solução particular, nós temos um importante resultado:

Teorema 4.7.1. *Seja $Ax = b$ um sistema linear possível. Então, toda solução de $Ax = b$ pode ser escrita como $x = x_p + x_n$, onde x_p é uma solução particular e $x_n \in N(A)$.*

Demonstração. *Seja x qualquer outra solução de $Ax = b$. Nós já sabemos que $Ax_p = b$. Assim sendo, nós temos que:*

$$A(x - x_p) = Ax - Ax_p = b - b = 0.$$

Logo, $x - x_p \in N(A)$. Ou seja, existe $x_n \in N(A)$ tal que $x_n = x - x_p$, e portanto, $x = x_p + x_n$. □

De um modo geral, se $n_1, n_2, \dots, n_{n-r}$ são as colunas da matriz núcleo N de A , nós temos que $x_n = \alpha_1 n_1 + \alpha_2 n_2 + \dots + \alpha_{n-r} n_{n-r}$, o que implica que:

$$x = x_p + \alpha_1 n_1 + \alpha_2 n_2 + \dots + \alpha_{n-r} n_{n-r}.$$

Cada vetor n_i é chamado de **solução especial** do sistema. Por sua vez, o vetor x_n , escrito desta forma, é chamado de **solução geral** do sistema, e o vetor x , composto pela soma da solução particular com a solução geral, é chamado de **solução completa** do sistema.

4.8 Exercícios

Importante: alguns dos exercícios são baseados em (2), em (6) e em (7).

4.1) Demonstre que o conjunto $\mathbb{C}^n$, munido das operações de soma e de multiplicação por escalar usuais, é um espaço vetorial.

4.2) Demonstre que o conjunto $\mathbb{R}^{\mathbb{R}}$, munido das operações de soma e de multiplicação por escalar usuais, é um espaço vetorial.

4.3) Demonstre que o conjunto $\mathcal{P}_n$, munido das operações usuais de soma e de multiplicação por escalar, é um subespaço vetorial de $\mathbb{R}^{\mathbb{R}}$.

4.4) Seja A uma matriz $m \times n$ qualquer. Demonstre que a transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ definida por $T(x) = Ax$ é linear.

4.5) Seja A uma matriz $m \times n$, e considere o conjunto

$$S = \{x \in \mathbb{R}^n; Ax = b\}.$$

Prove que, se $b \neq 0$, então S não é um subespaço vetorial.

4.6) Sejam b_1, b_2 e b_3 três vetores diferentes em $\mathbb{R}^m$. Como podemos construir uma matriz $A_{m \times n}$ tal que $Ax = b_1$ e $Ax = b_2$ tenham solução, mas $Ax = b_3$ não tenha? Isto é sempre possível?

4.7) Determine o núcleo e o espaço coluna de $A = \begin{bmatrix} 2 & 5 & 8 \\ 4 & 7 & 10 \\ 8 & 14 & 20 \end{bmatrix}$.

4.8) Considere a decomposição $A = S + T$, onde S é uma matriz simétrica e T é uma matriz antissimétrica. Prove que, se $x \in N(A)$, então $x \in N(S)$ se, e somente se $x \in N(T)$.

4.9) Sejam S e T dois subespaços de um espaço vetorial V .

a) Defina $S + T = \{s + t; s \in S \text{ e } t \in T\}$. Mostre que $S + T$ é um subespaço vetorial.

b) Defina $S \cup T = \{x; x \in S \text{ ou } x \in T\}$. Prove que $S \cup T$ é um subespaço vetorial se, e somente se, $S \subseteq T$ ou $T \subseteq S$.

c) Se S e T são retas em $\mathbb{R}^3$, o que são $S + T$ e $S \cup T$?

4.10) Sejam A uma matriz $m \times n$ e P uma matriz de permutação $m \times m$. Prove que $N(A) = N(PA)$.

4.11) Sejam A uma matriz $m \times n$ e P uma matriz de permutação $n \times n$. Mostre que, em geral, $N(A) \neq N(AP)$. Qual é a relação correta entre $N(A)$ e $N(AP)$? Em quais casos se tem $N(A) = N(AP)$?

4.12) Como o núcleo $N(C)$ é relacionado aos núcleos $N(A)$ e $N(B)$, onde $C = \begin{bmatrix} A \\ B \end{bmatrix}$?

4.13) Considere a matriz

$$A = \begin{bmatrix} 1 & 5 & 7 & 9 \\ 0 & 4 & 1 & 7 \\ 2 & -2 & 11 & -3 \end{bmatrix}.$$

a) Ache a sua forma escalonada reduzida.

b) Encontre uma solução especial para $Ax = 0$.

c) Seja x_p uma solução particular de $Ax = b$. Qual é a solução completa do sistema?

4.14) Se $A_{4 \times 4}$ é uma matriz inversível, descreva todos os vetores no núcleo da matriz $B = \begin{bmatrix} A & A \end{bmatrix}$ (que é 4×8)?

4.15) Sejam $A = \begin{bmatrix} 1 & 5 & 10 & 4 \\ 2 & 3 & 2 & 8 \\ 4 & 8 & 7 & 1 \end{bmatrix}$, $x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix}$ e $b = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$. Quais condições precisam ser satisfeitas para que o sistema $Ax = b$ possua solução?

4.16) Seja $A = \begin{bmatrix} 1 & 2 \\ 3 & 8 \end{bmatrix}$. Qual é o núcleo de $B = \begin{bmatrix} A \\ 2A \end{bmatrix}$? E qual é o núcleo de $C = \begin{bmatrix} A & 2A \end{bmatrix}$?

4.17) Suponha que $Ax = b$ e $Cx = b$ tenham as mesmas soluções completas para todo b . Podemos concluir que $A = C$?

4.18) Seja A uma matriz $m \times n$ qualquer. Demonstre que os vetores-coluna da matriz núcleo N geram $N(A)$.

Capítulo 5

Os Quatro Subespaços Fundamentais

Importante: este capítulo é baseado em (6).

Neste capítulo, nós iremos desenvolver mais profundamente os conceitos relacionados a espaços vetoriais, e apresentar os quatro subespaços fundamentais de uma matriz. Além disso, nós iremos enunciar um teorema muito importante, que os relaciona entre si: o Teorema do Posto (que será generalizado no próximo capítulo para toda transformação linear).

5.1 Posto de uma Matriz

No capítulo anterior, nós definimos um número r como o número de pivôs de uma matriz A . Agora, nós formalizaremos esta noção, e a utilizaremos para falar sobre o número de soluções de um sistema linear.

Definição 5.1.1 (Posto). *Seja A uma matriz $m \times n$ qualquer com r pivôs. Ao número r se dá o nome de **posto** (ou **rank**) da matriz A .*

Uma consequência imediata desta definição é a seguinte desigualdade:

Proposição 5.1.2. *Seja A uma matriz $m \times n$ de posto r . Então:*

$$r \leq \min\{m, n\}.$$

Para os casos em que ocorre uma igualdade, a matriz A recebe nomes especiais com relação ao posto:

Definição 5.1.3 (Posto completo nas colunas). *Seja A uma matriz $m \times n$ de posto r . Se $r = n$, nós dizemos que A tem **posto completo nas colunas**.*

Definição 5.1.4 (Posto completo nas linhas). *Seja A uma matriz $m \times n$ de posto r . Se $r = m$, nós dizemos que A tem **posto completo nas linhas**.*

É interessante analisar as consequências de uma matriz A possuir posto completo nas colunas ou nas linhas. Se A possui posto completo nas colunas, então todas as colunas são pivôs, e o sistema possui 0 ou 1 solução, dependendo de b . Por sua vez, se A possui posto completo nas linhas, então todas as linhas são pivôs, e o sistema possui infinitas soluções, independente de b .

Também é interessante analisar a relação entre o posto e a forma escalonada reduzida (com permutações) de A . De fato, dado que o processo de escalonamento e, depois,

as permutações em R , revelam uma certa estrutura, é esperado que tal estrutura varie conforme a completude do posto.

Se A é uma matriz quadrada com posto completo (ou seja, $r = n = m$), então:

$$R' = I$$

. Consequentemente, neste caso, $N(A) = \{0\}$ e $C(A) = \mathbb{R}^n$.

Se A é uma matriz $m \times n$ com posto completo nas colunas (ou seja, $r = n < m$), então:

$$R' = \begin{bmatrix} I_{n \times n} \\ 0_{(m-n) \times n} \end{bmatrix}$$

Consequentemente, neste caso, $N(A) = \{0\}$ e as linhas de zeros restringem $C(A)$.

Se A é uma matriz $m \times n$ com posto completo nas linhas (ou seja, $r = m < n$), então:

$$R' = \begin{bmatrix} I_{m \times m} & F_{m \times (n-m)} \end{bmatrix}$$

Consequentemente, neste caso, $N' = \begin{bmatrix} -F \\ I \end{bmatrix}$ e $C(A) = \mathbb{R}^m$.

No caso geral, se A é uma matriz $m \times n$, com $r < m$ e $r < n$, então:

$$R' = \begin{bmatrix} I_{r \times r} & F_{r \times (n-r)} \\ 0_{(m-r) \times r} & 0_{(m-r) \times (n-r)} \end{bmatrix}$$

Consequentemente, neste caso, $N' = \begin{bmatrix} -F \\ I \end{bmatrix}$ e $C(A)$ é restringido pelas linhas de zeros de R' .

5.2 Os Quatro Subespaços Fundamentais

Tendo definido o conceito de posto, nós estamos prontos para dizer quais são os quatro subespaços fundamentais de uma matriz. Dois deles nós já conhecemos: são o espaço coluna e o núcleo. Os outros dois nós definiremos a seguir:

Definição 5.2.1 (Quatro subespaços fundamentais). *Seja A uma matriz $m \times n$ qualquer. Então, os **quatro subespaços fundamentais** associados a A são:*

- 1) $C(A) = \{Ax \in \mathbb{R}^m; x \in \mathbb{R}^n\}$ (*espaço coluna*);
- 2) $N(A) = \{x \in \mathbb{R}^n; Ax = 0\}$ (*núcleo*);
- 3) $C(A^T) = \{A^T y \in \mathbb{R}^n; y \in \mathbb{R}^m\}$ (*espaço linha*);
- 4) $N(A^T) = \{y \in \mathbb{R}^m; A^T y = 0\}$ (*núcleo à esquerda*).

Eles são chamados de subespaços fundamentais porque, juntos, descrevem toda a estrutura de uma matriz, e também porque estão relacionados entre si de uma maneira que nós ainda veremos.

Uma pequena observação sobre o núcleo à esquerda é o fato de que $A^T y = (y^T A)^T$. Sabemos que $A^T y$ é uma combinação linear das linhas de A . Assim sendo, $A^T y = 0 \iff y^T A = 0$. Por isso, $N(A^T)$ é chamado de núcleo à esquerda.

Muito em breve, nós desenvolveremos muitos conceitos e teoremas que se baseiam fortemente nos quatro subespaços fundamentais de uma matriz. No entanto, para que nós possamos chegar a este ponto, precisamos dar um passo atrás e entender alguns conceitos que são comuns a todos os espaços e subespaços vetoriais. Nós faremos isto nas próximas seções, e depois retomaremos a discussão sobre os subespaços fundamentais.

5.3 Base de um Espaço Vetorial

Quando nós discutimos o conceito de posto, nós estávamos preocupados em entender qual é a relação do número de pivôs de uma matriz com o número de soluções de um sistema linear associado a ela. Porém, o que exatamente produz um pivô? Ou melhor, o que exatamente produz a falta de um pivô?

Vamos analisar um exemplo simples. Considere a matriz $A = \begin{bmatrix} 1 & 3 \\ 2 & 6 \end{bmatrix}$. Ao fazer o processo de eliminação, nós obtemos $U = \begin{bmatrix} 1 & 3 \\ 0 & 0 \end{bmatrix}$, que possui apenas um pivô. Nós podemos perceber que a segunda coluna é uma combinação linear da primeira (e que o mesmo acontece nas linhas). Agora, altere a matriz A , obtendo $A = \begin{bmatrix} 1 & 3 \\ 2 & 5 \end{bmatrix}$. Ao fazer o processo de eliminação, nós obtemos $U = \begin{bmatrix} 1 & 3 \\ 0 & -1 \end{bmatrix}$, que possui dois pivôs. Nós podemos, por sua vez, que a segunda coluna de A não é uma combinação linear da primeira (e o mesmo vale para as linhas).

Assim sendo, algo nos sugere que a relação entre um vetor ser ou não uma combinação linear de outros é algo importante. É precisamente isto que nós desenvolveremos agora.

Definição 5.3.1 (Independência linear). *Seja V um espaço vetorial. Diremos que $v_1, v_2, \dots, v_n \in V$ são **linearmente independentes (LI)** se*

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n = 0 \iff \alpha_1 = \alpha_2 = \dots = \alpha_n = 0.$$

No caso da segunda matriz do nosso exemplo, é possível demonstrar que as suas colunas são linearmente independentes. Vamos fazê-lo:

Proposição 5.3.2. *Sejam $v_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e $v_2 = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$ em $\mathbb{R}^2$. Então, v_1 e v_2 são linearmente independentes.*

Demonstração. *Considere a equação $\alpha_1 v_1 + \alpha_2 v_2 = 0$. Esta equação é, na verdade, um sistema de equações, dado por:*

$$\begin{cases} \alpha_1 + 3\alpha_2 = 0 \\ 2\alpha_1 + 5\alpha_2 = 0 \end{cases}$$

Realizando a eliminação, nós obtemos:

$$\begin{cases} \alpha_1 + 3\alpha_2 = 0 \\ -\alpha_2 = 0 \end{cases}$$

Este sistema possui uma única solução: $\alpha_1 = 0$ e $\alpha_2 = 0$. Logo, v_1 e v_2 são linearmente independentes.

□

Por sua vez, se determinados vetores em um espaço não são linearmente independentes, eles são linearmente dependentes.

Definição 5.3.3 (Dependência linear). *Seja V um espaço vetorial. Diremos que $v_1, v_2, \dots, v_n$ são **linearmente dependentes (LD)** se existem $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$, nem todos nulos, tais que:*

$$\alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n = 0.$$

Um exemplo de vetores linearmente dependentes é dado pelas colunas da primeira matriz do nosso exemplo. De fato, $\begin{bmatrix} 3 \\ 6 \end{bmatrix} = 3 \begin{bmatrix} 1 \\ 2 \end{bmatrix}$.

No capítulo anterior, nós definimos o conjunto *span* como sendo o conjunto de todas as combinações lineares de um certo grupo de vetores. Assim sendo, nós podemos definir o que significa um conjunto de vetores gerar um espaço em termos do conjunto *span*:

Definição 5.3.4 (Gerador). *Sejam $v_1, v_2, \dots, v_n$ vetores tais que $\text{span}(\{v_1, v_2, \dots, v_n\}) = V$. Então, dizemos que $v_1, v_2, \dots, v_n$ **geram** V .*

Na prática, isto quer dizer que qualquer vetor $w \in V$ pode ser escrito como uma combinação linear de $v_1, v_2, \dots, v_n$. No entanto, note que nós não dissemos que $v_1, v_2, \dots, v_n$ são LI. De fato, isto não é uma condição necessária para que um grupo de vetores gere um espaço ou um subespaço vetorial. Os geradores podem ser LD. Porém, muitas vezes nós estamos interessados no caso em que os vetores geradores são LI. Eles são o menor grupo de vetores que gera um espaço, e isso é algo especial. Assim sendo, nós podemos definir o conceito de base:

Definição 5.3.5 (Base de um espaço vetorial). *O conjunto de vetores $\{v_1, v_2, \dots, v_n\}$ é dito uma **base** para V se:*

- 1) $v_1, v_2, \dots, v_n$ são linearmente independentes;
- 2) $v_1, v_2, \dots, v_n$ geram V .

Uma vez que nós definimos o conceito de base, seria muito bom se, dada uma base $\{v_1, v_2, \dots, v_n\}$ para V , todo vetor de V fosse representado de forma única nesta base. Isto acontece, e nós o demonstraremos agora:

Proposição 5.3.6. *Se $\{v_1, v_2, \dots, v_n\}$ é uma base para V , então para qualquer $u \in V$, existem únicos $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$ tais que $u = \sum_{i=1}^n \alpha_i v_i$.*

Demonstração. *Nós precisamos provar duas coisas: a existência e a unicidade. A existência segue diretamente da definição de *span*. Vamos, então, demonstrar a unicidade.*

Seja $u \in V$, e suponha que existem dois conjuntos de coordenadas, $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$ e $\beta_1, \beta_2, \dots, \beta_n \in \mathbb{R}$ tais que $u = \alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n$ e $u = \beta_1 v_1 + \beta_2 v_2 + \dots + \beta_n v_n$. Então, ao fazermos $u - u$, nós obtemos:

$$0 = (\alpha_1 - \beta_1)v_1 + (\alpha_2 - \beta_2)v_2 + \dots + (\alpha_n - \beta_n)v_n.$$

Como os todos os v_i 's formam uma base, por definição eles são LI. Assim sendo:

$$\alpha_1 - \beta_1 = \alpha_2 - \beta_2 = \dots = \alpha_n - \beta_n = 0 \iff \alpha_1 = \beta_1, \alpha_2 = \beta_2, \dots, \alpha_n = \beta_n.$$

□

Vamos dar alguns exemplos de base em $\mathbb{R}^2$:

Exemplo 5.3.7. Considere o espaço vetorial $\mathbb{R}^2$. Alguns exemplos de base neste espaço são:

- 1) A base canônica: $\{e_1, e_2\} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\};$
- 2) O conjunto: $\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\};$
- 3) O conjunto: $\left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 3 \\ 5 \end{bmatrix} \right\}.$

Um outro exemplo interessante está em $\mathcal{P}_n$:

Exemplo 5.3.8. Considere o espaço dos polinômios de grau menor ou igual a n (denotado por $\mathcal{P}_n$). Então, o conjunto $\{1, x, x^2, \dots, x^n\}$ é considerado a base canônica de $\mathcal{P}_n$.

Note que, dado um espaço vetorial, a base não é única. Qualquer conjunto de vetores que sejam linearmente independentes e que gere o espaço é uma base.

5.4 Dimensão de um Espaço Vetorial

Nesta seção, nós apresentaremos o conceito de dimensão de um espaço vetorial. Para fazer isto, no entanto, primeiro nós vamos demonstrar um teorema que permite falar em dimensão de um espaço.

Teorema 5.4.1 (Teorema da Dimensão). Se $\{v_1, v_2, \dots, v_n\}$ e $\{u_1, u_2, \dots, u_k\}$ são bases de um espaço vetorial V , então $n = k$.

Demonstração. A demonstração deste teorema se dará em duas partes. Como nós queremos provar que $n = k$, nós devemos provar que $n \leq k$ e que $n \geq k$ ao mesmo tempo.

Primeiro, vamos provar que $n \leq k$. Suponha, por absurdo, que $n > k$. Então, para cada $i \in \{1, \dots, n\}$, nós temos que $v_i \in \text{span}(\{u_1, \dots, u_k\})$. Assim sendo,

$$v_i = a_{i1}u_1 + a_{i2}u_2 + \dots + a_{ik}u_k = \sum_{j=1}^k a_{ij}u_j.$$

Com isso, nós temos uma matriz $A_{n \times k}$ com $n > k$. Deste modo, A tem mais linhas do que colunas, o que implica que a matriz R' possui linhas de zeros. Assim sendo, existe $y \neq 0$ em $\mathbb{R}^n$ tal que $y^T A = 0$. Considere:

$$\sum_{i=1}^n y_i v_i = \sum_{i=1}^n y_i \left(\sum_{j=1}^k a_{ij} u_j \right) = \sum_{j=1}^k u_j \left(\sum_{i=1}^n y_i a_{ij} \right) = \sum_{j=1}^k u_j (y^T A)_j = 0.$$

Isso implica que o conjunto $\{u_1, \dots, u_k\}$ é LD, um absurdo. Logo, devemos ter $n \leq k$.

Agora, nós vamos provar que $n \geq k$. Suponha, por absurdo, que $k > n$. Então, para cada $i \in \{1, \dots, k\}$, nós temos que $u_i \in \text{span}(\{v_1, \dots, v_n\})$. Assim sendo,

$$u_i = a_{i1}v_1 + a_{i2}v_2 + \dots + a_{in}v_n = \sum_{j=1}^n a_{ij}v_j.$$

Com isso, nós temos uma matriz $A_{k \times n}$ com $k > n$. Deste modo, A tem mais linhas do que colunas, o que implica que a matriz R' possui linhas de zeros. Assim sendo, existe $y \neq 0$ em $\mathbb{R}^k$ tal que $y^T A = 0$. Considere:

$$\sum_{i=1}^k y_i u_i = \sum_{i=1}^k y_i \left(\sum_{j=1}^n a_{ij} v_j \right) = \sum_{j=1}^n v_j \left(\sum_{i=1}^k y_i a_{ij} \right) = \sum_{j=1}^n v_j (y^T A)_j = 0.$$

Isso implica que o conjunto $\{v_1, \dots, v_n\}$ é LD, um absurdo. Logo, devemos ter $n \geq k$.

Como $n \leq k$ e $n \geq k$ ao mesmo tempo, segue que $n = k$. □

Agora que nós sabemos que todas as bases de um mesmo espaço vetorial possuem a mesma quantidade de vetores, nós podemos formalizar o conceito de dimensão:

Definição 5.4.2 (Dimensão de um espaço vetorial). *Seja $\{v_1, v_2, \dots, v_n\}$ uma base para V . Então, nós chamamos o número n de **dimensão** de V , e escrevemos $\dim V = n$.*

Do Teorema da Dimensão, segue um corolário:

Corolário 5.4.3. *Se $\dim V = n$, então $n + 1$ vetores em V são linearmente dependentes.*

Demonstração. *Sem perda de generalidade, podemos supor que o conjunto de $n + 1$ vetores é da forma $\{v_1, \dots, v_n, v_{n+1}\}$, onde $\{v_1, \dots, v_n\}$ é uma base para V . Segue então que:*

$$v_{n+1} = \alpha_1 v_1 + \dots + \alpha_n v_n.$$

Ou seja:

$$\alpha_1 v_1 + \dots + \alpha_n v_n - v_{n+1} = 0.$$

Ou seja, nós achamos uma combinação linear não-trivial do 0 usando $v_1, \dots, v_{n+1}$. Logo, o conjunto $\{v_1, \dots, v_{n+1}\}$ é LD. □

Tendo analisado o que acontece com um conjunto de vetores de tamanho maior do que a dimensão de um espaço vetorial, vamos ver o que acontece quando temos um conjunto de vetores menor do que a dimensão do espaço. Especificamente, nós vamos considerar que tal conjunto é LI, e chegar à conclusão de que ele pode ser estendido até obtermos uma base. Este é o Teorema da Extensão:

Teorema 5.4.4 (Teorema da Extensão). *Seja V um espaço vetorial com $\dim V = n$ e $\{v_1, \dots, v_k\}$ um conjunto LI em V , com $k < n$. Então, existem $\{v_{k+1}, \dots, v_n\}$ LI tal que $\{v_1, \dots, v_n\}$ é uma base de V .*

Demonstração. *Como $\{v_1, \dots, v_k\}$ é um conjunto LI, e $k < n$, nós temos que $\{v_1, \dots, v_k\}$ não gera V . Isto significa que $\text{span}(\{v_1, \dots, v_k\}) \subsetneq V$, ou seja, existe $v_{k+1} \in V$ tal que $v_{k+1} \notin \text{span}(\{v_1, \dots, v_k\})$. Então, se considerarmos o conjunto $\{v_1, \dots, v_k, v_{k+1}\}$, ele será LI.*

Se $k + 1 = n$, nós temos um conjunto de n vetores LI que gera todo o espaço, e portanto, temos uma base. Por outro lado, se $k + 1 < n$, basta repetir o procedimento até chegarmos em um conjunto LI de n vetores que gera todo o espaço (ou seja, até obtermos uma base). □

Deste teorema segue um corolário:

Corolário 5.4.5. *Se $\dim V = n$, qualquer conjunto de n vetores LI é uma base para V .*

Agora, demonstraremos mais um importante teorema que descreve a ação de uma matriz invertível sobre um conjunto LI de vetores.

Teorema 5.4.6. *Seja B uma matriz quadrada $m \times m$ invertível. Se $\{v_1, \dots, v_k\}$ é um conjunto LI, então o mesmo é verdade para o conjunto $\{Bv_1, \dots, Bv_k\}$.*

Demonstração. *Considere a matriz V definida por:*

$$V = \begin{bmatrix} | & & | \\ v_1 & \cdots & v_k \\ | & & | \end{bmatrix}_{m \times k}.$$

Como as colunas de V são LI por hipótese, nós temos que $N(V) = \{0\}$. Considere agora a matriz BV definida por:

$$BV = \begin{bmatrix} | & & | \\ Bv_1 & \cdots & Bv_k \\ | & & | \end{bmatrix}.$$

Nós queremos analisar $N(BV)$. Em primeiro lugar, vamos provar que $N(V) \subseteq N(BV)$. De fato, nós temos que:

$$x \in N(V) \iff Vx = 0 \implies BVx = 0 \implies x \in N(BV).$$

Agora, nós vamos provar que $N(BV) \subseteq N(V)$. Precisamente agora nós iremos usar o fato de que B é invertível. Nós temos que:

$$x \in N(BV) \iff BVx = 0 \implies B^{-1}BVx = B^{-1}0 \implies Vx = 0 \implies x \in N(V).$$

Logo, $N(V) = N(BV)$. Como, porém, as colunas de V são LI, segue que $N(V) = \{0\}$. Logo, $N(BV) = \{0\}$ e, portanto, as colunas de BV também são LI.

□

Este teorema (e um outro que garante que, se as colunas de V são LD, então as colunas de BV também são LD, e que será um dos exercícios) é o que fundamenta uma demonstração que nós fizemos no capítulo anterior: $N(A) = N(R)$. Isto acontece porque a matriz E que realiza a eliminação é invertível.

5.5 Base e Dimensão de $C(A)$ e $C(A^T)$

Voltamos agora aos quatro subespaços fundamentais. O teorema anterior nos permitirá construir uma base e determinar a dimensão deles.

De fato, uma das consequências deste teorema é o fato de que as colunas pivôs da forma escalonada R são LI e, portanto, as mesmas colunas de A são LI e, de igual modo, como as colunas livres de R são combinações lineares das colunas pivôs, o mesmo é verdade para as colunas livres de A .

Assim sendo, nós chegamos à seguinte conclusão:

Teorema 5.5.1 (Base e Dimensão de $C(A)$). *Seja A uma matriz $m \times n$ tal que $\{a_1, \dots, a_r\}$ são as suas colunas pivôs. Então:*

$$C(A) = \text{span}(\{a_1, \dots, a_r\})$$

e

$$\dim C(A) = r.$$

Por sua vez, encontrar uma base e a dimensão de $C(A^T)$ também é algo bem simples:

Teorema 5.5.2 (Base e Dimensão de $C(A^T)$). *Seja A uma matriz $m \times n$ tal que $\{b_1^T, \dots, b_r^T\}$ são as suas linhas pivôs. Então:*

$$C(A^T) = \text{span}(\{b_1^T, \dots, b_r^T\})$$

e

$$\dim C(A^T) = r.$$

Demonstração. *Nós temos que:*

$$\begin{aligned} C(A^T) &= \text{span}(\{\text{linhas de } A\}) = \text{span}(\{\text{linhas de } R\}) \\ &= \text{span}(\{\text{linhas pivôs de } R\}) = \text{span}(\{\text{linhas pivôs de } A\}). \end{aligned}$$

Como são r as linhas de pivôs de A , segue que $\dim C(A^T) = r$. $\square$

Note que, neste caso, as linhas pivôs de R também formam uma base para $C(A^T)$. Por outro lado, como $C(A) \neq C(R)$, não se pode dizer que as colunas pivôs de R formam uma base para $C(A)$. Isto ocorre porque as operações elementares que nós fazemos em A alteram a relação espacial entre as suas colunas, mas isto não ocorre nas linhas. Por consequência, nós podemos dizer que $C(A^T) = C(R^T)$.

5.6 Base e Dimensão de $N(A)$

Para encontrarmos uma base para $N(A)$, o trabalho é um bem maior do que para o espaço das colunas ou o das linhas. Vamos desenvolvê-lo agora.

Seja $\{v_1, \dots, v_r\}$ uma base para $C(A) \subset \mathbb{R}^m$ e considere $x_i \in \mathbb{R}^n$ tal que $Ax_i = v_i$, para $i \in \{1, \dots, r\}$.

Lema 5.6.1. *O conjunto $\{x_1, \dots, x_r\}$ é LI.*

Demonstração. *De fato, se $\alpha_1 x_1 + \dots + \alpha_r x_r = 0$, então $A(\alpha_1 x_1 + \dots + \alpha_r x_r) = A0 = 0$. Daí segue, pela linearidade de A , que $\alpha_1 Ax_1 + \dots + \alpha_r Ax_r = 0$. Como nós temos que $Ax_i = v_i$, segue que $\alpha_1 v_1 + \dots + \alpha_r v_r = 0$ e, como $\{v_1, \dots, v_r\}$ é uma base para $C(A)$, então, $\alpha_1 = \dots = \alpha_r = 0$.* $\square$

Dado que $\{x_1, \dots, x_r\}$ é LI, pelo Teorema da Extensão, que existem $\{x_{r+1}, \dots, x_n\}$ tais que $\{x_1, \dots, x_n\}$ é uma base para $\mathbb{R}^n$.

Note também que $Ax_i \in \text{span}(\{v_1, \dots, v_r\})$, para $i \in \{r+1, \dots, n\}$. Assim sendo, escrevamos:

$$Ax_i = \alpha_{1i} v_1 + \dots + \alpha_{ri} v_r = \alpha_{1i} Ax_1 + \dots + \alpha_{ri} Ax_r = A(\alpha_{1i} x_1 + \dots + \alpha_{ri} x_r).$$

Definindo $x'_i = x_i - (\alpha_{1i} x_1 + \dots + \alpha_{ri} x_r)$, nós temos o seguinte resultado:

Lema 5.6.2. *O vetor x'_i pertence a $N(A)$.*

Demonstração. *De fato, $Ax'_i = Ax_i - A(\alpha_{1i}x_1 + \cdots + \alpha_{ri}x_r) = Ax_i - Ax_i = 0$. Logo, $x'_i \in N(A)$.*

□

Com este resultado, nós concluímos que o conjunto $\{x'_{r+1}, \dots, x'_n\}$ é LI.

Lema 5.6.3. *O conjunto $\{x'_{r+1}, \dots, x'_n\}$ é LI.*

Demonstração. *Nós queremos provar que $c_{r+1}x'_{r+1} + \cdots + c'_n x'_n = 0 \implies c_{r+1} = \cdots = c_n = 0$. De fato, esta soma é igual a:*

$$\begin{aligned} & c_{r+1}[x_{r+1} - (\alpha_{1,r+1}x_1 + \cdots + \alpha_{r,r+1}x_r)] \\ & + c_{r+2}[x_{r+2} - (\alpha_{1,r+2}x_1 + \cdots + \alpha_{r,r+2}x_r)] + \\ & \vdots \\ & + c_n[x_n - (\alpha_{1,n}x_1 + \cdots + \alpha_{r,n}x_r)] = 0. \end{aligned}$$

Desenvolvendo esta soma, nós obtemos:

$$\begin{aligned} & c_{r+1}x_{r+1} + \cdots + c_n x_n + \\ & + x_1(-c_{r+1}\alpha_{1,r+1} - c_{r+2}\alpha_{1,r+2} - \cdots - c_n\alpha_{1,n}) + \\ & + x_2(-c_{r+1}\alpha_{2,r+1} - c_{r+2}\alpha_{2,r+2} - \cdots - c_n\alpha_{2,n}) + \\ & \vdots \\ & + x_r(-c_{r+1}\alpha_{r,r+1} - c_{r+2}\alpha_{r,r+2} - \cdots - c_n\alpha_{r,n}) = 0. \end{aligned}$$

Como o conjunto $\{x_1, \dots, x_n\}$ é LI, segue que $c_{r+1} = \cdots = c_n = 0$.

□

Nós sabemos que $\dim \mathbb{R}^n = n$. Assim sendo, nós queremos mostrar que $\{x_1, \dots, x_r, x'_{r+1}, \dots, x'_n\}$ é uma base de $\mathbb{R}^n$.

Lema 5.6.4. *O conjunto $\{x_1, \dots, x_r, x'_{r+1}, \dots, x'_n\}$ forma uma base para $\mathbb{R}^n$.*

Demonstração. *Pelo corolário do Teorema da Dimensão, segue que nós precisamos unicamente provar que este conjunto é LI. Ou seja, queremos provar que:*

$$\beta_1 x_1 + \cdots + \beta_r x_r + \beta_{r+1} x'_{r+1} + \cdots + \beta_n x'_n = 0 \implies \beta_1 = \cdots = \beta_n = 0.$$

Reescrevendo a soma, nós obtemos:

$$\begin{aligned} & \beta_1 x_1 + \cdots + \beta_r x_r + \\ & + \beta_{r+1}[x_{r+1} - (\alpha_{1,r+1}x_1 + \cdots + \alpha_{r,r+1}x_r)] + \\ & + \beta_{r+2}[x_{r+2} - (\alpha_{1,r+2}x_1 + \cdots + \alpha_{r,r+2}x_r)] + \\ & \vdots \\ & + \beta_n[x_n - (\alpha_{1,n}x_1 + \cdots + \alpha_{r,n}x_r)] = 0. \end{aligned}$$

Nós podemos rearranjar a soma, obtendo:

$$\begin{aligned}
& \cancel{\beta_{r+1}}^0 x_{r+1} + \cdots + \cancel{\beta_n}^0 x_n + \\
& + (\cancel{\beta_1}^0 - \cancel{\beta_{r+1}}^0 \alpha_{1,r+1} - \cancel{\beta_{r+2}}^0 \alpha_{1,r+2} - \cdots - \cancel{\beta_n}^0 \alpha_{1,n}) x_1 + \\
& \vdots \\
& + (\cancel{\beta_r}^0 - \cancel{\beta_{r+1}}^0 \alpha_{r,r+1} - \cancel{\beta_{r+2}}^0 \alpha_{r,r+2} - \cdots - \cancel{\beta_n}^0 \alpha_{r,n}) x_r = 0.
\end{aligned}$$

Os cancelamentos que nós fizemos foram baseados no fato de que o conjunto $\{x_1, \dots, x_n\}$ é LI. De fato, da primeira linha nós obtemos que $\beta_{r+1} = \cdots = \beta_n = 0$ e, conseqüentemente, nas demais linhas nós temos $\beta_1 = \cdots = \beta_r = 0$. Assim sendo, nós temos que $\beta_1 = \cdots = \beta_r = \beta_{r+1} = \cdots = \beta_n = 0$. □

Finalmente, nós podemos demonstrar a última coisa que falta para nós enunciarmos formalmente o teorema sobre a base de $N(A)$.

Lema 5.6.5. $N(A) = \text{span}(\{x'_{r+1}, \dots, x'_n\})$.

Demonstração. $\implies$ Suponha que $x \in N(A) \subseteq \mathbb{R}^n$. Então, podemos escrever x como:

$$x = \alpha_1 x_1 + \cdots + \alpha_r x_r + \alpha_{r+1} x'_{r+1} + \cdots + \alpha_n x'_n.$$

Além disso, como $Ax = 0$, nós temos que:

$$0 = \alpha_1 Ax_1 + \cdots + \alpha_r Ax_r + \alpha_{r+1} \cancel{Ax'_{r+1}}^0 + \cdots + \alpha_n \cancel{Ax'_n}^0.$$

Assim sendo, segue que:

$$\alpha_1 v_1 + \cdots + \alpha_r v_r = 0$$

e, como o conjunto $\{v_1, \dots, v_r\}$ é LI, segue que:

$$\alpha_1 = \cdots = \alpha_r = 0.$$

Assim sendo, nós temos que:

$$x = \alpha_{r+1} x'_{r+1} + \cdots + \alpha_n x'_n.$$

Logo, $x \in \text{span}(\{x'_{r+1}, \dots, x'_n\})$.

$\Leftarrow$ Suponha que $x \in \text{span}(\{x'_{r+1}, \dots, x'_n\})$. Ao calcular Ax , nós obtemos:

$$Ax = \alpha_{r+1} Ax'_{r+1} + \cdots + \alpha_n Ax'_n.$$

Porém, cada Ax'_i , para $i \in \{r+1, \dots, n\}$, é igual a zero. Logo, $Ax = 0$, o que significa que $x \in N(A)$. Portanto, $N(A) = \text{span}(\{x'_{r+1}, \dots, x'_n\})$. □

Assim sendo, podemos chegar à seguinte conclusão:

Teorema 5.6.6 (Base e Dimensão de $N(A)$). *Seja A uma matriz $m \times n$, e considere o conjunto $\{x'_{r+1}, \dots, x'_n\}$, com $x'_i = x_i - (\alpha_{1i}x_1 + \cdots + \alpha_{ri}x_r)$. Então, $\{x'_{r+1}, \dots, x'_n\}$ é uma base para $N(A)$ e $\dim N(A) = n - r$.*

Demonstração. *Segue diretamente de tudo o que fizemos até agora nesta seção, e particularmente, dos 5 lemas anteriores.*

□

Muito embora nós tenhamos tido todo este trabalho para determinar uma base para $N(A)$, existe uma outra base que é muito mais fácil de se encontrar: tal base é a das colunas da matriz núcleo. No entanto, a grande utilidade da teoria que nós desenvolvemos aqui é o grande teorema do curso: o Teorema do Posto (chamado também de Teorema do Núcleo e da Imagem no contexto de transformações lineares).

Teorema 5.6.7 (Teorema do Posto). *Seja A uma matriz $m \times n$ qualquer. Então:*

$$\dim C(A) + \dim N(A) = n.$$

A demonstração deste teorema consiste basicamente no passo a passo que nós fizemos anteriormente. Nós demonstramos que $\dim C(A) = r$, e também demonstramos que $\dim N(A) = n - r$. Somando as dimensões, nós obtemos $\dim C(A) + \dim N(A) = r + n - r = n$. Assim sendo, nós focaremos um pouco na sua interpretação.

Lembre-se de que toda matriz é, na verdade, uma forma de se representar uma transformação linear. Assim sendo, uma matriz $A_{m \times n}$ pode ser vista como uma função $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$ tal que $A(x) = Ax$. O que o Teorema do Posto (ou o Teorema do Núcleo e da Imagem, como eu gosto mais de chamar) nos diz é que a soma da dimensão da imagem de A com a dimensão do núcleo de A é igual à dimensão do domínio de A . Ou seja, o núcleo nos revela o quanto a matriz (ou a transformação linear) está próxima de ser injetiva (nós falaremos melhor disso no próximo capítulo). Se $\dim N(A) = 0$, a transformação é injetiva. Se $\dim N(A) = n$ (um caso muito extremo, atingido apenas pela matriz 0), então todos os vetores são mapeados por A no vetor $0 \in \mathbb{R}^m$. É o extremo oposto do que seria uma função injetiva.

5.7 Base e Dimensão de $N(A^T)$

Para concluir a análise da base e da dimensão dos quatro subespaços fundamentais, nós vamos agora encontrar uma base para $N(A^T)$ e a sua dimensão. Encontrar a dimensão de $N(A^T)$ é uma tarefa bem simples: nós sabemos que $\dim C(A^T)$. Logo, pelo Teorema do Posto, nós temos que $\dim N(A^T) = m - \dim C(A^T) = m - r$.

Assim sendo, vamos nos concentrar agora em encontrar uma base para $N(A^T)$. Em primeiro lugar, recordemo-nos de que as linhas de R são combinações lineares das linhas de A , e vice-versa. Assim sendo, existe uma matriz E que transforma A na sua forma escalonada reduzida permutada R atuando nas linhas de A . Ou seja, existe E tal que $EA = R$.

Suponha então que A é uma matriz $m \times n$ com posto r . Então, E é uma matriz $m \times m$ que definiremos em termos dos seus vetores linha da seguinte forma:

$$E = \begin{bmatrix} - & v_1^T & - \\ & \vdots & \\ - & v_m^T & - \end{bmatrix}.$$

Multiplicando E à esquerda de A , nós obtemos:

$$EA = \begin{bmatrix} - & v_1^T A & - \\ & \vdots & \\ - & v_m^T A & - \end{bmatrix} = R.$$

Nós sabemos que E é invertível. Assim sendo, todas as colunas de E são LI e todas as linhas de E são LI. Sabemos também que as últimas $m - r$ linhas de R são iguais a 0. Assim sendo, nós temos que $v_i^T A = 0$, para todo $i \in \{r + 1, \dots, m\}$. Logo, $v_i \in N(A^T)$, para todo $i \in \{r + 1, \dots, m\}$. Como os v_i 's são linearmente independentes, e este conjunto possui $m - r$ vetores, segue que $\{v_{r+1}, \dots, v_m\}$ formam uma base para $N(A^T)$.

Vamos resumir toda esta discussão em um teorema:

Teorema 5.7.1 (Base e Dimensão de $N(A^T)$). *Sejam A uma matriz $m \times n$ com posto r , e E a matriz tal que $EA = R$. Considere o conjunto $\{v_{r+1}, \dots, v_m\}$ formado pelos $m - r$ últimos vetores-linha de E . Então, $\{v_{r+1}, \dots, v_m\}$ é uma base para $N(A^T)$, e $\dim N(A^T) = m - r$.*

Após tantas informações ao longo das últimas três seções, façamos um exemplo para clarear melhor as ideias.

Exemplo 5.7.2. *Considere a matriz $A = \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 1 & 2 & 4 & 6 \\ 0 & 0 & 0 & 1 & 2 \end{bmatrix}$. Nós queremos encontrar bases para os quatro subespaços fundamentais de A . Para isto, em primeiro lugar, vamos aplicar o processo de escalonamento de modo a obter a matriz R :*

$$\begin{aligned} & \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 1 & 2 & 4 & 6 \\ 0 & 0 & 0 & 1 & 2 \end{bmatrix} \xrightarrow{L_2 - L_1} \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 1 & 2 \end{bmatrix} \xrightarrow{L_3 - L_2} \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \\ & \xrightarrow{L_1 - 3L_2} \begin{bmatrix} 0 & 1 & 2 & 0 & -2 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} = R. \end{aligned}$$

Nós temos exatamente 2 colunas pivôs (a 2ª e a 4ª) e exatamente 3 colunas livres (a 1ª, a 3ª e a 5ª). Tendo achado a forma escalonada de A , vamos agora encontrar bases para os subespaços fundamentais.

1) Base para $C(A)$: pode ser formada pelas colunas pivôs de A . Assim sendo:

$$\text{Base para } C(A) = \left\{ \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 \\ 4 \\ 1 \end{bmatrix} \right\}.$$

2) Base para $C(A^T)$: pode ser formada pelas linhas pivôs de A . Assim sendo:

$$\text{Base para } C(A^T) = \left\{ \begin{bmatrix} 0 \\ 1 \\ 2 \\ 3 \\ 4 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \\ 6 \end{bmatrix} \right\}.$$

3) Base para $N(A)$: em primeiro lugar, vamos achar a matriz R' . Primeiro, nós permutamos as colunas 1 e 2. Em seguida, permutamos as novas colunas 3 e 4 e, em

seguida, permutamos as colunas 2 e 3 (as permutações são feitas de modo a preservar a ordem original das colunas livres). Assim, nós obtemos:

$$R' = \begin{bmatrix} 1 & 0 & 0 & 2 & -2 \\ 0 & 1 & 0 & 0 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}.$$

Assim sendo, a matriz F é dada por:

$$F = \begin{bmatrix} 0 & 2 & -2 \\ 0 & 0 & 2 \end{bmatrix}.$$

Podemos, agora, montar a matriz núcleo. Vamos fazer isto passo a passo, retomando as permutações que foram feitas, da última para a primeira:

$$\begin{bmatrix} 0 & -2 & 2 \\ 0 & 0 & -2 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{L_2 \leftrightarrow L_3} \begin{bmatrix} 0 & -2 & 2 \\ 1 & 0 & 0 \\ 0 & 0 & -2 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{L_3 \leftrightarrow L_4} \begin{bmatrix} 0 & -2 & 2 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -2 \\ 0 & 0 & 1 \end{bmatrix} \xrightarrow{L_1 \leftrightarrow L_2} \begin{bmatrix} 1 & 0 & 0 \\ 0 & -2 & 2 \\ 0 & 1 & 0 \\ 0 & 0 & -2 \\ 0 & 0 & 1 \end{bmatrix} = N.$$

Assim sendo, uma base para $N(A)$ é dada pelas colunas de N , da seguinte forma:

$$\text{Base para } N(A) = \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 2 \\ 0 \\ -2 \\ 1 \end{bmatrix} \right\}.$$

4) Base para $N(A^T)$: nós podemos perceber que, durante o processo de escalonamento, nós já obtivemos uma matriz U com zeros na última linha antes de chegar a R . Recordando:

$$U = \begin{bmatrix} 0 & 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}.$$

Assim sendo, se nós considerarmos a matriz $\tilde{E} = L^{-1}$ tal que $\tilde{E}A = U$ (ou, igualmente, $A = LU$), nós podemos tomar a última linha de $\tilde{E}$ como base para $N(A^T)$.

A matriz L é dada por:

$$L = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}.$$

A sua inversa, L^{-1} , é dada por:

$$L^{-1} = \tilde{E} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 1 & -1 & 1 \end{bmatrix}.$$

Para confirmar que esta é, de fato, a matriz inversa de L , nós podemos simplesmente multiplicar as matrizes de eliminação que atuam sobre A . $\tilde{E}$, na verdade, mais fácil fazer isto do que achar a inversa de L . Tendo achado a matriz $\tilde{E}$, nós temos que:

$$\text{Base para } N(A^T) = \left\{ \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix} \right\}.$$

5.8 Resumo sobre os Quatro Subespaços Fundamentais

Nesta seção, nós vamos fazer uma tabela que resume toda a discussão que nós tivemos sobre os quatro subespaços fundamentais.

	$r = m = n$	$r = n < m$	$r = m < n$	$r < m, r < n$
R'	I	$\begin{bmatrix} I_{n \times n} \\ 0_{m-n \times n} \end{bmatrix}$	$\begin{bmatrix} I_{m \times m} & F_{m \times n-m} \end{bmatrix}$	$\begin{bmatrix} I_{r \times r} & F_{r \times n-r} \\ 0_{m-r \times r} & 0_{m-r \times n-r} \end{bmatrix}$
# sols. de $Ax = b$	1	0 ou 1	infinitas soluções	0 ou infinitas
$\dim C(A)$	n	$n < m$	m	$r < m$
$\dim N(A)$	0	$0 = n - r$	$n - m$	$n - r$
$\dim C(A^T)$	n	$r = n$	$m < n$	$r < n$
$\dim N(A^T)$	0	$m - r = m - n$	0	$m - r$
bases	$C(A)$: colunas (pivôs) de A , ou $\{e_1, \dots, e_n\}$ já que $C(A) = \mathbb{R}^n$ $C(A^T)$: mesma coisa $N(A)$ e $N(A^T)$ não tem base	$C(A)$: colunas A $C(A^T)$: linhas pivôs de A , pode ser $\{e_1, \dots, e_n\}$ já que $C(A^T) = \mathbb{R}^n$ $N(A)$ não tem base $N(A^T) = \{v_{n+1}, \dots, v_m\}$	$C(A)$: colunas pivôs de A ou $\{e_1, \dots, e_m\}$ $C(A^T)$: linhas A $N(A)$: colunas de N $N(A^T)$: não tem	$C(A)$: colunas pivôs A $C(A^T)$: linhas pivôs A $N(A)$: cols. de N $N(A^T)$: $m - r$ últimos linhas da matriz elim.

5.9 Exercícios

Importante: alguns dos exercícios são baseados em (2) e em (6).

5.1) Seja $A = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \\ 1 & 3 & 5 & 7 & 9 \\ 1 & 3 & 6 & 10 & 15 \end{bmatrix}$. Determine o posto de A . Determine as dimensões dos quatro subespaços fundamentais de A e, em seguida, encontre bases para eles.

5.2) Ache matrizes A_1 e A_2 não triviais tais que $\text{posto}(A_1 B) = 1$ e $\text{posto}(A_2 B) = 0$ para $B = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$.

5.3) Seja $r(A)$ o posto da matriz A .

- a) Prove que, dadas duas matrizes $A_{m \times n}$ e $B_{n \times p}$, $r(AB) \leq \min\{r(A), r(B)\}$.
- b) Prove que, dadas duas matrizes A e B $n \times n$ quaisquer, $r(A + B) \leq r(A) + r(B)$.
- c) Prove que, dada uma matriz $A_{m \times n}$ qualquer, $r(A) = r(A^T)$.

5.4) Suponha que a coluna j de B é uma combinação linear das colunas anteriores de B .

- a) Mostre que a coluna j de AB é uma combinação linear das colunas anteriores de AB .
- b) Conclua que $\text{posto}(AB) \leq \text{posto}(B)$.
- c) Os itens anteriores nos dão $\text{posto}(B^T A^T) \leq \text{posto}(A^T)$. É possível concluir que $\text{posto}(AB) \leq \text{posto}(A)$?

5.5) Suponha que A e B são matrizes quadradas e $AB = I$. Prove que $\text{posto}(A) = n$. Conclua que B precisa ser a inversa (de ambos lados) de A . Então, $BA = I$.

5.6) Seja A uma matriz $m \times n$ com posto r . Suponha que existem b tais que $Ax = b$ não tenha solução.

- a) Escreva todas as desigualdades ($<$ e $\leq$) que os números m , n e r precisam satisfazer.
- b) Como podemos concluir que $A^T x = 0$ tem solução fora $x = 0$?

5.7) Considere o conjunto S definido por:

$$S = \{x \in \mathbb{R}^n; x = (x_1, 2x_1, 3x_1, \dots, nx_1)^T\}.$$

- a) Prove que S é um subespaço vetorial.
- b) Determine a dimensão de S .
- c) Encontre uma base para S .
- d) Estenda a base de S para encontrar uma base para $\mathbb{R}^n$.

5.8) Demonstre que, se $v_1, v_2, \dots, v_n$ são linearmente independentes em um espaço V , então $v_1 + v_2, v_2 + v_3, \dots, v_n + v_1$ são linearmente independentes se, e somente se, n é um número ímpar.

5.9) Seja B uma matriz invertível. Demonstre que, se $\{v_1, \dots, v_k\}$ é LD, então o mesmo é verdade para $\{Bv_1, \dots, Bv_k\}$.

5.10) Sejam S e T dois subespaços vetoriais, com bases $\{s_1, \dots, s_m\}$ e $\{t_1, \dots, t_n\}$, respectivamente. Defina o subespaço $S + T$ como:

$$S + T = \{s + t; s \in S \text{ e } t \in T\}.$$

Sabendo que $S \cap T = \{0\}$, determine uma base para $S + T$, e a sua dimensão.

5.11) Construa uma matriz cujo espaço coluna contenha $(1, 1, 5)^T$ e $(0, 3, 1)^T$ e cujo núcleo contenha $(1, 1, 2)^T$.

5.12) Construa uma matriz cujo núcleo contenha todos os múltiplos de $(4, 3, 2, 1)^T$.

5.13) Sem calcular A , ache uma base para os quatro espaços fundamentais:

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 6 & 1 & 0 \\ 9 & 8 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 & 4 \\ 0 & 1 & 2 & 3 \\ 0 & 0 & 1 & 2 \end{bmatrix}.$$

5.14) A equação $A^T x = w$ tem solução quando w está em qual dos quatro subespaços? Quando a solução é única (condição sobre algum dos quatro subespaços)?

5.15) Seja A uma matriz $m \times n$. Demonstre que $C(A) = N(A)$ se, e somente se as três seguintes afirmações são cumpridas: $m = n$, $\text{posto}(A) = \frac{n}{2}$ e $A^2 = 0$.

5.16) Sejam A e B matrizes $m \times n$ com os mesmos quatro subespaços fundamentais. Se ambas estão na sua forma escalonada reduzida, prove que F e G são iguais, onde:

$$A = \begin{bmatrix} I & F \\ 0 & 0 \end{bmatrix} \text{ e } B = \begin{bmatrix} I & G \\ 0 & 0 \end{bmatrix}.$$

5.17) Seja $v \in \mathbb{R}^n$, e considere a matriz $H = I - \frac{vv^T}{||v||^2}$. Determine o posto de H .

Capítulo 6

Transformações Lineares

Importante: este capítulo é baseado em: (8) e em (7).

No capítulo 4, nós introduzimos o conceito de transformação linear, e demos uma breve motivação. Agora, nós vamos desenvolver melhor este conceito e nos aprofundar em alguns dos seus principais aspectos.

6.1 Transformações Lineares

Para começar, novamente nós vamos escrever a definição de transformação linear.

Definição 6.1.1 (Transformação Linear). *Sejam U e V dois espaços vetoriais. Dizemos que $T : U \rightarrow V$ é uma **transformação linear** se:*

- 1) $T(u + v) = T(u) + T(v)$;
- 2) $T(\alpha u) = \alpha T(u)$,

para $u, v \in U$ e $\alpha \in \mathbb{R}$.

Na prática, nós podemos reunir estas duas condições em uma única condição: uma transformação $T : U \rightarrow V$ é linear se, e somente se, $T(\alpha u + \beta v) = \alpha T(u) + \beta T(v)$, para $u, v \in U$ e $\alpha, \beta \in \mathbb{R}$. Em resumo, uma transformação é dita linear quando é linear.

Uma primeira propriedade que nós podemos enunciar e provar se refere à aplicação de uma transformação linear no vetor 0.

Proposição 6.1.2. *Seja $T : U \rightarrow V$ uma transformação linear. Então, $T(0) = 0$.*

Demonstração. *Seja $u \in U$. Então, $T(0) = T(0 \cdot u) = 0T(u) = 0 \in V$.*

□

Vamos agora ver alguns exemplos de transformações lineares:

Exemplo 6.1.3. *Alguns exemplos de transformações lineares são:*

- 1) *A transformação $I : \mathbb{R}^n \rightarrow \mathbb{R}^n$ definida por $I(x) = x$ é linear.*
- 2) *A transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ definida por $T(x) = Ax$, onde A é uma matriz $m \times n$, é linear.*
- 3) *A transformação $D : \mathcal{P}_n \rightarrow \mathcal{P}_n$, definida por $D(p) = p'$, é linear.*
- 4) *A transformação $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, definida por $T(x, y) = (y, x)$ é linear.*

Vamos também ver alguns exemplos de transformações não-lineares:

Exemplo 6.1.4. Alguns exemplos de transformações não-lineares são:

- 1) A transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^n$ definida por $T(x) = x + b$, onde $b \neq 0$, não é linear.
- 2) A transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}$, definida por $T(x) = \|x\|$, não é linear.
- 3) A transformação $T : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida por $T(x, y) = x^2 + y^2$ não é linear.
- 4) A transformação $T : \mathbb{R} \rightarrow \mathbb{R}^2$, definida por $T(x) = (x, x + 2)^T$ não é linear.

Para demonstrar que uma transformação é linear, basta demonstrarmos que a transformação cumpre todos os requisitos da definição. Para exemplificar, demonstraremos que a transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$, definida por $T(x) = Ax$, com A sendo uma matriz $m \times n$, é linear.

Proposição 6.1.5. Considere a transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ definida por $T(x) = Ax$, onde A é uma matriz $m \times n$. Então, T é uma transformação linear.

Demonstração. Sejam $x, y \in \mathbb{R}^n$ e $\alpha \in \mathbb{R}$. Então:

$$\begin{aligned} T(x + y) &= A(x + y) = \sum_{i=1}^m \sum_{j=1}^n a_{ij}(x_j + y_j) = \sum_{i=1}^m \sum_{j=1}^n (a_{ij}x_j + a_{ij}y_j) \\ &= \sum_{i=1}^m \sum_{j=1}^n a_{ij}x_j + \sum_{i=1}^m \sum_{j=1}^n a_{ij}y_j \\ &= Ax + Ay. \end{aligned}$$

$$T(\alpha x) = A(\alpha x) = \sum_{i=1}^m \sum_{j=1}^n \alpha a_{ij}x_j = \alpha \sum_{i=1}^m \sum_{j=1}^n a_{ij}x_j = \alpha Ax.$$

Logo, T é uma transformação linear. □

Agora, para exemplificar, nós demonstraremos que a transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}$ definida por $T(x) = \|x\|$ não é linear.

Proposição 6.1.6. Considere a transformação $T : \mathbb{R}^n \rightarrow \mathbb{R}$ definida por $T(x) = \|x\|$. Então, T não é uma transformação linear.

Demonstração. Sejam $x, y \in \mathbb{R}^n$. Então, nós temos que:

$$T(x + y) = \|x + y\| \leq \|x\| + \|y\|.$$

Logo, T não é uma transformação linear. □

Um dos modos mais fáceis de se demonstrar que $T : U \rightarrow V$ não é uma transformação linear ocorre no caso em que $T(0) \neq 0$. Neste caso, é imediato que T não é uma transformação linear. No entanto, existem transformações não-lineares T tais que $T(0) = 0$ e, neste caso, é necessário analisar as condições da definição de transformação linear.

6.2 Núcleo e Imagem de uma Transformação Linear

Nos 2 capítulos anteriores, nós definimos o núcleo e o espaço coluna de uma matriz. Agora, nós estenderemos este conceito para uma transformação linear qualquer. Na prática, as definições são as mesmas, porém agora nós estamos lidando com um contexto mais geral de transformações lineares.

Definição 6.2.1 (Núcleo de uma transformação linear). *Seja $T : U \rightarrow V$ uma transformação linear qualquer. Então, definimos o núcleo de T como o conjunto:*

$$N(T) = \{v \in V; T(v) = 0\}.$$

Definição 6.2.2 (Imagem de uma transformação linear). *Seja $T : U \rightarrow V$ uma transformação linear qualquer. Então, definimos a imagem de T como o conjunto:*

$$Im(T) = \{T(v); v \in V\}.$$

Pela linearidade deste tipo de transformações, é imediato o fato de que $N(T)$ e $Im(T)$ são subespaços vetoriais. A demonstração é a mesma que no contexto do núcleo e do espaço coluna de uma matriz.

Tendo definido estes conceitos, vamos agora definir o conceito de injetividade, e relacioná-lo com o núcleo e de uma transformação.

Definição 6.2.3 (Injetividade). *Seja $T : U \rightarrow V$ uma transformação linear. Dizemos que T é **injetiva** se $T(u) = T(v)$ implica em $u = v$.*

Nós poderíamos substituir a definição da seguinte forma: T é injetiva se $u \neq v$ implica em $T(u) \neq T(v)$. Ou seja, entradas diferentes produzem saídas diferentes.

A injetividade de uma transformação linear está diretamente relacionada com o seu núcleo, como nós veremos a seguir:

Proposição 6.2.4. *Seja $T : U \rightarrow V$ uma transformação linear. Então, T é injetiva se, e somente se, $N(T) = \{0\}$.*

Demonstração. $\Rightarrow$ *Suponha que T é injetiva. Nós queremos provar que $N(T) = \{0\}$. Nós sabemos que $\{0\} \subseteq N(T)$ (afinal, $T(0) = 0$). Para provar a inclusão na outra direção, suponha que $v \in N(T)$. Então:*

$$T(v) = 0 = T(0).$$

Pela injetividade de T , segue que $T(v) = T(0) \iff v = 0$. Logo, $N(T) \subseteq \{0\}$. Portanto, $N(T) = \{0\}$.

$\Leftarrow$ *Suponha agora que $N(T) = \{0\}$. Nós queremos provar que T é injetiva. Para isso, sejam $u, v \in U$ e suponha que $T(u) = T(v)$. Então:*

$$T(u) - T(v) = T(u - v) = 0.$$

Assim sendo, $u - v \in N(T) = \{0\}$. Logo, $u - v = 0$, o que implica que $u = v$. Assim sendo, T é injetiva.

□

Esta discussão formaliza o que nós já havíamos comentado no capítulo anterior: o núcleo de uma transformação linear mede a sua injetividade. Conhecendo o núcleo, nós sabemos o quão próxima ou distante está uma transformação linear de ser injetiva. Particularmente, se a transformação for $0 : U \rightarrow V$ definida como $0(x) = 0, \forall x \in U$, então todos os vetores em U pertencem a $N(0)$ e, neste caso, nós temos a máxima distância que uma transformação linear pode estar de ser injetiva.

Agora, nós vamos definir a sobrejetividade de uma transformação linear:

Definição 6.2.5. *Seja $T : U \rightarrow V$ uma transformação linear. Dizemos que T é sobrejetiva se $Im(T) = V$.*

Ou seja, se para cada elemento $v \in V$, existir pelo menos um elemento $u \in U$ tal que $T(u) = v$, a transformação é sobrejetiva. Note que a sobrejetividade depende do contra-domínio de T . Suponha, por exemplo, que nós definimos o operador derivada como $D : \mathcal{P}_n \rightarrow \mathcal{P}_n$ tal que $D(p) = p'$. Esta transformação não é sobrejetiva, pois, por exemplo, o polinômio x^n não está em $Im(D)$. Por sua vez, se nós definimos o operador derivada como $D : \mathcal{P}_n \rightarrow \mathcal{P}_{n+1}$ tal que $D(p) = p'$, então a transformação passa a ser sobrejetiva, pois a sua imagem corresponde ao contra-domínio inteiro.

Um resultado que nós já tínhamos para as matrizes, mas que também é válido para toda e qualquer transformação linear em espaços vetoriais de dimensão finita, é o seguinte:

Teorema 6.2.6 (Teorema do Núcleo e da Imagem). *Seja $T : U \rightarrow V$ uma transformação linear. Então:*

$$\dim U = \dim N(T) + \dim Im(T).$$

Este teorema é basicamente o Teorema do Posto, só que agora nós estamos olhando para transformações lineares em geral.

6.3 Matriz de uma Transformação Linear

Deixemos de lado a injetividade e a sobrejetividade por um momento. Queremos agora responder a uma outra pergunta: “Se $\dim U = n$, quanto precisamos conhecer da transformação linear $T : U \rightarrow V$ para sabermos $T(u)$ para todo $u \in U$?”. A esta pergunta, nós respondemos com o seguinte teorema:

Teorema 6.3.1. *Seja $\{u_1, \dots, u_n\}$ uma base de U . Então,*

$$T(u) = x_1 T(u_1) + \dots + x_n T(u_n),$$

onde $u = x_1 u_1 + \dots + x_n u_n$, com $x_i \in \mathbb{R}$.

Demonstração. *Nós sabemos que $\{u_1, \dots, u_n\}$ é uma base para U . Assim sendo, nós temos que, para todo $u \in U$, existem únicos $x_1, \dots, x_n$ reais tais que $u = x_1 u_1 + \dots + x_n u_n$. Assim sendo:*

$$T(u) = T(x_1 u_1 + \dots + x_n u_n) = T(x_1 u_1) + \dots + T(x_n u_n) = x_1 T(u_1) + \dots + x_n T(u_n).$$

□

Em resumo, o que este teorema nos diz é que, se nós queremos saber como uma transformação linear age sobre todos os vetores do seu domínio, basta saber como ela age sobre os vetores de uma base do seu domínio, dado que qualquer outro vetor neste espaço é uma combinação linear dos vetores da base.

Por sua vez, mantendo $\{u_1, \dots, u_n\}$ como uma base de U , e supondo que $\dim V = m$ e que $\{v_1, \dots, v_m\}$ é uma base para V , nós podemos escrever:

$$T(u_j) = a_{1j}v_1 + \dots + a_{mj}v_m,$$

para $j \in \{1, \dots, n\}$. Assim sendo, nós temos que:

$$T(u) = \sum_{j=1}^n x_j T(u_j) = \sum_{j=1}^n x_j \sum_{i=1}^m a_{ij} v_i = \sum_{i=1}^m \left(\sum_{j=1}^n a_{ij} x_j \right) v_i = \sum_{i=1}^m (Ax)_i v_i.$$

Isso quer dizer que, dadas duas bases $\{u_1, \dots, u_n\}$ para U e $\{v_1, \dots, v_m\}$ para V , existe uma matriz A tal que $T : U \rightarrow V$ pode ser definida como:

$$T(u) = \sum_{i=1}^m (Ax)_i v_i.$$

Nós chamamos a matriz A de **matriz da transformação linear T relativa às bases $\{u_1, \dots, u_n\}$ e $\{v_1, \dots, v_m\}$** .

Disto segue o seguinte resultado:

Proposição 6.3.2. *Seja $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ uma transformação linear, e considere as bases canônicas para o domínio e para o contradomínio. Então, $T(x) = Ax$.*

Demonstração. *Nós temos que o vetor $u \in \mathbb{R}^n$ pode ser escrito, na base canônica, como:*

$$u = x_1 e_1 + \dots + x_n e_n = x.$$

Assim sendo, nós temos que:

$$T(u) = T(x) = \sum_{i=1}^m (Ax)_i e_i = \sum_{i=1}^m (Ax)_i = Ax.$$

Logo, $T(x) = Ax$.

□

Vamos considerar um exemplo simples:

Exemplo 6.3.3. *Considere a transformação linear $T : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ definida como $T(x, y, z) = (x + y, y + z)$, em que $\left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}$ é uma base para $\mathbb{R}^3$ e $\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 2 \\ 3 \end{bmatrix} \right\}$ é uma base para $\mathbb{R}^2$. Nós queremos encontrar a matriz A da transformação linear T nestas bases. Para isto, nós devemos calcular a transformação em cada vetor da base do domínio, e escrever os resultados como combinações lineares dos vetores da base do contradomínio. Os coeficientes dessas combinações lineares formarão as colunas da matriz A .*

Primeiramente, nós temos que:

$$T \left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \right) = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 1 \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 0 \cdot \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

Neste caso, é fácil encontrar os coeficientes:

$$T\left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}\right) = 1 \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 0 \cdot \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

Em seguida, calculamos:

$$T\left(\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Para encontrar os coeficientes, resolvemos o seguinte sistema linear:

$$\begin{cases} x + 2y = 2 \\ 3y = 1 \end{cases}$$

Assim sendo, $y = \frac{1}{3}$ e $x = \frac{4}{3}$. Logo:

$$T\left(\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}\right) = \frac{4}{3} \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \frac{1}{3} \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

Por fim, nós calculamos:

$$T\left(\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}\right) = \begin{bmatrix} 2 \\ 2 \end{bmatrix}.$$

Para achar os coeficientes, nós resolvemos o seguinte sistema linear:

$$\begin{cases} x + 2y = 2 \\ y = 2 \end{cases}$$

Assim sendo, $y = 2$ e $x = -2$. Logo:

$$T\left(\begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}\right) = -2 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + 2 \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

Assim sendo, a matriz A relativa às bases dadas é:

$$A = \begin{bmatrix} 1 & 4/3 & -2 \\ 0 & 1/3 & 2 \end{bmatrix}.$$

6.4 Composição de Transformações Lineares

Na seção anterior, nós aprendemos que transformações lineares podem ser representadas por matrizes quando nós conhecemos uma base para o domínio e uma base para o contradomínio. Assim sendo, é razoável que a multiplicação de matrizes tenha um significado em termos das transformações lineares que elas representam. Para isto, nós vamos apresentar o conceito de composição de transformações lineares.

Definição 6.4.1 (Composição de duas transformações lineares). *Sejam $T_1 : V \rightarrow W$ e $T_2 : U \rightarrow V$ duas transformações lineares. Então, a **composição** de T_1 com T_2 é definida como:*

$$\begin{aligned} T_1 \circ T_2 : U &\rightarrow W \\ x &\mapsto T_1(T_2(x)) \end{aligned}$$

Com este conceito em mãos, nós podemos enunciar e demonstrar o fato que relaciona a composição de transformações lineares com a multiplicação de matrizes:

Teorema 6.4.2. *Sejam $T_1 : V \rightarrow W$ e $T_2 : U \rightarrow V$ duas transformações lineares com matrizes A e B , respectivamente. Suponha ainda que $\dim U = n$, $\dim V = m$ e $\dim W = p$. Então:*

$$(T_1 \circ T_2)(u) = ABu.$$

Demonstração. *Sejam $\{u_1, \dots, u_n\}$, $\{v_1, \dots, v_m\}$ e $\{w_1, \dots, w_p\}$ bases, respectivamente, para U , V e W . Então:*

$$T_1(v) = \sum_{i=1}^m \sum_{k=1}^p a_{ki} y_i w_k,$$

onde $v = \sum_{i=1}^m y_i v_i$, e:

$$T_2(u) = \sum_{j=1}^n \sum_{i=1}^m b_{ij} x_j v_i,$$

onde $u = \sum_{j=1}^n x_j u_j$.

Denote por C a matriz de $T_1 \circ T_2 : U \rightarrow W$. Queremos provar que $C = AB$. Sabemos que:

$$(T_1 \circ T_2)(u) = \sum_{j=1}^n \sum_{k=1}^p c_{kj} x_j w_k.$$

Como $T_2(u) = \sum_{j=1}^n \sum_{i=1}^m b_{ij} x_j v_i$, invertendo a ordem dos somatórios nós obtemos:

$$T_2(u) = \sum_{i=1}^m \sum_{j=1}^n b_{ij} x_j v_i = \sum_{i=1}^m y_i v_i,$$

com $y_i = \sum_{j=1}^n b_{ij} x_j = (Bx)_i$.

Assim sendo, segue que:

$$\begin{aligned} (T_1 \circ T_2)(u) &= T_1(T_2(u)) = \sum_{i=1}^m \sum_{k=1}^p a_{ki} y_i w_k = \sum_{i=1}^m \sum_{k=1}^p a_{ki} \left(\sum_{j=1}^n b_{ij} x_j \right) w_k \\ &= \sum_{j=1}^n \sum_{k=1}^p \left(\sum_{i=1}^m a_{ki} b_{ij} \right) x_j w_k. \end{aligned}$$

Logo, $c_{kj} = \sum_{i=1}^m a_{ki} b_{ij}$, o que ocorre se, e somente se, $C = AB$.

□

Isto explica, por exemplo, a regra das dimensões na multiplicação de matrizes. Também explica o motivo pelo qual a fórmula da multiplicação de matrizes é como é, e não, por exemplo, uma multiplicação elemento a elemento: porque uma multiplicação de matrizes é uma forma de representar uma composição de transformações lineares.

6.5 Bijeções e Isomorfismos

Nesta seção, nós introduziremos alguns conceitos novos envolvendo transformações lineares e espaços vetoriais. Há algumas seções, nós definimos os conceitos de injetividade e sobrejetividade. No entanto, um caso muito importante ocorre quando a transformação linear é injetiva e sobrejetiva ao mesmo tempo.

Definição 6.5.1 (Bijetividade). *Suponha que $T : U \rightarrow V$ é uma transformação, ao mesmo tempo, injetiva e sobrejetiva. Dizemos então que T é **bijetiva**.*

Assim como existem matrizes que são invertíveis, nós podemos dizer que existem transformações lineares invertíveis. Vamos definir formalmente este conceito:

Definição 6.5.2 (Inversa de uma transformação linear). *Seja $T : U \rightarrow V$ uma transformação linear tal que existe uma transformação linear $S : V \rightarrow U$ que satisfaz as seguintes propriedades:*

- 1) $S \circ T = I : U \rightarrow U$;
- 2) $T \circ S = I : V \rightarrow V$.

*Então, dizemos que S é uma **inversa** da transformação T , e dizemos que T é **invertível**.*

Agora, nós provaremos o resultado que nós permite falar em “a inversa” de uma transformação linear.

Proposição 6.5.3 (Unicidade da inversa de uma transformação linear). *Seja $T : U \rightarrow V$ uma transformação linear invertível. Então, a inversa de T é única.*

Demonstração. *Suponha que S_1 e S_2 são inversas de T . Então:*

$$S_1 = S_1 \circ I = S_1 \circ (T \circ S_2) = (S_1 \circ T) \circ S_2 = I \circ S_2 = S_2.$$

Logo, $S_1 = S_2$.

□

Neste caso, como a inversa de uma transformação linear invertível T é única, nós a denotamos por T^{-1} .

Um fato bastante intuitivo sobre a invertibilidade de uma transformação linear é o seguinte:

Teorema 6.5.4. *Seja $T : U \rightarrow V$ uma transformação linear. Então, T é invertível se, e somente se, T é bijetora.*

Demonstração. $\Rightarrow$ *Suponha que T é invertível. Devemos mostrar que T é bijetora, ou seja, devemos mostrar que T é injetora e sobrejetora. Para mostrar que T é injetora, suponha que $u, v \in U$ são tais que $T(u) = T(v)$. Então:*

$$u = T^{-1}T(u) = T^{-1}T(v) = v,$$

logo $u = v$. Assim sendo, T é injetora.

Para mostrar que T é sobrejetora, seja $v \in V$. Então, $v = T(T^{-1}(v))$, o que mostra que $v \in \text{Im}(T)$. Logo, $\text{Im}(T) = V$, ou seja, T é sobrejetora.

Logo, T é bijetora.

$\Leftarrow$ Suponha que T é bijetora. Nós queremos provar que T é invertível. Para isso, para cada $v \in V$, defina $S(v)$ como o único elemento de V tal que $T(S(v)) = v$ (a existência e a unicidade deste elemento vem da bijetividade de T , assumida por hipótese). A definição de S implica que $T \circ S = I : V \rightarrow V$.

Para provar que $S \circ T = I : U \rightarrow U$, seja $u \in U$. Então:

$$T((S \circ T)(u)) = (T \circ S)(T(u)) = I(T(u)) = T(u).$$

Esta equação implica que $(S \circ T)(u) = u$ (pela injetividade de T), logo $S \circ T = I : U \rightarrow U$.

Para completar a prova, devemos mostrar que S é uma transformação linear. Para fazer isto, suponha que $v_1, v_2 \in V$. Então:

$$T(S(v_1) + S(v_2)) = T(S(v_1)) + T(S(v_2)) = v_1 + v_2.$$

Pela injetividade de T , segue que $S(v_1) + S(v_2)$ é o único elemento de U que T leva em $v_1 + v_2$. Pela definição de S , segue que $S(v_1 + v_2) = S(v_1) + S(v_2)$.

Agora, sejam $v \in V$ e $\alpha \in \mathbb{R}$. Então:

$$T(\alpha S(v)) = \alpha T(S(v)) = \alpha v.$$

Assim sendo, $\alpha S(v)$ é o único elemento de U que T leva em αv . Logo, pela definição de S , segue que $S(\alpha v) = \alpha S(v)$.

Portanto, S é uma transformação linear e, como também é a inversa de T , segue que T é invertível. □

Agora, nós vamos introduzir uma ideia muito interessante que permite relacionar certos espaços vetoriais.

Definição 6.5.5 (Isomorfismo). Seja $T : U \rightarrow V$ uma transformação linear invertível. Dizemos que T é um **isomorfismo** entre U e V , e dizemos que U e V são **isomorfos**.

Se U e V são dois espaços vetoriais isomorfos, nós usamos a seguinte notação: $U \cong V$. Na prática, é muito intuitivo saber quando dois espaços vetoriais são isomorfos: basta olhar para as suas dimensões.

Teorema 6.5.6. Sejam U e V dois espaços vetoriais. Então, $U \cong V$ se, e somente se, $\dim U = \dim V$.

Demonstração. $\Rightarrow$ Suponha que $U \cong V$. Então, existe um isomorfismo $T : U \rightarrow V$. Como T é invertível, nós temos que $N(T) = \{0\}$ e $\text{Im}(T) = V$. Assim sendo, $\dim N(T) = 0$ e $\dim \text{Im}(T) = \dim V$. Pelo Teorema do Núcleo e da Imagem, nós temos que:

$$\dim U = \dim N(T) + \dim \text{Im}(T) \Rightarrow \dim U = 0 + \dim V \Rightarrow \dim U = \dim V.$$

$\Leftarrow$ Suponha que $\dim U = \dim V$. Sejam $\{u_1, \dots, u_n\}$ e $\{v_1, \dots, v_n\}$ bases para U e V , respectivamente. Definamos $T : U \rightarrow V$ como:

$$T(c_1u_1 + \cdots + c_nu_n) = c_1v_1 + \cdots + c_nv_n.$$

Então, T é uma transformação linear bem-definida porque $\{u_1, \dots, u_n\}$ é uma base de U . Igualmente, T é sobrejetiva porque $\text{span}(\{v_1, \dots, v_n\}) = V$. Finalmente, $N(T) = \{0\}$ porque $\{v_1, \dots, v_n\}$ é linearmente independente. Assim sendo, T é injetiva. Logo, T é bijetora e, portanto, é um isomorfismo. Assim sendo, $U \cong V$. $\square$

Um exemplo muito intuitivo de espaços vetoriais isomorfos é o seguinte:

Exemplo 6.5.7. Considere os espaços vetoriais $\mathbb{R}^2$ e $\mathbb{C}$ (ambos definidos sobre $\mathbb{R}$, nestas notas de aula, a menos que se fale o contrário, nós estamos sempre considerando isto, mas num contexto mais geral, esta observação é muito importante, dado que apenas dois espaços definidos sobre um mesmo corpo podem ser isomorfos). Então, $\mathbb{R}^2 \cong \mathbb{C}$. De fato, o conjunto $\left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}$ é uma base para $\mathbb{R}^2$, e o conjunto $\{1, i\}$ é uma base para $\mathbb{C}$. Logo, ambos os espaços possuem dimensão igual a 2 e, pelo teorema anterior, segue que $\mathbb{R}^2 \cong \mathbb{C}$.

Um isomorfismo explícito entre estes dois espaços é a transformação linear $T : \mathbb{R}^2 \rightarrow \mathbb{C}$ definida por:

$$T(x, y) = x + iy.$$

Podemos demonstrar facilmente que esta transformação é bijetiva e, portanto, é um isomorfismo.

Na prática, um isomorfismo entre dois espaços é uma transformação que preserva soma e multiplicação por escalar. Isso pode ser usado para demonstrar que uma transformação é um isomorfismo, se for mais fácil.

Por fim, vamos fazer a última definição desta seção, que se refere ao contexto em que o isomorfismo acontece entre dois espaços iguais:

Definição 6.5.8 (Automorfismo). Suponha que a transformação linear $T : U \rightarrow U$ é um isomorfismo. Neste caso, dizemos que T é um **automorfismo**.

Um exemplo muito simples de automorfismo é a transformação identidade $I : \mathbb{R}^n \rightarrow \mathbb{R}^n$, definida por $I(x) = x$. Esta transformação é claramente bijetora e, portanto, é um isomorfismo de $\mathbb{R}^n$ em $\mathbb{R}^n$. Logo, é um automorfismo.

6.6 Coordenadas e Mudança de Bases

Após termos feito um breve passeio por bijeções e isomorfismos, vamos voltar à ideia de representação matricial de transformações lineares. Quando nós fizemos um exemplo sobre este tema, nós usamos duas bases diferentes da base canônica. É mais fácil fazer isto usando a base canônica, porque não é necessário resolver nenhum sistema linear para encontrar as entradas da matriz. Porém, é muito importante saber trabalhar com bases diferentes (sobretudo em alguns problemas mais aplicados, como o de interpolação polinomial, que nós veremos mais profundamente em Álgebra Linear Numérica). É o que nós faremos de um modo mais sistemático neste capítulo.

Os coeficientes que nós procurávamos naquele exemplo serão precisamente a definição que nós faremos agora:

Definição 6.6.1 (Coordenadas). *Seja U um espaço vetorial com $\dim U = n$, e seja $\mathcal{U} = \{u_1, \dots, u_n\}$ uma base para U . Sabemos que, para cada $u \in U$, existem únicos*

escalares $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$ tais que $u = x_1 u_1 + x_2 u_2 + \dots + x_n u_n$. Então, nós definimos x como

*as **coordenadas** de u na base $\mathcal{U}$, e escrevemos:*

$$[u]_{\mathcal{U}} = x.$$

Uma propriedade interessante, muito embora seja muito intuitiva, é a linearidade das coordenadas:

Proposição 6.6.2. *Sejam U um espaço vetorial com $\dim U = n$ e base $\mathcal{U} = \{u_1, \dots, u_n\}$, e $u, v \in U$. Então:*

$$[\alpha u + v]_{\mathcal{U}} = \alpha[u]_{\mathcal{U}} + [v]_{\mathcal{U}}.$$

Demonstração. *Considere $u = x_1 u_1 + \dots + x_n u_n$, com $[u]_{\mathcal{U}} = x$, e $v = y_1 u_1 + \dots + y_n u_n$, com $[v]_{\mathcal{U}} = y$. Então:*

$$\begin{aligned} \alpha u + v &= \alpha(x_1 u_1 + \dots + x_n u_n) + y_1 u_1 + \dots + y_n u_n = (\alpha x_1 + y_1) u_1 + \dots + (\alpha x_n + y_n) u_n \\ &\implies [\alpha u + v]_{\mathcal{U}} = \alpha x + y = \alpha[u]_{\mathcal{U}} + [v]_{\mathcal{U}}. \end{aligned}$$

□

Nós usamos este conceito de coordenadas para empregar o seguinte raciocínio: se $T : U \rightarrow V$ é uma transformação linear, então denotamos:

$$[T]_{\mathcal{U}} = A = \begin{bmatrix} \begin{array}{c} | \\ [T(u_1)]_{\mathcal{U}} \\ | \end{array} & \begin{array}{c} | \\ [T(u_2)]_{\mathcal{U}} \\ | \end{array} & \cdots & \begin{array}{c} | \\ [T(u_n)]_{\mathcal{U}} \\ | \end{array} \end{bmatrix}.$$

Se $\dim U = n$ e $\dim V = m$, então esta matriz é $m \times n$. Em suma, é o que nós fizemos quando estávamos falando da representação matricial de uma transformação linear com relação a uma base do domínio e a uma base do contradomínio. A grande diferença entre uma transformação linear e a sua representação matricial é que uma transformação linear não depende de coordenadas, mas a sua representação matricial sim.

Fixadas uma base para o domínio e uma para o contradomínio, a representação matricial de uma transformação linear é única. E como é bem fácil trabalhar com matrizes, isto ajuda a facilitar as contas.

Uma propriedade desta representação de uma transformação linear é a seguinte:

Proposição 6.6.3. *Seja $T : U \rightarrow V$ uma transformação linear. Então:*

$$[T(u)]_{\mathcal{U}} = [T]_{\mathcal{U}}[u]_{\mathcal{U}}.$$

Demonstração. *Nós sabemos que $T(u) = T\left(\sum_{i=1}^n x_i u_i\right)$, onde $x = [u]_{\mathcal{U}}$. Como T é uma transformação linear, segue que $T\left(\sum_{i=1}^n x_i u_i\right) = \sum_{i=1}^n x_i T(u_i)$. Assim sendo, nós obtemos:*

$$[T(u)]_{\mathcal{U}} = \sum_{i=1}^n x_i [T(u_i)]_{\mathcal{U}} = [T]_{\mathcal{U}} [u]_{\mathcal{U}},$$

já que $[T(u_i)]_{\mathcal{U}}$ corresponde às colunas de $[T]_{\mathcal{U}}$.

□

Isto confirma a nossa ideia de que existe uma correspondência entre aplicar uma transformação linear a um vetor e multiplicar uma matriz por um vetor.

Mas agora, nós sabemos que um mesmo espaço vetorial pode possuir muitas bases diferentes. Então, como podemos fazer uma mudança de bases dentro de um espaço vetorial? Se praticamente tudo o que estamos fazendo envolve matrizes, neste caso não é diferente: nós encontraremos uma matriz que realiza este tipo de transformação.

Sejam $\mathcal{U} = \{u_1, \dots, u_n\}$ e $\mathcal{V} = \{v_1, \dots, v_n\}$ duas bases do espaço vetorial U . Nós vamos verificar que:

$$P = \begin{bmatrix} | & | & \cdots & | \\ [u_1]_{\mathcal{V}} & [u_2]_{\mathcal{V}} & \cdots & [u_n]_{\mathcal{V}} \\ | & | & \cdots & | \end{bmatrix}$$

muda os vetores na base $\mathcal{U}$ para a base $\mathcal{V}$. (ou seja, $[u]_{\mathcal{V}} = P[u]_{\mathcal{U}}$).

De fato, sejam $x = [u]_{\mathcal{U}}$, $y = [u]_{\mathcal{V}}$ e $p_j = [u_j]_{\mathcal{V}}$. Então, $u = \sum_{j=1}^n x_j u_j$. No entanto, na base $\mathcal{V}$, $u_j = \sum_{i=1}^n p_{ij} v_i$. Assim sendo:

$$u = \sum_{j=1}^n x_j \sum_{i=1}^n p_{ij} v_i = \sum_{i=1}^n \left(\sum_{j=1}^n p_{ij} x_j \right) v_i = \sum_{i=1}^n y_i v_i.$$

Logo, $y = Px$, ou seja, $[u]_{\mathcal{V}} = P[u]_{\mathcal{U}}$. Por consequência, segue que $[u]_{\mathcal{U}} = P^{-1}[u]_{\mathcal{V}}$.

Por meio desta discussão, podemos chegar à seguinte conclusão:

Teorema 6.6.4. *Seja $T : U \rightarrow U$ uma transformação linear e considere $A = [T]_{\mathcal{U}}$ e $B = [T]_{\mathcal{V}}$. Então, $A = P^{-1}BP$.*

Demonstração. *Nós temos que:*

$$\begin{aligned} (P^{-1}BP)[u]_{\mathcal{U}} &= P^{-1}B(P[u]_{\mathcal{U}}) = P^{-1}[T]_{\mathcal{V}}[u]_{\mathcal{V}} = P^{-1}[T(u)]_{\mathcal{V}} \\ &= [T(u)]_{\mathcal{U}} = [T]_{\mathcal{U}}[u]_{\mathcal{U}} = A[u]_{\mathcal{U}}. \end{aligned}$$

Logo, $A = P^{-1}BP$.

□

Vamos fazer um exemplo bem simples para encerrar a parte teórica deste capítulo:

Exemplo 6.6.5. *Sejam $\mathcal{U} = \left\{ \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \begin{bmatrix} 4 \\ 5 \end{bmatrix} \right\} = \{u_1, u_2\}$ e $\mathcal{V} = \left\{ \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\} = \{v_1, v_2\}$ duas bases para $\mathbb{R}^2$. Então, a matriz que faz a mudança de base de $\mathcal{U}$ para $\mathcal{V}$ é:*

$$P = \begin{bmatrix} | & | \\ [u_1]_{\mathcal{V}} & [u_2]_{\mathcal{V}} \\ | & | \end{bmatrix}.$$

Primeiro, nós obtemos o sistema:

$$\begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix} x = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$$

Resolvendo, nós obtemos $x = \begin{bmatrix} 1/2 \\ 5/2 \end{bmatrix}$, que corresponde à primeira coluna de P .

Agora, nós obtemos o sistema:

$$\begin{bmatrix} -1 & 1 \\ 1 & 1 \end{bmatrix} x = \begin{bmatrix} 4 \\ 5 \end{bmatrix},$$

que, resolvendo, nos dá $x = \begin{bmatrix} 1/2 \\ 9/2 \end{bmatrix}$. Logo, a matriz de mudança de base P é:

$$P = \begin{bmatrix} 1/2 & 1/2 \\ 5/2 & 9/2 \end{bmatrix}.$$

6.7 Exercícios

Importante: Alguns dos exercícios são baseados em (7).

6.1) Considere a transformação $T : \mathbb{R} \rightarrow \mathbb{R}^3$ definida por:

$$T(x) = (x, 2x, 3x)^T.$$

Esta transformação é linear? Demonstre a sua resposta. E se trocarmos a última coordenada por $x + 1$?

6.2) Prove que a transformação $T : \mathcal{P}_n \rightarrow \mathbb{R}$, definida como:

$$T(p) = \int_0^1 p(x) dx$$

é uma transformação linear.

6.3) Por que a transformação $T : \mathcal{P}_n \rightarrow \mathcal{P}_{n+1}$, definida por:

$$T(p) = \int p(x) dx$$

não é linear?

6.4) Considere a transformação linear $T : \mathbb{R}^3 \rightarrow \mathbb{R}^2$, dada por:

$$T(x, y, z) = (2x + 3y, y - z)^T.$$

Encontre $N(T)$ e $Im(T)$.

6.5) Considere a transformação linear $T : \mathcal{P}_n \rightarrow \mathcal{P}_{n+1}$ definida por:

$$T(p) = \int_0^x p(t) dt.$$

Encontre o núcleo e a imagem de T . Esta transformação é injetiva? Ela é sobrejetiva?

6.6) Suponha que V e W são dois espaços vetoriais tais que $\dim V > \dim W$. Prove que nenhuma transformação linear $T : V \rightarrow W$ é injetiva.

6.7) Suponha que V e W são dois espaços vetoriais tais que $\dim V < \dim W$. Prove que nenhuma transformação linear $T : V \rightarrow W$ é sobrejetiva.

6.8) Considere a transformação linear $D : \mathcal{P}_n \rightarrow \mathcal{P}_{n-1}$ definida por:

$$D(p) = p'.$$

Encontre a matriz de D com relação às bases canônicas.

6.9) Considere uma transformação linear $T : V \rightarrow V$ qualquer. Prove que a transformação $T^n : V \rightarrow V$, definida como:

$$T^n(x) = (\underbrace{T \circ T \circ \cdots \circ T}_{n \text{ vezes}})(x)$$

é linear. Prove ainda que, se A é a matriz de T em relação à base canônica, então A^n é a matriz de T^n em relação à base canônica.

6.10) Considere a transformação linear $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ definida como:

$$T(x, y) = (x + y, x - y)^T.$$

Esta transformação é bijetiva? Se sim, encontre a sua inversa T^{-1} .

6.11) Prove que $\mathcal{P}_n \cong \mathbb{R}^{n+1}$ de duas formas:

- Demonstrando que ambos os espaços possuem mesma dimensão.
- Exibindo um isomorfismo explícito entre os dois espaços (é necessário demonstrar que a transformação linear em questão é um isomorfismo).

6.12) Demonstre que $\mathbb{R}^n \cong \mathbb{C}^m$ se, e somente se, $n = 2m$.

6.13) Demonstre que $\mathbb{R}^{m \times n} \cong \mathbb{R}^{mn}$ exibindo um isomorfismo explícito entre os dois espaços.

6.14) Demonstre que a transformação linear $T : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ definida como:

$$T(x, y) = (y, x)^T$$

é um automorfismo. O que esta transformação representa geometricamente?

6.15) Considere as duas seguintes bases para $\mathbb{R}^2$: $\mathcal{U} = \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 0 \end{bmatrix} \right\}$ e $\mathcal{V} = \left\{ \begin{bmatrix} 1 \\ 5 \end{bmatrix}, \begin{bmatrix} 2 \\ 3 \end{bmatrix} \right\}$.

a) Ache a matriz de $T(x, y) = (2x - y, x + 3y)^T$ em relação às bases $\mathcal{U}$ e $\mathcal{V}$.

b) Encontre a matriz P que realiza a mudança de base de $\mathcal{U}$ para $\mathcal{V}$.

c) Considere o vetor $[x]_{\mathcal{U}} = \begin{bmatrix} 5 \\ 3 \end{bmatrix}$. Encontre $[x]_{\mathcal{V}}$.

d) Determine $[T]_{\mathcal{U}}$ e, utilizando a matriz de mudança de base, determine $[T]_{\mathcal{V}}$.

Capítulo 7

Ortogonalidade

Importante: Este capítulo é baseado em (7), (9), (10) e em (11).

Tendo entendido em qual espaço residem os vetores, e como acontecem as transformações entre eles, vamos agora discutir a questão da ortogonalidade. Em $\mathbb{R}^2$ é uma ideia muito simples: dois vetores são ortogonais quando o ângulo entre eles é 90° . Mas como podemos dizer que dois vetores são ortogonais em $\mathbb{R}^n$, para um n qualquer, ou em espaços mais abstratos, como $\mathcal{P}_n$? Mais ainda, será que nós podemos dizer que dois subespaços vetoriais são ortogonais entre si? É o que estudaremos com maior detalhe neste capítulo.

7.1 Norma e Produto Interno

Antes de definirmos o conceito de ortogonalidade, nós vamos definir formalmente os conceitos de produto interno. Lembre-se que, no primeiro capítulo, nós definimos o produto interno euclidiano e a norma euclidiana, mas dissemos que aquele era apenas um produto interno e que esta era apenas uma norma. Tendo, porém, definido o conceito de espaço vetorial, nós estamos prontos para conceituar formalmente o produto interno e a norma como funções. Primeiramente, vamos definir o produto interno:

Definição 7.1.1 (Produto Interno). *Seja V um espaço vetorial definido sobre o corpo $\mathbb{R}$. Um **produto interno** é uma função $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$ tal que, para quaisquer $u, v, w \in V$, todas as seguintes propriedades são satisfeitas:*

- 1) **Simetria:** $\langle u, v \rangle = \langle v, u \rangle$.
- 2) **Positividade Definida:** $\langle v, v \rangle \geq 0$, com $\langle v, v \rangle = 0 \iff v = 0$.
- 3) **Distributividade:** $\langle u + v, w \rangle = \langle u, w \rangle + \langle v, w \rangle$.
- 4) **Homogeneidade:** $\langle \lambda u, v \rangle = \lambda \langle u, v \rangle$, para todo $\lambda \in \mathbb{R}$.

O exemplo mais famoso de produto interno é o produto interno euclidiano, aquele que nós definimos no primeiro capítulo com a notação $u \cdot v$ (ou $u^T v$), para $u, v \in \mathbb{R}^n$ (notações estas que utilizaremos ao longo de todo o texto, pois o produto interno em que estamos interessados é o euclidiano). Um outro exemplo, porém, é o seguinte:

Exemplo 7.1.2. *Sejam p e q dois polinômios em $\mathcal{P}_n$. Um produto interno (não o provaremos) possível entre p e q é dado por:*

$$\langle p, q \rangle = \int_{-1}^1 p(x)q(x) dx.$$

Agora, nós definiremos formalmente o conceito de norma:

Definição 7.1.3 (Norma). *Seja V um espaço vetorial definido sobre o corpo $\mathbb{R}$. Uma **norma** é uma função $\|\cdot\| : V \rightarrow \mathbb{R}$ tal que, para quaisquer $u, v \in V$, todas as seguintes propriedades são satisfeitas:*

- 1) **Positividade Definida:** $\|u\| \geq 0$, e $\|u\| = 0 \iff u = 0$.
- 2) **Homogeneidade Absoluta:** $\|\alpha u\| = |\alpha| \|u\|$, para todo $\alpha \in \mathbb{R}$.
- 3) **Desigualdade Triangular:** $\|u + v\| \leq \|u\| + \|v\|$.

O exemplo mais conhecido de norma é a norma euclidiana em $\mathbb{R}^n$. Na verdade, ela é um caso particular da definição que faremos a seguir (e que não usaremos para mais nada neste curso, a não ser para aumentar a lista de exercícios do capítulo):

Definição 7.1.4 (Norma- p). *Seja $v \in \mathbb{R}^n$. Definimos a **norma- p** de v como:*

$$\|v\|_p = \left(\sum_{i=1}^n |v_i|^p \right)^{\frac{1}{p}}, 1 \leq p < \infty.$$

A norma euclidiana nada mais é do que a norma-2 de um vetor em $\mathbb{R}^n$. A norma-1, a título de curiosidade, é conhecida como a “norma de Manhattan”, ou “métrica do táxi”. E, é claro, podemos definir outras normas, como, por exemplo, a norma- ∞ . No entanto, neste curso, estaremos preocupados apenas com a norma euclidiana (ou norma-2) de um vetor em $\mathbb{R}^n$.

Um ponto interessante de se notar é o fato de que a norma se parece muito com o produto interno. De fato, existem espaços vetoriais que não possuem norma, e existem espaços vetoriais que não possuem produto interno. Nos espaços que possuem um produto interno, tal função induz uma norma, porém nem toda norma provém de um produto interno (mesmo nestes espaços). E, de igual modo, um espaço vetorial que possui norma pode não possuir um produto interno.

Mas não se preocupem com este fato, eu apenas o escrevi para mostrar alguns fatos mais avançados de Álgebra Linear. Nas nossas notas de aula, nós trabalharemos essencialmente com a norma euclidiana e o produto interno euclidiano (a não ser nos exercícios, que por vezes podem trazer coisas mais interessantes).

7.2 Ortogonalidade

Agora sim, vamos ao que interessa. A partir deste capítulo, toda vez que falarmos em norma e em produto interno nós estaremos interessados especificamente na norma e produto interno euclidianos, em espaços vetoriais euclidianos.

Em $\mathbb{R}^2$, é muito fácil pensar de forma geométrica na ortogonalidade entre dois vetores. Analisamos apenas o ângulo entre eles, e se for um ângulo reto, eles são ortogonais. Em $\mathbb{R}^3$, ainda é fácil pensar nesta noção, mas já não é algo tão intuitivo. Em $\mathbb{R}^n$, com $n \geq 4$, é pior ainda. Nem conseguimos imaginar geometricamente o que está acontecendo. Assim sendo, nós precisamos definir ortogonalidade entre vetores de um modo tal que não olhemos para o ângulo entre os vetores, e sim unicamente para os vetores. É o que nós faremos agora:

Definição 7.2.1 (Vetores ortogonais). *Seja V um espaço vetorial, com $u, v \in V$. Dizemos que u e v são **ortogonais** se $v^T u = 0$, e escrevemos $v \perp u$.*

Um fato importante é o seguinte: $\|u\|^2 = u^T u = u \cdot u$. Com estas definições em mãos, nós conseguimos demonstrar o Teorema de Pitágoras em um espaço real n -dimensional.

Teorema 7.2.2 (Teorema de Pitágoras). *Sejam u e v dois vetores ortogonais em $\mathbb{R}^n$. Então, $\|v + u\|^2 = \|v\|^2 + \|u\|^2$.*

Demonstração. *Pela definição do produto interno euclidiano, nós temos que:*

$$\begin{aligned}\|v + u\|^2 &= (v + u)^T(v + u) = (v^T + u^T)(v + u) \\ &= v^T v + v^T u + u^T v + u^T u = v^T v + 2u^T v + u^T u.\end{aligned}$$

Como u e v são ortogonais, segue que $u^T v = 0$. Assim sendo, nós temos que:

$$\|v + u\|^2 = v^T v + u^T u = \|v\|^2 + \|u\|^2.$$

□

Para não ficarmos unicamente no mundo abstrato dos espaços vetoriais, vamos fazer uma ilustração geométrica que ajudará a compreender melhor as ideias:




Figura 7.1: Teorema de Pitágoras (arquivo pessoal)

Tendo definido a ortogonalidade entre dois vetores, nós podemos começar a pensar na ortogonalidade entre dois subespaços vetoriais. A ideia é muito simples: dois subespaços serão ortogonais se todos os vetores de um subespaço forem ortogonais a todos os vetores do outro subespaço. Definindo isto formalmente:

Definição 7.2.3 (Subespaços vetoriais ortogonais). *Sejam U e V dois subespaços vetoriais de E . Dizemos que U é **ortogonal** a V se $u \perp v$ para todos $u \in U$ e $v \in V$, e escrevemos $U \perp V$.*

Uma consequência direta desta definição é o seguinte fato:

Proposição 7.2.4. *Sejam U e V dois subespaços vetoriais de E tais que $U \perp V$. Então, $w \in U \cap V$ se, e somente se, $w = 0$.*

Demonstração. $\implies$ *Suponha que $w \in U \cap V$. Então, $w \in U$ e $w \in V$. Como $U \perp V$, nós temos que $w^T w = 0$. Ou seja, $\|w\|^2 = 0$. No entanto, isto acontece se, e somente se, $w = 0$.*

$\impliedby$ *Suponha que $w = 0$. Como U e V são subespaços vetoriais, segue que $w \in U$ e $w \in V$. Logo, $w \in U \cap V$.*

□

Vamos mostrar alguns exemplos simples que podem ser visualizados geometricamente:

Exemplo 7.2.5. Considere $E = \mathbb{R}^2$. Então, dadas as retas $U = \{(x, x)^T; x \in \mathbb{R}\}$ e $V = \{(x, -x)^T; x \in \mathbb{R}\}$, nós temos que $U \perp V$. De fato, todo vetor de U é da forma $u = \begin{bmatrix} a \\ a \end{bmatrix}$, e todo vetor de V é da forma $v = \begin{bmatrix} b \\ -b \end{bmatrix}$. Calculando $u^T v$, nós obtemos:

$$u^T v = ab + a(-b) = ab - ab = 0.$$

Logo, todo vetor de U é ortogonal a todo vetor de V . Assim sendo, segue que $U \perp V$.

A figura a seguir ilustra este exemplo:




Figura 7.2: Ortogonalidade em $\mathbb{R}^2$ (arquivo pessoal)

Exemplo 7.2.6. Considere $E = \mathbb{R}^3$. Então, dados o plano $U = \{(x, y, 0)^T; x, y \in \mathbb{R}\}$ e a reta $V = \{(0, 0, z)^T; z \in \mathbb{R}\}$, nós temos que $U \perp V$. De fato, todo vetor de U é da forma $u = \begin{bmatrix} a \\ b \\ 0 \end{bmatrix}$ e todo vetor de V é da forma $v = \begin{bmatrix} 0 \\ 0 \\ c \end{bmatrix}$. Calculando $u^T v$, nós obtemos:

$$u^T v = a \cdot 0 + b \cdot 0 + 0 \cdot c = 0.$$

Logo, todo vetor de U é ortogonal a todo vetor de V . Assim sendo, segue que $U \perp V$.

A figura a seguir ilustra este exemplo:




Figura 7.3: Ortogonalidade em $\mathbb{R}^3$ (arquivo pessoal)

Vamos agora nos voltar para os quatro subespaços fundamentais de uma matriz. No capítulo 4, nós estudamos as suas dimensões e, agora, nós estudaremos as relações de ortogonalidade entre eles. Unindo as suas relações de dimensão e de ortogonalidade, nós obtemos o que foi popularizado por Gilbert Strang como “Teorema Fundamental da Álgebra Linear”. Como, porém, aqui eu quero tratar apenas sobre as relações de ortogonalidade, eu ainda não darei este nome e, no final do capítulo, eu enunciarei as duas partes do Teorema Fundamental da Álgebra Linear (sem fazer a sua demonstração, pois já a teremos feito em diferentes partes destas notas de aula).

Teorema 7.2.7 (Teorema Fundamental da Ortogonalidade). *Seja A uma matriz $m \times n$ qualquer. Então, $N(A) \perp C(A^T)$ e $C(A) \perp N(A^T)$.*

Demonstração. *Primeiro, nós queremos demonstrar que $N(A) \perp C(A^T)$. Para isso, seja $w \in C(A^T)$. Então, existe $y \in \mathbb{R}^m$ tal que $w = A^T y$. Assim sendo, tomando $x \in N(A)$ qualquer, nós temos que:*

$$x^T w = x^T A^T y = (Ax)^T y = 0^T y = 0.$$

Logo, $N(A) \perp C(A^T)$.

Agora, nós queremos demonstrar que $C(A) \perp N(A^T)$. Mas isto segue diretamente do primeiro fato. Nós temos que:

$$N(A^T) \perp C((A^T)^T) = C(A).$$

Logo, $N(A^T) \perp C(A)$.

□

7.3 Complemento Ortogonal

Nesta seção, nós desenvolveremos o conceito de complemento ortogonal. O complemento ortogonal é muito simples: dado um subespaço vetorial V , o seu complemento ortogonal é um conjunto W cujos vetores são ortogonais a V . Definindo de maneira mais formal:

Definição 7.3.1 (Complemento ortogonal). *Seja V um subespaço vetorial de E . Então, definimos o **complemento ortogonal** de V como:*

$$V^\perp = \{w \in E; w \perp V\}.$$

O primeiro resultado a respeito do complemento ortogonal é bastante intuitivo: ele é também um subespaço vetorial.

Proposição 7.3.2. *Seja V um subespaço vetorial de E . Então, $V^\perp$ é também um subespaço vetorial de E .*

Demonstração. *Considere dois vetores $w_1, w_2 \in V^\perp$ e dois escalares $\alpha, \beta \in \mathbb{R}$. Nós queremos provar que $\alpha w_1 + \beta w_2 \in V^\perp$. Ou seja, queremos provar que, para todo $v \in V$, $\alpha w_1 + \beta w_2 \perp v$. De fato, calculando $v^T(\alpha w_1 + \beta w_2)$, nós temos que:*

$$v^T(\alpha w_1 + \beta w_2) = \alpha v^T w_1 + \beta v^T w_2 = \alpha \cdot 0 + \beta \cdot 0 = 0.$$

Logo, nós temos que $\alpha w_1 + \beta w_2 \perp v$ para todo $v \in V$, e portanto, $\alpha w_1 + \beta w_2 \in V^\perp$. □

O fato de $V^\perp$ ser também um subespaço de E nos sugere uma decomposição para qualquer vetor de E que nós discutiremos no futuro. Mas vamos com calma, tudo tem o seu tempo certo. Por agora, vamos desenvolver mais alguns fatos sobre o complemento ortogonal de um subespaço, e depois estaremos prontos para falar melhor sobre isso.

Proposição 7.3.3. *Seja $\{v_1, \dots, v_k\}$ uma base para V . Então, $w \in V^\perp$, se, e somente se, $w \perp v_i$, para todo $i \in \{1, \dots, k\}$.*

Demonstração. $\implies$ *É verdade diretamente da definição de $V^\perp$.*

$\Leftarrow$ *Suponha que $w \perp v_i$, para todo $i \in \{1, \dots, k\}$. Queremos provar que $w \perp \text{span}(\{v_1, \dots, v_k\}) = V$. De fato, seja $v \in \text{span}(\{v_1, \dots, v_k\})$. Então, existem $c_1, \dots, c_k \in \mathbb{R}$ tais que $v = c_1 v_1 + \dots + c_k v_k$. Calculando $w^T v$, nós temos:*

$$w^T v = w^T(c_1 v_1 + \dots + c_k v_k) = c_1 w^T v_1 + \dots + c_k w^T v_k = c_1 \cdot 0 + \dots + c_k \cdot 0 = 0.$$

Logo, pela definição, $w \in V^\perp$. □

Ainda considerando $\{v_1, \dots, v_k\}$ como uma base para V , nós podemos, a partir deste conjunto, encontrar uma base para $V^\perp$. De fato, definamos

$$A = \begin{bmatrix} - & v_1^T & - \\ - & v_2^T & - \\ & \vdots & \\ - & v_k^T & - \end{bmatrix}.$$

Suponha que $x \in N(A)$. Então, nós temos que

$$\begin{bmatrix} - & v_1^T & - \\ - & v_2^T & - \\ & \vdots & \\ - & v_k^T & - \end{bmatrix} x = 0,$$

o que nos dá $v_i^T x = 0$ para cada v_i . Logo, se $x \in N(A)$, então $x \in V^\perp$ e, reciprocamente, se $x \in V^\perp$, então $v_i^T x = 0$ para cada v_i , e, portanto, $x \in N(A)$. Assim sendo, nós temos que $V^\perp = N(A)$ e, portanto, para encontrarmos uma base para $V^\perp$, basta encontrar uma base para $N(A)$. Nós já sabemos fazer isso: basta encontrar a matriz núcleo N .

Exemplo 7.3.4. *Seja $V = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \right\} \right)$ um subespaço de $\mathbb{R}^4$. Como o conjunto*

$\left\{ \begin{bmatrix} 1 \\ 0 \\ 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \right\}$ é LI, nós temos que ele é uma base para V . Nós queremos encontrar uma

base para $V^\perp$. Para fazer isto, definamos a matriz A como:

$$A = \begin{bmatrix} 1 & 0 & 1 & 2 \\ 1 & 2 & 3 & 4 \end{bmatrix}.$$

Fazendo o processo de escalonamento, nós obtemos:

$$\begin{bmatrix} 1 & 0 & 1 & 2 \\ 1 & 2 & 3 & 4 \end{bmatrix} \xrightarrow{L_2 - L_1} \begin{bmatrix} 1 & 0 & 1 & 2 \\ 0 & 2 & 2 & 2 \end{bmatrix} \xrightarrow{L_2/2} \begin{bmatrix} 1 & 0 & 1 & 2 \\ 0 & 1 & 1 & 1 \end{bmatrix} = R.$$

Nós temos que $F = \begin{bmatrix} 1 & 2 \\ 1 & 1 \end{bmatrix}$, e, como nós não fizemos nenhuma permutação entre colunas, $R = R'$ e $N = N'$. Assim sendo, a matriz núcleo é dada por:

$$N = \begin{bmatrix} -1 & -2 \\ -1 & -1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Logo, o conjunto $\left\{ \begin{bmatrix} -1 \\ -1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -2 \\ -1 \\ 0 \\ 1 \end{bmatrix} \right\}$ é uma base para $V^\perp$.

Agora, nós vamos enunciar e demonstrar mais três proposições antes de chegarmos à tão sonhada decomposição ortogonal (este é nome da decomposição de que falamos anteriormente).

Proposição 7.3.5. *Seja V um subespaço vetorial de E . Então, $V \cap V^\perp = \{0\}$.*

Demonstração. $\Rightarrow$ *Considere um vetor w tal que $w \in V \cap V^\perp$. Então, $w \in V$ e $w \in V^\perp$. Assim sendo, $w \perp w$, ou seja, $w^T w = 0$. Segue que $\|w\|^2 = 0$, o que acontece se, e somente se, $w = 0$.*

$\Leftarrow$ *Nós sabemos que, dado um subespaço qualquer U , $0 \in U$. Assim sendo, como $V \cap V^\perp$ é um subespaço vetorial (em algum exercício anterior pede-se para provar este fato), nós temos que $0 \in V \cap V^\perp$. Logo, $\{0\} \subseteq V \cap V^\perp$.*

Logo, $V \cap V^\perp = \{0\}$.

□

Proposição 7.3.6. *Seja V um subespaço vetorial de E . Então, $\dim V + \dim V^\perp = \dim E$.*

Demonstração. Suponha que $\{v_1, \dots, v_r\}$ é uma base para V , com $\dim V = r$ e $\dim E = n$. Então, como nós vimos anteriormente, nós temos que $V^\perp = N(A)$, onde

$$A = \begin{bmatrix} - & v_1^T & - \\ - & v_2^T & - \\ & \vdots & \\ - & v_r^T & - \end{bmatrix}.$$

Assim sendo, nós temos que $\dim C(A^T) = r$ e, conseqüentemente, $\dim C(A) = r$ também. Logo, segue que $\dim N(A) = n - r$. Mas como $V^\perp = N(A)$, nós temos que $\dim V + \dim V^\perp = r + (n - r) = n = \dim E$. □

Proposição 7.3.7. Seja V um espaço vetorial de E . Então, $V = (V^\perp)^\perp$.

Demonstração. Primeiramente, nós vamos demonstrar que $V \subseteq (V^\perp)^\perp$. Para isso, tome $u \in V$. Por definição, para qualquer $v \in V^\perp$, nós temos que $u^T v = 0$. Nós sabemos que o produto interno é simétrico por definição, logo, $u^T v = v^T u$. Como $u^T v = 0$, segue que $v^T u = 0$. Logo, nós temos que $u \perp V^\perp$. Portanto, $u \in (V^\perp)^\perp$. Assim sendo, $V \subseteq (V^\perp)^\perp$.

Agora, nós queremos demonstrar que $(V^\perp)^\perp = V$. Para fazer isso, vamos usar as dimensões dos subespaços. Por um lado, nós temos que $\dim V + \dim V^\perp = \dim E$. Por outro lado, nós temos que $\dim V^\perp + \dim (V^\perp)^\perp = \dim E$. Assim sendo, nós temos que:

$$\dim V + \dim V^\perp = \dim V^\perp + \dim (V^\perp)^\perp \implies \dim V = \dim (V^\perp)^\perp.$$

Como V é um subespaço de $(V^\perp)^\perp$ (como nós demonstramos acima), e V possui a mesma dimensão de $(V^\perp)^\perp$, segue que $V = (V^\perp)^\perp$. □

Estamos prontos para falar em decomposição ortogonal. Em exercícios anteriores, nós definimos e trabalhamos com a soma de dois subespaços. No entanto, a fim de formalizar melhor esta ideia, nós iremos definir este conceito novamente.

Definição 7.3.8 (Soma de dois subespaços). Sejam V_1 e V_2 dois subespaços vetoriais de V . Então, nós definimos a **soma** de V_1 e V_2 como:

$$V_1 + V_2 = \{v_1 + v_2; v_1 \in V_1 \text{ e } v_2 \in V_2\}.$$

Como esta ideia nos sugere, este conceito pode ser estendido para a soma de m subespaços de V , da seguinte forma:

Definição 7.3.9 (Soma de m subespaços). Sejam $V_1, \dots, V_m$ subespaços vetoriais de V . Então, nós definimos a **soma** de $V_1, \dots, V_m$ como:

$$V_1 + \dots + V_m = \{v_1 + \dots + v_m; v_1 \in V_1, \dots, v_m \in V_m\}.$$

No nosso caso, nós estamos preocupados especificamente com o caso $m = 2$. Mas antes de chegar ao que queremos, nós definiremos, ainda para uma quantidade qualquer de subespaços, a soma direta.

Definição 7.3.10 (Soma direta). Sejam $V_1, \dots, V_m$ subespaços de V tais que cada vetor de $V_1 + \dots + V_m$ pode ser escrito de forma única como $v_1 + \dots + v_m$. Então, dizemos que esta soma é uma **soma direta**, e a denotamos por $V_1 \oplus \dots \oplus V_m$.

Com estas coisas em mente, vamos agora enunciar e demonstrar o Teorema da Decomposição Ortogonal.

Teorema 7.3.11 (Teorema da Decomposição Ortogonal). *Seja V um subespaço vetorial de E . Então, todo vetor $x \in E$ pode ser escrito, de forma única, como $x = v + v^\perp$, onde $v \in V$ e $v^\perp \in V^\perp$.*

Demonstração. Existência: *Suponha que $\dim E = n$ e $\dim V = k$. Então, consideremos as bases $\{v_1, \dots, v_k\}$ e $\{w_1, \dots, w_{n-k}\}$ para V e $V^\perp$, respectivamente. Nós provaremos que o conjunto $\{v_1, \dots, v_k, w_1, \dots, w_{n-k}\}$ é LI. De fato, tomemos*

$$\alpha_1 v_1 + \dots + \alpha_k v_k + \alpha_{k+1} w_1 + \dots + \alpha_n w_{n-k} = 0.$$

Nós temos que

$$\alpha_1 v_1 + \dots + \alpha_k v_k = -(\alpha_{k+1} w_1 + \dots + \alpha_n w_{n-k}).$$

O lado esquerdo da equação pertence a V , e o lado direito da equação pertence a $V^\perp$. Logo, ambos os vetores pertencem a $V \cap V^\perp$. Mas nós sabemos que $V \cap V^\perp = \{0\}$. Logo:

$$\alpha_1 v_1 + \dots + \alpha_k v_k = 0$$

e

$$\alpha_{k+1} w_1 + \dots + \alpha_n w_{n-k} = 0.$$

Pela independência linear dos v_i 's e dos w_i 's, segue que:

$$\alpha_1 = \dots = \alpha_k = \alpha_{k+1} = \dots = \alpha_n = 0.$$

Logo, o conjunto $\{v_1, \dots, v_k, w_1, \dots, w_{n-k}\}$ é LI. Mais do que isso, como este conjunto possui n vetores e $\dim E = n$, ele é uma base para E . Assim sendo, para todo $x \in E$, existem $\alpha_1, \dots, \alpha_k, \alpha_{k+1}, \dots, \alpha_n \in \mathbb{R}$ tais que:

$$x = \alpha_1 v_1 + \dots + \alpha_k v_k + \alpha_{k+1} w_1 + \dots + \alpha_n w_{n-k}.$$

Ou seja, $x = v + v^\perp$.

Unicidade: *Suponha que existem $v_1, v_2 \in V$ e $v_1^\perp, v_2^\perp \in V^\perp$ tais que*

$$x = v_1 + v_1^\perp = v_2 + v_2^\perp.$$

Então, segue que $v_1 - v_2 = v_2^\perp - v_1^\perp$. O primeiro vetor pertence a V e o segundo vetor pertence a $V^\perp$. Logo, ambos os vetores pertencem a $V \cap V^\perp = \{0\}$. Ou seja, $v_1 - v_2 = 0$ e $v_2^\perp - v_1^\perp = 0$. Segue então que $v_1 = v_2$ e $v_1^\perp = v_2^\perp$.

□

Do Teorema da Decomposição Ortogonal, segue imediatamente o seguinte corolário:

Corolário 7.3.12. *Seja V um subespaço vetorial de E . Então, $E = V \oplus V^\perp$.*

A grande importância que tem o Teorema da Decomposição Ortogonal é a ideia de projeção ortogonal, que desenvolveremos a partir da próxima seção. Mas, antes disso, façamos um exemplo para mostrar como podemos encontrar a decomposição ortogonal de um vetor dados um subespaço e o seu complemento ortogonal.

Exemplo 7.3.13. Considere $x = \begin{bmatrix} 2 \\ 5 \\ -1 \\ 0 \end{bmatrix}$ e o subespaço vetorial $V = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \end{bmatrix} \right\} \right)$.

Nós queremos encontrar os vetores $v \in V$ e $v^\perp \in V^\perp$ tais que $x = v + v^\perp$. Primeiramente, vamos encontrar uma base para $V^\perp$, sabendo que o conjunto $\left\{ \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \end{bmatrix} \right\}$ é uma base para

V . Montando a matriz A , nós temos:

$$A = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 2 & 4 \end{bmatrix}.$$

A matriz A já está na sua forma escalonada reduzida. Assim sendo, nós temos que:

$$N = \begin{bmatrix} -1 & 0 \\ -2 & -4 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Ou seja, $\left\{ \begin{bmatrix} -1 \\ -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ -4 \\ 0 \\ 1 \end{bmatrix} \right\}$ é uma base para $V^\perp$. Então, nós queremos encontrar escalares $a, b, c, d \in \mathbb{R}$ tais que:

$$\begin{bmatrix} 2 \\ 5 \\ -1 \\ 0 \end{bmatrix} = a \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix} + b \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \end{bmatrix} + c \begin{bmatrix} -1 \\ -2 \\ 1 \\ 0 \end{bmatrix} + d \begin{bmatrix} 0 \\ -4 \\ 0 \\ 1 \end{bmatrix}$$

Isto equivale ao seguinte sistema linear:

$$\begin{bmatrix} 1 & 0 & -1 & 0 \\ 0 & 1 & -2 & -4 \\ 1 & 2 & 1 & 0 \\ 0 & 4 & 0 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \\ d \end{bmatrix} = \begin{bmatrix} 2 \\ 5 \\ -1 \\ 0 \end{bmatrix}$$

Resolvendo este sistema linear (nós não o faremos aqui, porque, a esta altura, certamente vocês já estão cansados de fazer isso, e eu também), nós obtemos:

$$\begin{bmatrix} a \\ b \\ c \\ d \end{bmatrix} = \begin{bmatrix} 15/38 \\ 4/38 \\ -61/38 \\ -16/38 \end{bmatrix}.$$

Assim sendo, o vetor v é dado por:

$$v = a \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix} + b \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \end{bmatrix} = \frac{15}{38} \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \end{bmatrix} + \frac{4}{38} \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \end{bmatrix} = \begin{bmatrix} 15/38 \\ 4/38 \\ 23/38 \\ 16/38 \end{bmatrix},$$

e o vetor $v^\perp$ é dado por:

$$v^\perp = c \begin{bmatrix} -1 \\ -2 \\ 1 \\ 0 \end{bmatrix} + d \begin{bmatrix} 0 \\ -4 \\ 0 \\ 1 \end{bmatrix} = -\frac{61}{38} \begin{bmatrix} -1 \\ -2 \\ 1 \\ 0 \end{bmatrix} + -\frac{16}{38} \begin{bmatrix} 0 \\ -4 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 61/38 \\ 186/38 \\ -61/38 \\ -16/38 \end{bmatrix}.$$

Logo, a decomposição ortogonal de x é:

$$\begin{bmatrix} 2 \\ 5 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} 15/38 \\ 4/38 \\ 23/38 \\ 16/38 \end{bmatrix} + \begin{bmatrix} 61/38 \\ 186/38 \\ -61/38 \\ -16/38 \end{bmatrix},$$

ou, escrevendo de um jeito mais bonitinho,

$$\begin{bmatrix} 2 \\ 5 \\ -1 \\ 0 \end{bmatrix} = \frac{1}{38} \left(\begin{bmatrix} 15 \\ 4 \\ 23 \\ 16 \end{bmatrix} + \begin{bmatrix} 61 \\ 186 \\ -61 \\ -16 \end{bmatrix} \right).$$

7.4 Matrizes de Projeção

Nesta seção, nós vamos falar sobre matrizes de projeção. Mais especificamente, nós estaremos em falar sobre projeção ortogonal. E a primeira pergunta natural é: “por que nós queremos projetar?” A resposta é muito simples: nem todo sistema linear $Ax = b$ possui solução. No entanto, o nosso grande objetivo é resolver $Ax = b$. Então, quando o sistema não tem solução, nós queremos encontrar algo que se pareça com uma solução. A projeção nos dá exatamente isso.

Mas, para falar em projeção, nós precisamos primeiro entender o que é isso. Vamos começar com um caso mais simples, e depois estendemos a ideia para casos mais gerais.

Considere a e b dois vetores em $\mathbb{R}^2$. Para a nossa discussão ficar interessante, considere que a e b são vetores LI. Vamos mostrar uma figura para esta ideia ficar mais clara:




Figura 7.4: Vetores LI em $\mathbb{R}^2$ (arquivo pessoal)

O vetor a está em um subespaço vetorial U , enquanto o vetor b não está neste subespaço. Nós desejamos projetar b em a , ou seja, nós queremos encontrar um vetor $p \in U$ tal que $p = xa$, para algum $x \in \mathbb{R}$, de modo que b pode ser escrito como $b = p + q$, para algum q em outro subespaço. Existem muitas formas de fazer isso. Na verdade, existem infinitas formas. A própria escolha $p = a$ é uma opção (dado que $b = a + (b - a)$). Então, na prática, nós já achamos uma projeção de b em a (ou melhor dizendo, de b no subespaço U).

No entanto, dadas infinitas possíveis projeções, nós queremos encontrar uma projeção que seja melhor do que todas as outras. E ser melhor, no nosso caso, significa minimizar a distância entre b e p . Ou seja, nós queremos encontrar um vetor p tal que $\|b - p\|$ seja a menor possível. Intuitivamente (e, de maneira nada rigorosa), nós queremos um vetor p que seja quase igual a b , só que pertencente ao subespaço U .

E isto é algo bastante sugestivo: nós sabemos que, em $\mathbb{R}^2$ (e, na prática, em $\mathbb{R}^n$), a melhor forma de fazer isso é encontrar um vetor p tal que $b - p$ seja ortogonal a a (e a p também, mas enfim). Ou seja, nós queremos encontrar um vetor p tal que $a^T(b - p) = 0$. Novamente, vamos ver uma imagem para estas ideias ficarem mais claras:




Figura 7.5: Projeção ortogonal em $\mathbb{R}^2$ (arquivo pessoal)

Vamos então procurar p . Nós sabemos que $p = xa$, onde x é um escalar real. Então, nós precisamos determinar x tal que $a^T(b - xa) = 0$. Façamos as contas:

$$a^T(b - xa) = 0 \iff a^Tb - xa^Ta = 0 \iff xa^Ta = a^Tb \iff x = \frac{a^Tb}{a^Ta}.$$

Logo, nós temos que $p = \frac{a^Tb}{a^Ta}a$. Como $\frac{a^Tb}{a^Ta}$ é um escalar, nós podemos escrever $p = a \frac{a^Tb}{a^Ta}$ e, pela associatividade, segue que $p = \frac{aa^T}{a^Ta}b$. No entanto, $\frac{aa^T}{a^Ta}$ é uma matriz de posto 1. Denotando esta matriz por P , segue que este processo pode ser descrito matricialmente por $p = Pb$. A matriz P pertence a uma classe especial de matrizes que nós chamamos de matrizes de projeção, e, neste caso, a uma classe mais especial ainda de matrizes que nós chamamos de matrizes de projeção ortogonal. Então, vamos definir formalmente estas duas classes de matrizes.

Definição 7.4.1 (Matriz de projeção). *Uma matriz P é dita uma **matriz de projeção** quando $P^2 = P$.*

A intuição de $P^2 = P$ é muito simples. Se nós temos um vetor x , e aplicamos uma matriz de projeção P nele, nós obtemos um certo vetor Px . Se nós aplicamos a mesma matriz de projeção a este vetor Px (ou seja, fazemos P^2x), nós precisamos encontrar o mesmo vetor Px , já que um vetor projetado sobre si mesmo pela mesma matriz de projeção é igual ao próprio vetor. De $P^2 = P$, seguirá imediatamente que $P^n = P$ para qualquer $n \in \mathbb{N}$, o que condiz perfeitamente com a nossa intuição.

Definição 7.4.2 (Matriz de projeção ortogonal). *Uma matriz P é dita uma **matriz de projeção ortogonal** quando $P^2 = P$ e $P^T = P$.*

Vamos, então, mostrar que a matriz de posto 1 que nós encontramos anteriormente é, de fato, uma matriz de projeção ortogonal (generalizando para $\mathbb{R}^n$).

Proposição 7.4.3. *Dados dois vetores $a, b \in \mathbb{R}^n$, a matriz $P = \frac{aa^T}{a^Ta}$ é uma matriz de projeção ortogonal.*

Demonstração. *Primeiro, vamos mostrar que $P^2 = P$. De fato:*

$$P^2 = \frac{aa^T}{a^Ta} \cdot \frac{aa^T}{a^Ta} = \frac{a(a^Ta)a^T}{a^Taa^Ta} = \frac{(a^Ta)aa^T}{(a^Ta)a^Ta} = \frac{aa^T}{a^Ta} = P.$$

Agora, nós vamos mostrar que $P^T = P$. De fato:

$$P^T = \left(\frac{aa^T}{a^Ta} \right)^T = \frac{(aa^T)^T}{a^Ta} = \frac{aa^T}{a^Ta} = P.$$

Logo, P é uma matriz de projeção ortogonal.

□

Agora, nós vamos estender este conceito para um caso mais geral. Nós já sabemos projetar sobre uma reta. Agora, nós queremos aprender a projetar sobre um plano (ou, melhor ainda, sobre um hiperplano).

Suponha que $\{a_1, \dots, a_k\}$ é uma base para um certo hiperplano, e existe um certo vetor b que não pertence a este hiperplano. Nós queremos encontrar $\{x_1, \dots, x_k\}$ tais que o vetor p projetado ortogonalmente possa ser escrito como $p = x_1a_1 + \dots + x_ka_k$. Note que:

$$x_1a_1 + \dots + x_ka_k = \begin{bmatrix} a_1 & a_2 & \dots & a_k \end{bmatrix} x = Ax,$$

com $x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_k \end{bmatrix}.$

Como o conjunto dos a_i 's é uma base para o hiperplano, nós podemos entendê-lo como o espaço coluna de A . A ideia agora é a mesma: nós queremos encontrar x tal que $a_i^T(b - Ax) = 0$. Escrevendo esta fórmula de maneira matricial, isto equivale a $A^T(b - Ax) = 0$. Assim sendo, nós obtemos:

$$A^T(b - Ax) = 0 \iff A^Tb - A^TAx = 0 \iff A^TAx = A^Tb.$$

As equações $A^TAx = A^Tb$ são chamadas de equações normais. No caso em que A^TA é invertível (e, por enquanto é, já que estamos considerando A como sendo a matriz

cujas colunas formam uma base para o hiperplano, mas, generalizando para qualquer A , poderia não ser), nós obtemos $x = (A^T A)^{-1} A^T b$, e, como $p = Ax$, nós obtemos a matriz de projeção ortogonal $P = A(A^T A)^{-1} A^T$.

Nós não provaremos que esta matriz é, de fato, uma matriz de projeção ortogonal, mas, como todo escritor meio preguiçoso gosta de fazer, e eu também, esta demonstração será um dos exercícios para o leitor.

Existe um motivo a mais pelo qual projeções ortogonais são legais: todo vetor de um espaço E pode ser escrito de forma única como a soma de um vetor em um certo subespaço V com um vetor no complemento ortogonal $V^\perp$. Então, seja $x \in E$. Se nós encontramos a projeção ortogonal de x sobre V , é muito fácil encontrar a sua projeção sobre $V^\perp$: basta fazer uma subtração.

Mas vamos fazer isto de maneira formal: Considere uma matriz $A_{m \times n}$ tal que $A^T A$ é inversível. Nós sabemos que $C(A) \perp N(A^T)$, ou seja, $\dim C(A) + \dim N(A^T) = m$. Nós queremos projetar um certo vetor $b \in \mathbb{R}^m$ qualquer sobre $C(A)$ e também sobre $N(A^T)$. Suponha que P é a matriz de projeção sobre $C(A)$. Então, pelo Teorema da Decomposição Ortogonal, nós temos que b pode ser escrito de forma única como $b = Pb + p^\perp$, onde $p^\perp \in N(A^T)$. Resolvendo a equação, segue imediatamente que $p^\perp = b - Pb$. Sabemos, porém, que:

$$b - Pb = Ib - Pb = (I - P)b.$$

Logo, se P projeta b sobre $C(A)$, então a matriz $I - P$ projeta b sobre $N(A^T)$. De fato, como falamos antes, conhecendo b e Pb , encontrar a projeção de b sobre $N(A^T)$ se resume a fazer uma subtração. Mas focar no aspecto matricial dessas operações: queremos provar que $I - P$ é uma matriz de projeção ortogonal.

Proposição 7.4.4. *Sejam $A_{m \times n}$ uma matriz tal que $A^T A$ é invertível e P a matriz de projeção ortogonal sobre $C(A)$. Então, $I - P$ é uma matriz de projeção ortogonal sobre $N(A^T)$.*

Demonstração. *Primeiro, nós vamos provar que $(I - P)^2 = I - P$. De fato:*

$$(I - P)^2 = (I - P)(I - P) = I^2 - IP - PI + P^2 = I - 2P + P = I - P.$$

Agora, nós vamos provar que $(I - P)^T = (I - P)$. De fato:

$$(I - P)^T = I^T - P^T = I - P.$$

Finalmente, vamos provar que $I - P$ projeta sobre $N(A^T)$. Seja $b \in \mathbb{R}^m$ um vetor qualquer. Então:

$$\begin{aligned} A^T((I - P)b) &= A^T(b - Pb) = A^Tb - A^TPb = A^Tb - A^T(A(A^T A)^{-1} A^T)b \\ &= A^Tb - (A^T A)(A^T A)^{-1} A^Tb = A^Tb - A^Tb = 0. \end{aligned}$$

Logo, $I - P$ é uma matriz de projeção ortogonal sobre $N(A^T)$.

□

Para não ficarmos unicamente presos à teoria, vamos fazer um exemplo:

Exemplo 7.4.5. Considere $A = \begin{bmatrix} 1 & 2 \\ 3 & 2 \\ 0 & 1 \end{bmatrix}$ e $b = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$. Nós queremos encontrar o vetor p que é a projeção ortogonal de b sobre $C(A)$ e o vetor $p^\perp$ que é a projeção ortogonal de b sobre $N(A^T)$.

Para encontrar p , nós não vamos achar $A(A^T A)^{-1} A^T$, pois não queremos inverter matrizes. Ao invés disso, usaremos as equações normais, resolveremos os sistemas lineares para encontrar x e, por fim, calcularemos $p = Ax$. Recordando, as equações normais são dadas por $A^T A x = A^T b$. Assim sendo, vamos calcular $A^T A$ e $A^T b$:

$$A^T A = \begin{bmatrix} 1 & 3 & 0 \\ 2 & 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 2 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 10 & 8 \\ 8 & 9 \end{bmatrix}$$

$$A^T b = \begin{bmatrix} 1 & 3 & 0 \\ 2 & 2 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Assim sendo, nós obtemos o sistema

$$\begin{bmatrix} 10 & 8 \\ 8 & 9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

A solução deste sistema é $x = \begin{bmatrix} -7/26 \\ 12/26 \end{bmatrix}$. Assim sendo, nós encontramos o vetor p fazendo:

$$p = Ax = \begin{bmatrix} 1 & 2 \\ 3 & 2 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} -7/26 \\ 12/26 \end{bmatrix} = \begin{bmatrix} 17/26 \\ 3/26 \\ 12/26 \end{bmatrix} = \frac{1}{26} \begin{bmatrix} 17 \\ 3 \\ 12 \end{bmatrix}.$$

Por sua vez, para achar a projeção ortogonal de b sobre $N(A^T)$, basta fazer

$$p^\perp = b - p = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \begin{bmatrix} 17/26 \\ 3/26 \\ 12/26 \end{bmatrix} = \begin{bmatrix} 9/26 \\ -3/26 \\ -12/26 \end{bmatrix} = \frac{1}{26} \begin{bmatrix} 9 \\ -3 \\ -12 \end{bmatrix}.$$

Em todas as proposições desta seção, nós estávamos considerando que $A^T A$ possui inversa. Agora, no entanto, nós precisamos determinar quando $A^T A$ possui inversa, para que as coisas funcionem como desejamos.

Teorema 7.4.6. Seja A uma matriz $m \times n$. Então, $A^T A$ possui inversa se, e somente se, as colunas de A são LI.

Demonstração. Nós queremos demonstrar que $N(A^T A) = N(A)$.

Primeiramente, provaremos que $N(A^T A) \subseteq N(A)$. De fato, $x \in N(A^T A) \iff A^T A x = 0$. Isto implica que

$$x^T A^T A x = 0 \iff (Ax)^T (Ax) = 0 \iff \|Ax\|^2 = 0 \iff Ax = 0.$$

Logo, $x \in N(A)$.

Agora, provaremos que $N(A) \subseteq N(A^T A)$. De fato:

$$x \in N(A) \iff Ax = 0 \iff A^T A x = 0.$$

Logo, $x \in N(A^T A)$.

Assim sendo, $N(A^T A) = N(A)$ e, por consequência, $N(A^T A) = \{0\} \iff N(A) = \{0\}$.

□

7.5 Mínimos Quadrados

Nesta seção, nós vamos desenvolver a primeira grande aplicação de Álgebra Linear. Como nós mencionamos anteriormente, quando o sistema $Ax = b$ não possui solução, nós queremos encontrar um vetor $\tilde{x}$ que esteja o mais próximo possível de ser uma solução do nosso sistema. Vamos adotar uma convenção a partir de agora: toda vez que falarmos em projeção, estaremos falando especificamente em projeção ortogonal.

Vamos desenvolver esta ideia formalmente: considere o sistema $Ax = b$ tal que $b \notin C(A)$ (com A uma matriz $m \times n$ tal que $m > n$). Este sistema linear não possui solução. No entanto, se nós projetarmos b em $C(A)$, o sistema $A\tilde{x} = p$ possuirá solução. Neste caso, o vetor $\tilde{x}$ é “quase” uma solução para $Ax = b$. Ele é, na verdade, o vetor que está mais próximo de ser uma solução para $Ax = b$.

Mas como nós medimos o que significa “estar mais próximo de ser uma solução de $Ax = b$ ”? É muito simples: quando um sistema linear possui solução, e x é essa solução, nós temos que $\|Ax - b\| = 0$. Quando nós encontramos o vetor $\tilde{x}$ que é quase uma solução de um sistema sem solução, nós obtemos $\min_{x \in \mathbb{R}^n} \|Ax - b\|$. Como, no entanto, trabalhar diretamente com a norma costuma ser difícil, e a norma é sempre maior ou igual a zero, este problema é equivalente a um problema mais fácil:

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|^2.$$

Este problema é chamado **Problema de Mínimos Quadrados**. Ele é chamado assim porque nós estamos procurando o vetor $\tilde{x}$ que minimiza o quadrado da norma de $Ax - b$. O vetor $Ax - b$ é chamado de **resíduo**, e o escalar $\|Ax - b\|^2$ é chamado de **erro**.

Vamos agora enunciar e demonstrar a solução do Problema de Mínimos Quadrados.

Teorema 7.5.1 (Solução do Problema de Mínimos Quadrados). *Seja $Ax = b$ um sistema linear sem solução, com A sendo uma matriz $m \times n$ tal que $A^T A$ é invertível. Então, a solução do Problema de Mínimos Quadrados é*

$$\tilde{x} = (A^T A)^{-1} A^T b.$$

Demonstração. *Pelo Teorema da Decomposição Ortogonal, nós podemos escrever $b = p + (b - p)$, onde $p \in C(A)$ é a projeção ortogonal de b em $C(A)$ e $b - p \in N(A^T)$. Assim sendo, nós temos que $Ax - b = (Ax - p) + (b - p)$. Pelo Teorema de Pitágoras, nós temos que:*

$$\|Ax - b\|^2 = \|Ax - p\|^2 + \|b - p\|^2.$$

O nosso objetivo é minimizar $\|Ax - b\|^2$. Mas note que o termo $\|b - p\|^2$ não depende de x . Assim sendo, este problema equivale a minimizar $\|Ax - p\|^2$. O vetor p está em $C(A)$, logo, basta achar x tal que $Ax - p = 0$. Fazendo as contas, nós obtemos:

$$Ax - p = 0 \implies Ax = p \implies Ax = Pb \implies Ax = A(A^T A)^{-1} A^T b.$$

Escolhendo $\tilde{x} = (A^T A)^{-1} A^T b$, nós obtemos $Ax - p = 0$. Logo, a solução de Mínimos Quadrados é $\tilde{x} = (A^T A)^{-1} A^T b$. □

Um exemplo de aplicação direta deste conceito é quando, dado um conjunto de pontos, nós queremos encontrar uma reta que melhor se ajuste a eles (poderia ser uma outra função, mas a regressão linear é melhor para fazer contas na mão). Vamos, assim, fazer um exemplo:

Exemplo 7.5.2. Considere o seguinte conjunto de dados: $\mathcal{D} = \{(0, 1), (1, 1), (2, 3)\}$. Nós queremos encontrar os coeficientes C e D tal que a reta $f(t) = C + Dt$ se ajusta da melhor forma possível aos dados do conjunto $\mathcal{D}$.

Perceba que $f(t) = \begin{bmatrix} 1 & t \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix}$. Assim sendo, nós podemos considerar a matriz A como:

$$A = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ 1 & t_3 \end{bmatrix},$$

o vetor x como:

$$x = \begin{bmatrix} C \\ D \end{bmatrix}$$

e o vetor b como:

$$b = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}.$$

Na prática, isto quer dizer o seguinte: a matriz A é a matriz dos dados de entrada aplicados a cada termo que compõe $f(t)$. O vetor x é o vetor dos coeficientes que nós queremos encontrar, e o vetor b é o vetor dos dados de saída do experimento. Para encontrar o vetor $\tilde{x}$, nós resolvemos as equações normais.

Primeiramente, calculemos $A^T A$:

$$A^T A = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix} = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}.$$

Agora, calculemos $A^T b$:

$$A^T b = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 5 \\ 7 \end{bmatrix}.$$

Agora, basta resolver o seguinte sistema linear:

$$\begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 5 \\ 7 \end{bmatrix}.$$

Fazendo as contas, a solução deste sistema é $\tilde{x} = \begin{bmatrix} 2/3 \\ 1 \end{bmatrix}$. Logo, a reta que melhor se ajusta ao conjunto $\mathcal{D}$ é $f(t) = \frac{2}{3} + t$.

Vamos mostrar uma imagem representando este exemplo:




Figura 7.6: Regressão linear (arquivo pessoal)

De um modo geral, se nós temos um conjunto de dados $\mathcal{D} = \{(t_1, b_1), (t_2, b_2), \dots, (t_m, b_m)\}$, e nós queremos ajustá-los por uma reta $f(t) = C + Dt$, nós temos que a matriz A é dada por:

$$A = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix},$$

o vetor x é dado por:

$$x = \begin{bmatrix} C \\ D \end{bmatrix}$$

e o vetor b é dado por:

$$b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}.$$

A partir daí, basta resolver as equações normais. Explicitamente, nós temos que:

$$A^T A = \begin{bmatrix} 1 & 1 & \dots & 1 \\ t_1 & t_2 & \dots & t_m \end{bmatrix} \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix} = \begin{bmatrix} m & \sum t_i \\ \sum t_i & \sum t_i^2 \end{bmatrix}.$$

e

$$A^T b = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ t_1 & t_2 & \cdots & t_m \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix} = \begin{bmatrix} \sum b_i \\ \sum t_i b_i \end{bmatrix}.$$

Nós podemos transformar $A^T A$ em uma matriz diagonal definindo $s_i = t_i - \bar{t}$, onde $\bar{t} = \frac{1}{m} \sum_{i=1}^m t_i$. Assim sendo, nós obtemos:

$$A^T A = \begin{bmatrix} m & \sum s_i \\ \sum s_i & \sum s_i^2 \end{bmatrix}.$$

Nós temos, porém, que:

$$\sum_{i=1}^m s_i = \sum_{i=1}^m (t_i - \bar{t}) = \sum_{i=1}^m t_i - \sum_{i=1}^m \bar{t} = \sum_{i=1}^m t_i - m\bar{t} = \sum_{i=1}^m t_i - \sum_{i=1}^m t_i = 0.$$

Assim sendo, segue que:

$$A^T A = \begin{bmatrix} m & 0 \\ 0 & \sum s_i^2 \end{bmatrix}.$$

Por sua vez, $A^T b$ transforma-se em:

$$A^T b = \begin{bmatrix} \sum b_i \\ \sum s_i b_i \end{bmatrix}.$$

Nós obtemos, dessa forma, o sistema linear

$$\begin{bmatrix} m & 0 \\ 0 & \sum s_i^2 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} \sum b_i \\ \sum s_i b_i \end{bmatrix}$$

e, fazendo um pouco de contas, nós obtemos que os coeficientes C e D são dados por:

$$C = \frac{1}{m} \sum_{i=1}^m b_i = \bar{b}$$

e

$$D = \frac{\frac{1}{m} \sum_{i=1}^m (t_i - \bar{t}) b_i}{\frac{1}{m} \sum_{i=1}^m (t_i - \bar{t})^2}.$$

7.6 Exercícios

Importante: Alguns dos exercícios são baseados em (2), em (7), em (9), e em (12).

7.1) Sejam $x = (x_1, \dots, x_n)^T$ e $y = (y_1, \dots, y_n)^T$. Mostre que a função $\langle \cdot, \cdot \rangle : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$, definida como:

$$\langle x, y \rangle = x \cdot y = x^T y = \sum_{i=1}^n x_i y_i$$

é um produto interno.

7.2) Sejam p e q dois polinômios em $\mathcal{P}_n$. Mostre que a função $\langle \cdot, \cdot \rangle : \mathcal{P}_n \times \mathcal{P}_n \rightarrow \mathbb{R}$, definida como:

$$\langle p, q \rangle = \int_{-1}^1 p(x)q(x) dx$$

é um produto interno.

7.3) Seja $x = (x_1, \dots, x_n)^T$. Mostre que a função $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}$, definida como:

$$\|x\| = \left(\sum_{i=1}^n x_i^2 \right)^{\frac{1}{2}}$$

é uma norma.

7.4) Seja $x = (x_1, \dots, x_n)^T$. Mostre que a função $\| \cdot \|_p : \mathbb{R}^n \rightarrow \mathbb{R}$, definida como:

$$\|x\|_p = \left(\sum_{i=1}^n x_i^p \right)^{\frac{1}{p}}$$

é uma norma, para $1 \leq p < \infty$. Quando $0 \leq p < 1$, esta função ainda é uma norma? Se sim, justifique; se não, quais axiomas não são satisfeitos?

7.5) Seja $x = (x_1, \dots, x_n)^T$.

a) Mostre que a função $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}$, definida como:

$$\|x\|_{\infty} = \max_i |x_i|$$

é uma norma.

b) Prove que $\lim_{p \rightarrow \infty} \|x\|_p = \|x\|_{\infty}$.

7.6) Seja V um espaço vetorial real munido de um produto interno $\langle \cdot, \cdot \rangle$, e seja $\|x\| = \sqrt{\langle x, x \rangle}$ para todo $x \in V$. Mostre que, dados $u, v \in V$ quaisquer, vale a identidade:

$$\|u + v\|^2 + \|u - v\|^2 = 2\|u\|^2 + 2\|v\|^2.$$

Nota: Esta identidade é conhecida como Regra do Paralelogramo, e é um resultado mais importante do que parece (e mais forte do que o que o exercício pede para provar): basicamente, é verdade que, se um espaço possui um produto interno, a norma induzida por ele satisfaz essa identidade e, reciprocamente, se um espaço normado satisfaz a Regra do Paralelogramo, então a norma vem de um produto interno. Neste exercício, vocês provarão somente a ida, e os mais curiosos podem tentar demonstrar a volta também, que é conhecida como Teorema de Jordan-von Neumann.

7.7) Sejam U e V dois subespaços vetoriais de E . Prove que:

$$\dim(U + V) = \dim U + \dim V - \dim(U \cap V).$$

7.8) Considere o subespaço vetorial $U = \{(x, y, 2x, 3y)^T; x, y \in \mathbb{R}\} \subseteq \mathbb{R}^4$.

a) Verifique que o vetor $x = (1, 2, 2, 6)^T \in U$.

- b) Encontre um vetor $y \in \mathbb{R}^4$ tal que $x^T y = 0$.
 c) Determine um subespaço V tal que $U \perp V$ e $y \in V$.
 d) Determine as dimensões de U e V .
 e) Conclua que $\dim U + \dim V \leq \dim \mathbb{R}^4$.
 f) Generalize o item e) para qualquer espaço vetorial: prove que, se E é um espaço vetorial, e U e V são dois subespaços de E tais que $U \perp V$, então $\dim U + \dim V \leq \dim E$.

7.9) Seja V um subespaço vetorial de E . Prove que o complemento ortogonal de V é único.

7.10) Considere $E = \mathbb{R}^3$. Ache $S^\perp$ para os seguintes conjuntos:

- a) $S = \{0\}$.
 b) $S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right\}$.
 c) $S = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix} \right\}$.
 d) $S = \left\{ \begin{bmatrix} 1 \\ 5 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} \right\}$. Note que S não é um subespaço, mas $S^\perp$ é.

7.11) Suponha que U é um subespaço de E . O que é $U + U$?

7.12) Seja $V = \text{span} \left\{ \begin{bmatrix} 2 \\ 0 \\ 1 \\ 3 \end{bmatrix}, \begin{bmatrix} 5 \\ -1 \\ 0 \\ 9 \end{bmatrix} \right\}$ um subespaço de $\mathbb{R}^4$, e considere o vetor $x = \begin{bmatrix} 0 \\ 1 \\ 2 \\ 4 \end{bmatrix}$.

Encontre a decomposição ortogonal de x .

7.13) Seja V o plano $3x + 2y - z = 0$ em $\mathbb{R}^3$. Considere o vetor $v = \begin{bmatrix} 5 \\ 4 \\ -1 \end{bmatrix}$. Ache a decomposição ortogonal de v .

7.14) Demonstre que nenhum par de planos V e W em $\mathbb{R}^3$ pode ser ortogonal.

7.15) Seja $A_{m \times n}$ uma matriz tal que $A^T A$ é invertível. Prove que $P = A(A^T A)^{-1} A^T$ é uma matriz de projeção ortogonal.

7.16) Seja A uma matriz 4×3 formada pelas primeiras 3 colunas da matriz identidade 4×4 . Projete o vetor $b = (1, 2, 3, 4)^T$ no espaço coluna de A . Ache a matriz de projeção P .

7.17) Seja P uma matriz de projeção qualquer.

- a) Prove que $C(I - P) = N(P)$.
 b) Prove que $N(I - P) = C(P)$.
 c) Suponha agora que P é uma matriz de projeção ortogonal. Prove que $N(P) = C(P)^\perp$.

7.18) Projete b sobre o espaço coluna de A resolvendo $A^T A \hat{x} = A^T b$ e $p = A \hat{x}$ para:

$$\begin{array}{l} \text{a)} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{bmatrix} \text{ e } \begin{bmatrix} 2 \\ 5 \\ -1 \end{bmatrix}. \\ \text{b)} \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \text{ e } \begin{bmatrix} 2 \\ -1 \\ 6 \end{bmatrix}. \\ \text{c)} \begin{bmatrix} 1 & 0 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \text{ e } \begin{bmatrix} 7 \\ -3 \\ 4 \end{bmatrix}. \end{array}$$

7.19) Considere o conjunto de dados $\mathcal{D} = \{(1, 2), (2, 3), (5, -1)\}$. Encontre a solução de mínimos quadrados $\hat{x} = (C, D)^T$ tal que $y(t) = C + Dt$ é a reta que melhor se ajusta aos dados. Encontre também a projeção $p = A\hat{x}$. Quais dos quatro subespaços fundamentais contêm o vetor erro $e = b - p$? E o vetor p ? E o vetor $\hat{x}$? Qual é o núcleo de A ?

7.20) (Desafio!) Reformule o problema de mínimos quadrados para ajustar a função $a + d \cos(t + \theta)$, onde a, d, θ são os coeficientes a serem calculados.

Capítulo 8

Fatoração QR

Importante: este capítulo é baseado em (9) e em (13).

No capítulo anterior, nós trabalhamos com o conceito de ortogonalidade, e vimos uma das possíveis aplicações deste conceito. Agora, nós veremos como a noção de ortogonalidade induz uma fatoração, que é conhecida como “Fatoração QR ”. Mas, primeiro, vamos introduzir alguns novos conceitos, que nos levarão à fatoração desejada.

8.1 Vetores Ortonormais

Suponha que nós temos um certo conjunto de vetores $\{q_1, \dots, q_k\}$. Nós dizemos que estes vetores são **ortogonais** se $q_i^T q_j = 0, \forall i \neq j$. No entanto, nós podemos criar uma noção ainda mais forte do que a de ortogonalidade para este conjunto.

Definição 8.1.1 (Vetores ortonormais). *Seja $\{q_1, \dots, q_k\}$ um conjunto de vetores. Nós dizemos que estes vetores são **ortonormais** se:*

$$q_i^T q_j = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}.$$

Em resumo, um conjunto de vetores ortonormais é tal que, dados dois vetores quaisquer diferentes entre si, eles são ortogonais e, além disso, a norma de todo vetor é igual a 1. Uma notação diferente que nós poderíamos usar para expressar é o “delta de Kronecker”, que definiremos a seguir:

Definição 8.1.2 (Delta de Kronecker). *Definimos o **delta de Kronecker** como:*

$$\delta_{ij} = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}.$$

Usando esta notação, nós temos que, em um conjunto ortonormal de vetores, $q_i^T q_j = \delta_{ij}$. O primeiro fato interessante que nós podemos provar, ainda em um conjunto ortogonal, e que, portanto, é válido para um conjunto ortonormal, é o seguinte:

Proposição 8.1.3. *Seja $\{q_1, \dots, q_k\}$ um conjunto de vetores ortogonais diferentes de zero. Então, este conjunto é LI.*

Demonstração. Nós queremos provar que:

$$\alpha_1 q_1 + \cdots + \alpha_k q_k = 0 \implies \alpha_1 = \cdots = \alpha_k = 0.$$

Calculando $q_i \cdot (\alpha_1 q_1 + \cdots + \alpha_k q_k) = q_i \cdot 0$, para qualquer $i \in \{1, \dots, k\}$ nós temos que:

$$\alpha_1 q_i \cdot q_1 + \cdots + \alpha_i q_i \cdot q_i + \cdots + \alpha_k q_i \cdot q_k = 0.$$

Pela ortogonalidade dos vetores deste conjunto, segue que:

$$\alpha_i \|q_i\|^2 = 0$$

e, como $\|q_i\|^2 \neq 0$, segue que $\alpha_i = 0$, para todo $i \in \{1, \dots, k\}$. Logo, o conjunto $\{q_1, \dots, q_n\}$ é LI. □

A consequência mais importante deste fato é que, se nós temos um conjunto ortogonal de n vetores em um espaço E de dimensão n , então este conjunto forma uma base para E . De maneira ainda mais particular, se este conjunto é ortonormal, ele forma uma base ortonormal para E . Bases ortonormais são muito boas.

De fato, seja E um espaço vetorial tal que $\dim E = n$, e suponha que $\{q_1, \dots, q_n\}$ forma uma base ortonormal para este espaço. Então, qualquer vetor $v \in E$ pode ser escrito como:

$$v = \alpha_1 q_1 + \cdots + \alpha_n q_n.$$

Se nós calculamos o produto interno $q_i \cdot v$, nós obtemos:

$$q_i \cdot v = \alpha_1 q_i \cdot q_1 + \cdots + \alpha_i q_i \cdot q_i + \cdots + \alpha_n q_i \cdot q_n = \alpha_i \|q_i\|^2.$$

Como, pela ortonormalidade do conjunto, $\|q_i\|^2 = 1$, segue que

$$q_i \cdot v = \alpha_i.$$

Ou seja, calcular o produto interno do i -ésimo vetor de uma base ortonormal com o vetor v resulta na i -ésima coordenada de v nesta base. Isto faz com que nós possamos escrever qualquer vetor nesta base como:

$$v = \sum_{i=1}^n (v \cdot q_i) q_i.$$

Precisamente esta fórmula (atribuída a Fourier) nos levará, no futuro, à ideia da fatoração QR.

O principal exemplo de base ortonormal em $\mathbb{R}^n$ é a base canônica, que corresponde ao conjunto $\{e_1, \dots, e_n\}$. De fato, fazendo as contas, nós vemos que $e_i^T e_j = 0$, se $i \neq j$, e $e_i^T e_i = 1$. Mas nós não precisamos nos prender à base canônica: dada uma base ortogonal $\{q_1, \dots, q_n\}$ qualquer, o conjunto $\left\{ \frac{q_1}{\|q_1\|}, \dots, \frac{q_n}{\|q_n\|} \right\}$ é uma base ortonormal. Também esta noção de normalização, que nós tínhamos apresentado no capítulo 1, será importante, tanto para encontrar bases ortonormais, quando para encontrar uma fatoração QR de uma matriz.

8.2 Matrizes Ortogonais

A noção de vetores ortonormais nos leva à noção de matrizes ortogonais, que nós definiremos agora:

Definição 8.2.1 (Matrizes ortogonais). *Seja Q uma matriz tal que as suas colunas, dadas por $\{q_1, \dots, q_n\}$, são ortonormais. Então, dizemos que Q é uma **matriz ortogonal**.*

Uma primeira coisa que é necessário pontuar: se uma certa matriz possui colunas ortogonais, **não necessariamente** esta matriz é ortogonal. Ela só é ortogonal se, além de ortogonais, as suas colunas forem ortonormais (sim, eu sei que vocês acham que essas matrizes deveriam se chamar “matrizes ortonormais”, eu também acho, e eu acho que todo mundo acha, mas não é o nome que foi dado, então teremos que conviver com isso).

Agora, nós veremos uma propriedade de certas matrizes ortogonais.

Proposição 8.2.2. *Seja Q uma matriz $m \times n$, com $m \geq n$ uma matriz tal que $Q^T Q = I$. Então, Q é uma matriz ortogonal.*

Demonstração. *Definamos a matriz Q como:*

$$Q = \begin{bmatrix} | & & | \\ q_1 & \cdots & q_n \\ | & & | \end{bmatrix}.$$

Nós temos que $Q^T Q$ é dada por:

$$Q^T Q = \begin{bmatrix} - & q_1^T & - \\ & \vdots & \\ - & q_n^T & - \end{bmatrix} \begin{bmatrix} | & & | \\ q_1 & \cdots & q_n \\ | & & | \end{bmatrix} = \begin{bmatrix} | & & | \\ e_1 & \cdots & e_n \\ | & & | \end{bmatrix} = I.$$

Nós temos que o elemento ij da matriz identidade é dado por $q_i^T q_j$. Sabemos, no entanto, que $I_{ij} = 1$, se $i = j$, e $I_{ij} = 0$, se $i \neq j$. Consequentemente, segue que:

$$q_i^T q_j = \begin{cases} 1, & \text{se } i = j \\ 0, & \text{se } i \neq j \end{cases}.$$

Logo, os vetores-coluna de Q são ortonormais e, portanto, Q é uma matriz ortogonal. □

No caso em que Q é uma matriz quadrada, nós temos algo mais interessante ainda:

Proposição 8.2.3. *Seja Q uma matriz ortogonal quadrada $n \times n$. Então, $Q^T Q = Q Q^T = I$, com $Q^{-1} = Q^T$. Reciprocamente, se $Q^T Q = Q Q^T = I$, com $Q^{-1} = Q^T$, então Q é uma matriz ortogonal quadrada.*

Demonstração. $\implies$ *Suponha que Q é uma matriz ortogonal quadrada. Então, nós temos que $[Q^T Q]_{ij} = q_i^T q_j$. Pela ortonormalidade dos q_i 's, segue diretamente que $Q^T Q = I$. Por outro lado, dado que $Q^T Q = I$, e que as colunas de Q são LI (garantindo a existência de Q^{-1}), nós temos que:*

$$Q^T Q Q^{-1} = Q^{-1} \implies Q^T = Q^{-1} \implies Q Q^T = I.$$

$\Leftarrow$ *Suponha que Q é uma matriz tal que $Q^T Q = Q Q^T = I$, com, naturalmente, $Q^{-1} = Q^T$. Então, pela proposição anterior, segue imediatamente que Q é uma matriz ortogonal.* □

Uma consequência imediata desta última proposição é o fato de que, se Q é uma matriz ortogonal quadrada, então Q^T também é uma matriz ortogonal quadrada. Antes de vermos algumas propriedades sobre matrizes ortogonais, vamos ver alguns exemplos destas matrizes.

Exemplo 8.2.4. *Seja $P_{n \times n}$ uma matriz de permutação. Então, P é uma matriz ortogonal. De fato, as colunas de P são alguma permutação do conjunto $\{e_1, \dots, e_n\}$ que, como vimos anteriormente, é um conjunto ortonormal. Isto também poderia ser visto por um fato que nós demonstramos anteriormente: $P^{-1} = P^T$. Particularmente, a matriz identidade $I_{n \times n}$ é uma matriz ortogonal.*

Exemplo 8.2.5. *Seja $Q_{2 \times 2}$ a matriz definida como:*

$$Q = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}.$$

Então, Q é uma matriz ortogonal. De fato, calculando as normas dos seus vetores-coluna, e o produto interno de uma coluna pela outra, nós vemos facilmente que esta matriz é ortogonal. O significado geométrico desta matriz é uma rotação de um vetor em $\mathbb{R}^2$ ao redor da origem por um ângulo θ no sentido trigonométrico.

Vamos ver agora algumas propriedades das matrizes ortogonais:

Proposição 8.2.6. *Seja $Q_{m \times n}$ uma matriz ortogonal com $m \geq n$. Então, $\|Qx\| = \|x\|$.*

Demonstração. *Vamos calcular o quadrado da norma de $\|Qx\|$:*

$$\|Qx\|^2 = (Qx)^T(Qx) = x^T Q^T Q x = x^T x = \|x\|^2.$$

Logo, $\|Qx\| = \|x\|$.

□

Proposição 8.2.7. *Seja $Q_{m \times n}$ uma matriz ortogonal com $m \geq n$. Então, a matriz de projeção ortogonal sobre $C(Q)$ é $P = QQ^T$.*

Demonstração. *Sabemos que, dada uma matriz A com todas as colunas LI, a matriz de projeção ortogonal sobre $C(A)$ é $P = A(A^T A)^{-1} A^T$. Assim sendo, fazendo $A = Q$, nós temos:*

$$P = Q(Q^T Q)^{-1} Q^T = Q I^{-1} Q^T = Q I Q^T = Q Q^T.$$

□

Podemos perceber que, quando nós queremos projetar vetores sobre o espaço gerado pelas colunas de uma matriz ortogonal, encontrar a projeção fica significativamente mais fácil. E, igualmente, a fatoração QR é baseada em uma matriz Q ortogonal, e uma matriz R que nós veremos depois como se comporta. Um dos exercícios deste capítulo relacionará o Problema de Mínimos Quadrados com a fatoração QR de uma matriz A . Desde já, fica uma pergunta: será que o fato de uma matriz ortogonal aparecer na solução do Problema de Mínimos Quadrados o tornará mais fácil? Ou será que não?

8.3 Processo de Gram-Schmidt

Nesta seção, nós desenvolveremos uma ferramenta para que, dada uma base para um subespaço vetorial, possamos encontrar uma base ortonormal para o mesmo subespaço. Em termos matriciais, dada uma matriz A não-singular, queremos encontrar uma nova matriz cujo espaço coluna seja igual a $C(A)$, mas cujos vetores-coluna sejam ortonormais.

Recordando, no capítulo 3, nós desenvolvemos um processo que, dada uma matriz A não singular, nós a transformávamos em uma matriz triangular superior, de modo a resolver sistemas lineares. Isto gerava uma fatoração LU , em que L era uma matriz triangular inferior e U era uma matriz triangular superior. Posteriormente, nós estendemos a fatoração LU para o caso em que A é uma matriz singular, fazendo com que a matriz L pudesse ter linhas inteiras de zeros.

Agora, nós faremos algo parecido, mas de modo que, a partir de uma matriz A não-singular, possamos encontrar uma matriz ortogonal Q tal que $C(Q) = C(A)$, e que induzirá uma fatoração QR . Tal fatoração, porém, pode ser estendida a matrizes não-singulares (muito embora o processo que desenvolveremos agora, chamado processo de Gram-Schmidt não lide de forma tão natural com este caso, mas um processo que desenvolveremos em um dos exercícios será a escolha natural para este caso).

Assim como quando nós apresentamos o processo de eliminação gaussiana, vamos começar a mostrar o processo de Gram-Schmidt com dois vetores LI, e depois estendemos para o caso geral.

Sejam v_1 e v_2 dois vetores LI. Nós queremos achar dois vetores u_1 e u_2 tais que $u_1 \perp u_2$ e $\text{span}(\{v_1, v_2\}) = \text{span}(\{u_1, u_2\})$. Para garantir que eles geram o mesmo subespaço, vamos procurar u_1 e u_2 que sejam combinações lineares de v_1 e v_2 .

Nós podemos começar com $u_1 = v_1$. Para achar um vetor ortogonal a u_1 no plano gerado por v_1 e v_2 , nós podemos projetar v_2 em v_1 e, se p é esta projeção, nós consideramos $u_2 = v_2 - p$.

Neste ponto, é legal definir formalmente uma notação para a projeção, para facilitar as nossas contas e, posteriormente, a discussão sobre o caso geral.

Definição 8.3.1 (Projeção de v em u). *Sejam u e v dois vetores em um espaço vetorial E . Nós definimos a **projeção de v em u** como:*

$$\text{proj}_u(v) = \frac{u^T v}{u^T u} u.$$

Assim sendo, o que nós fizemos até agora foi o seguinte algoritmo:

- 1) Defina $u_1 = v_1$;
- 2) Defina $u_2 = v_2 - \text{proj}_{u_1}(v_2)$.

Para completar o processo, normalizamos u_1 e u_2 , ou seja, fazemos:

- 3) Defina $q_1 = \frac{u_1}{\|u_1\|}$;
- 4) Defina $q_2 = \frac{u_2}{\|u_2\|}$.

De fato, nós podemos verificar que $u_1 \cdot u_2 = 0$ (e, consequentemente, $q_1 \cdot q_2 = 0$):

$$\begin{aligned} u_1 \cdot u_2 &= u_1^T u_2 = v_1^T \left(v_2 - \frac{u_1^T v_2}{u_1^T u_1} u_1 \right) = v_1^T v_2 - \frac{v_1^T v_2}{\|v_1\|^2} v_1^T v_1 = v_1^T v_2 - \frac{v_1^T v_2}{\|v_1\|^2} \|v_1\|^2 \\ &= v_1^T v_2 - v_1^T v_2 = 0. \end{aligned}$$

Antes de prosseguirmos desenvolvendo a teoria, vamos fazer um exemplo para fixarmos bem estas ideias novas:

Exemplo 8.3.2. Sejam $v_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ e $v_2 = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix}$ os geradores de um certo plano em $\mathbb{R}^3$.

Nós queremos encontrar vetores q_1 e q_2 que formem uma base para este plano. Para isso, vamos usar encontrar dois vetores ortogonais u_1 e u_2 que gerem este mesmo plano por meio do processo de Gram-Schmidt e, em seguida, normalizá-los para encontrar q_1 e q_2 .

Primeiramente, nós definimos $u_1 = v_1$. Ou seja:

$$u_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Em seguida, nós definimos $u_2 = v_2 - \text{proj}_{u_1}(v_2)$. A projeção é calculada como:

$$\text{proj}_{u_1}(v_2) = \frac{u_1^T v_2}{u_1^T u_1} u_1.$$

Nós temos que:

$$u_1^T v_2 = u_1 \cdot v_2 = 1 \cdot 1 + 1 \cdot 0 + 1 \cdot 2 = 3;$$

$$u_1^T u_1 = \|u_1\|^2 = 1^2 + 1^2 + 1^2 = 3;$$

$$\frac{u_1^T v_2}{u_1^T u_1} = \frac{3}{3} = 1;$$

$$\frac{u_1^T v_2}{u_1^T u_1} u_1 = 1 \cdot u_1 = u_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Assim sendo, nós temos que:

$$u_2 = v_2 - \text{proj}_{u_1}(v_2) = \begin{bmatrix} 1 \\ 0 \\ 2 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix}.$$

Finalmente, para encontrar q_1 e q_2 , nós fazemos:

$$q_1 = \frac{u_1}{\|u_1\|} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

e

$$q_2 = \frac{u_2}{\|u_2\|} = \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix}.$$

Assim, o conjunto $\left\{ \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \frac{1}{\sqrt{2}} \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix} \right\}$ forma uma base ortonormal para o plano

gerado por v_1 e v_2 .

Suponha agora que nós começamos o processo com três vetores v_1 , v_2 e v_3 LI. Nós precisamos criar u_1 , u_2 e u_3 como combinações lineares de v_1 , v_2 e v_3 tais que $u_1 \cdot u_2 = 0$, $u_1 \cdot u_3 = 0$ e $u_2 \cdot u_3 = 0$. Para u_1 e u_2 , basta repetir o procedimento anterior. Para u_3 , nós podemos definir

$$u_3 = v_3 - \text{proj}_{u_1}(v_3) - \text{proj}_{u_2}(v_3).$$

Nós não vamos fazer as contas aqui, mas é possível mostrar que, definindo u_3 desta forma, nós garantimos que $u_1 \cdot u_3 = 0$ e $u_2 \cdot u_3 = 0$. A partir daí, q_1 , q_2 e q_3 são obtidos normalizando u_1 , u_2 e u_3 .

De maneira geral, nós podemos repetir este processo para k vetores LI: basta definir cada u_i como:

$$u_i = v_i - \sum_{j=1}^{i-1} \text{proj}_{u_j}(v_i).$$

Isto nos dá o seguinte algoritmo para realizar o processo de Gram-Schmidt:

- 1) Defina $u_1 = v_1$;
- 2) Para $i \in \{2, \dots, k\}$, faça:

$$u_i = v_i - \sum_{j=1}^{i-1} \text{proj}_{u_j}(v_i);$$

- 3) Para $i \in \{1, \dots, k\}$, defina:

$$q_i = \frac{u_i}{\|u_i\|}.$$

8.4 Fatoração QR

Agora, nós estamos prontos para desenvolver a ideia principal deste capítulo. Por meio do processo de Gram-Schmidt, nós sabemos transformar uma matriz A não-singular em uma matriz Q ortogonal tal que $C(A) = C(Q)$.

Se $A = [v_1 \ v_2 \ \dots \ v_n]$, nós temos que, após a aplicação de todos os passos do processo de Gram-Schmidt, nós obtemos uma matriz $Q = [q_1 \ q_2 \ \dots \ q_n]$, em que os vetores-coluna são ortonormais. Lembre-se, no entanto, que, como os q_i 's formam uma base para $C(A)$, então os v_i 's podem ser escritos como combinações lineares dos q_i 's. Especificamente, nós podemos fazer isso usando a seguinte fórmula:

$$v_i = \sum_{j=1}^i (v_i^T q_j) q_j.$$

Esta fórmula vem do que discutimos na seção 8.1 sobre como escrever um vetor qualquer em uma base ortonormal, juntamente com a forma com a qual os q_i 's foram definidos nesta seção. Aqueles que quiserem um tratamento mais rigoroso podem demonstrar formalmente o que eu estou falando.

Como $(v_i^T q_j)$ é um escalar, nós podemos reescrever a fórmula como:

$$v_i = \sum_{j=1}^i q_j (v_i^T q_j).$$

Em notação matricial, isto equivale a uma fatoração $A = QR$, onde Q é a matriz formada pelos vetores q_j , e R é a matriz cujas entradas são formadas pelos $v_i^T q_j$'s (note que eu não disse que a entrada ij corresponde a $v_i^T q_j$, eu disse que os $v_i^T q_j$'s formam as entradas da matriz R).

Vamos analisar isso com mais calma. Primeiramente, consideremos o caso 2×2 . Sejam $A = \begin{bmatrix} v_1 & v_2 \end{bmatrix}$, com v_1 e v_2 LI, e suponha que, após o processo de Gram-Schmidt, nós obtivemos uma matriz $Q = \begin{bmatrix} q_1 & q_2 \end{bmatrix}$. Como nós vimos, existe uma fatoração $A = QR$. Como podemos encontrar explicitamente a matriz R ? Nós sabemos que, como Q é uma matriz ortogonal, então $Q^T Q = I$. Multiplicando os dois lados da equação à esquerda por Q^T , nós obtemos:

$$A = QR \implies Q^T A = Q^T QR \implies R = Q^T A.$$

Ou seja, exibindo essas coisas explicitamente, nós temos que:

$$R = \begin{bmatrix} q_1^T \\ q_2^T \end{bmatrix} \begin{bmatrix} v_1 & v_2 \end{bmatrix} = \begin{bmatrix} q_1^T v_1 & q_1^T v_2 \\ q_2^T v_1 & q_2^T v_2 \end{bmatrix} = \begin{bmatrix} v_1^T q_1 & v_2^T q_1 \\ v_1^T q_2 & v_2^T q_2 \end{bmatrix}.$$

Note uma coisa: $v_1^T q_2 = 0$. De fato, $v_1^T q_2 = v_1^T \frac{u_2}{\|u_2\|} = \frac{u_1^T u_2}{\|u_2\|} = 0$. De fato, não só neste caso, mas também no caso geral, a matriz R é triangular superior.

Falando no caso geral, vamos exibir explicitamente a matriz R . Seja $A = \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix}$, em que os v_i 's são vetores LI. Após o processo de Gram-Schmidt, nós obtemos uma matriz $Q = \begin{bmatrix} q_1 & q_2 & \cdots & q_n \end{bmatrix}$. Como Q é uma matriz ortogonal, nós temos que a matriz R é calculada como $R = Q^T A$. Explicitamente, nós temos:

$$R = \begin{bmatrix} q_1^T \\ q_2^T \\ \vdots \\ q_n^T \end{bmatrix} \begin{bmatrix} v_1 & v_2 & \cdots & v_n \end{bmatrix} = \begin{bmatrix} q_1^T v_1 & q_1^T v_2 & \cdots & q_1^T v_n \\ q_2^T v_1 & q_2^T v_2 & \cdots & q_2^T v_n \\ \vdots & \vdots & \ddots & \vdots \\ q_n^T v_1 & q_n^T v_2 & \cdots & q_n^T v_n \end{bmatrix} = \begin{bmatrix} v_1^T q_1 & v_2^T q_1 & \cdots & v_n^T q_1 \\ v_1^T q_2 & v_2^T q_2 & \cdots & v_n^T q_2 \\ \vdots & \vdots & \ddots & \vdots \\ v_1^T q_n & v_2^T q_n & \cdots & v_n^T q_n \end{bmatrix}.$$

É possível mostrar (e nós não o faremos aqui, mas tentem pensar um pouco sobre isso) que, na matriz R , $v_i^T q_j = 0, \forall i < j$. Assim sendo, nós temos que R é uma matriz triangular superior. Ou seja, dada uma matriz A , nós temos que $A = QR$, onde Q é uma matriz ortogonal e R é uma matriz triangular superior. Assim sendo, na prática, nós temos:

$$R = \begin{bmatrix} v_1^T q_1 & v_2^T q_1 & \cdots & v_n^T q_1 \\ 0 & v_2^T q_2 & \cdots & v_n^T q_2 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & v_n^T q_n \end{bmatrix}$$

e

$$A = \begin{bmatrix} | & | & \cdots & | \\ q_1 & q_2 & \cdots & q_n \\ | & | & \cdots & | \end{bmatrix} \begin{bmatrix} v_1^T q_1 & v_2^T q_1 & \cdots & v_n^T q_1 \\ 0 & v_2^T q_2 & \cdots & v_n^T q_2 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & v_n^T q_n \end{bmatrix}$$

Uma coisa muito importante de se pensar é nas dimensões das matrizes que compõem a fatoração QR . Se A é uma matriz $m \times n$, nós temos que Q é uma matriz $m \times m$ e R é uma matriz $n \times n$. No caso em que A é uma matriz não-singular, também é possível encontrar uma fatoração QR , porém o método de Gram-Schmidt precisa ser modificado, ou é necessário utilizar outro método para ortonormalizar as colunas de A . Um método muito bom para isso é utilizar refletores de Householder (que já apareceram em exercícios de capítulos anteriores, e aparecerão novamente em um exercício deste capítulo, que servirá especificamente para discutir esta ideia).

De fato, dada uma matriz $A_{m \times n}$ qualquer, é sempre possível encontrar uma fatoração QR , que não é única. Um teorema um tanto mais avançado diz que é possível garantir a unicidade da fatoração QR se A possuir colunas linearmente independentes e se adicionarmos uma restrição adicional, que é a de todas as entradas da diagonal da matriz R serem elementos estritamente positivos. Mas não vamos nos preocupar com isso aqui.

Um outro fato interessante são as variações da fatoração QR de uma matriz A qualquer. Se A é uma matriz $m \times n$ com posto r , existe (no mínimo) uma fatoração QR completa, em que Q é $m \times m$ e R é $m \times n$; (no mínimo) uma fatoração QR reduzida, em que Q é $m \times n$ e R é $n \times n$; e (no mínimo) uma fatoração QR compacta, em que Q é $m \times r$ e R é $r \times n$. No nosso caso, nós estamos trabalhando com a fatoração QR reduzida de A , mas essas distinções não são uma preocupação para nós neste curso. Ainda assim, já é legal conhecer estas informações, porque, em outros cursos, elas serão importantes.

Para encerrar a parte teórica deste exercício, vamos fazer um exemplo simples para mostrar, na prática, como encontrar a fatoração QR de uma matriz.

Exemplo 8.4.1. Considere a matriz $A = \begin{bmatrix} 1 & 8 \\ 3 & 4 \end{bmatrix}$. Queremos encontrar matrizes Q ortogonal e R triangular superior tais que $A = QR$. Para isso, primeiramente nós encontraremos a matriz Q usando o processo de Gram-Schmidt.

Sejam $v_1 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ e $v_2 = \begin{bmatrix} 8 \\ 4 \end{bmatrix}$. Definimos $u_1 = v_1 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$ e calculamos u_2 como:

$$u_2 = v_2 - \text{proj}_{u_1}(v_2) = v_2 - \frac{u_1^T v_2}{u_1^T u_1} u_1.$$

Calculando todos os termos da projeção:

$$u_1^T v_2 = u_1 \cdot v_2 = 1 \cdot 8 + 3 \cdot 4 = 20;$$

$$u_1^T u_1 = \|u_1\|^2 = 1^2 + 3^2 = 10;$$

$$\frac{u_1^T v_2}{u_1^T u_1} = \frac{20}{10} = 2;$$

$$\text{proj}_{u_1}(v_2) = \frac{u_1^T v_2}{u_1^T u_1} u_1 = 2 \cdot \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 2 \\ 6 \end{bmatrix}.$$

Assim sendo, nós temos que u_2 é dado por:

$$u_2 = v_2 - \text{proj}_{u_1}(v_2) = \begin{bmatrix} 8 \\ 4 \end{bmatrix} - \begin{bmatrix} 2 \\ 6 \end{bmatrix} = \begin{bmatrix} 6 \\ -2 \end{bmatrix}.$$

Agora, nós vamos normalizar u_1 e u_2 . Nós obtemos:

$$q_1 = \frac{u_1}{\|u_1\|} = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

e

$$q_2 = \frac{u_2}{\|u_2\|} = \frac{1}{\sqrt{40}} \begin{bmatrix} 6 \\ -2 \end{bmatrix} = \frac{1}{2\sqrt{10}} \begin{bmatrix} 6 \\ -2 \end{bmatrix} = \frac{1}{\sqrt{10}} \begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

Assim sendo, nós encontramos a matriz Q , ela é dada por:

$$Q = \begin{bmatrix} 1/\sqrt{10} & 3/\sqrt{10} \\ 3/\sqrt{10} & -1/\sqrt{10} \end{bmatrix}.$$

Agora, nós vamos encontrar a matriz R , fazendo $R = Q^T A$. Nós temos que:

$$R = \begin{bmatrix} 1/\sqrt{10} & 3/\sqrt{10} \\ 3/\sqrt{10} & -1/\sqrt{10} \end{bmatrix} \begin{bmatrix} 1 & 8 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 10/\sqrt{10} & 20/\sqrt{10} \\ 0 & 20/\sqrt{10} \end{bmatrix}.$$

Assim sendo, nós temos que:

$$A = \begin{bmatrix} 1/\sqrt{10} & 3/\sqrt{10} \\ 3/\sqrt{10} & -1/\sqrt{10} \end{bmatrix} \begin{bmatrix} 10/\sqrt{10} & 20/\sqrt{10} \\ 0 & 20/\sqrt{10} \end{bmatrix}.$$

Referências Bibliográficas

- 1 SAPORITO, Y. F. Apresentação de slides, *A geometria das equações lineares*. 2021. Material didático da disciplina Álgebra Linear para a turma de 2021.
- 2 GOEDERT, G. T. Lista de exercícios, *Álgebra Linear - Lista de Exercícios 1*. 2025. Material didático da disciplina Álgebra Linear para a turma de 2025.
- 3 SAPORITO, Y. F. Apresentação de slides, *Multiplicação de Matrizes e Eliminação Gaussiana*. 2021. Material didático da disciplina Álgebra Linear para a turma de 2021.
- 4 STRANG, G. *Álgebra Linear e suas Aplicações*. 4. ed. São Paulo, SP: Cengage Learning, 2010. ISBN 9788522107445.
- 5 SAPORITO, Y. F. Apresentação de slides, *Fatoração LU*. 2021. Material didático da disciplina Álgebra Linear para a turma de 2021.
- 6 SAPORITO, Y. F. Apresentação de slides, *Espaços vetoriais, espaço coluna e núcleo*. 2021. Material didático da disciplina Álgebra Linear para a turma de 2021.
- 7 AXLER, S. *Linear Algebra Done Right*. Fourth. Springer, 2026. (Undergraduate Texts in Mathematics). Disponível em: [<https://linear.axler.net/>](https://linear.axler.net/).
- 8 SAPORITO, Y. F. Apresentação de slides, *Transformações Lineares*. 2021. Material didático da disciplina Álgebra Linear para a turma de 2021.
- 9 SAPORITO, Y. F. Apresentação de slides, *Ortogonalidade*. 2021. Material didático da disciplina Álgebra Linear para a turma de 2021.
- 10 RUGGIERO, M. A. G.; VITORINO, A. *Álgebra Linear e Aplicações*. 2021. [<https://www.ime.unicamp.br/~marcia/AlgebraLinear/index.html>](https://www.ime.unicamp.br/~marcia/AlgebraLinear/index.html). Acessado em: 06 de agosto de 2026.
- 11 TREFETHEN, L. N.; BAU III, D. *Numerical Linear Algebra*. [S.l.]: Society for Industrial and Applied Mathematics (SIAM), 1997. v. 50. (Other Titles in Applied Mathematics, v. 50). ISBN 978-0-89871-361-9.
- 12 GOEDERT, G. T. Lista de exercícios, *Álgebra Linear - Lista de Exercícios A2*. 2025. Material didático da disciplina Álgebra Linear para a turma de 2025.
- 13 SANTOS, A. D. F. dos; GUEDES, J. T. G. Lista de exercícios, *Banco de Questões 2 - Álgebra Linear Numérica*. 2026. Material didático da disciplina Álgebra Linear Numérica para a turma de 2026.